



UNIVERSIDAD
DE GRANADA

E.T.S. de Ingenierías Informática y de Telecomunicación

INGENIERÍA INFORMÁTICA

TRABAJO DE FIN DE GRADO

Modelos generativos basados en procesos de difusión para la detección de datos fuera de la distribución en imágenes médicas

Presentado por:
Alejandro Egea López

Curso académico 2025-2026



Modelos generativos basados en procesos de difusión para la detección de datos fuera de la distribución en imágenes médicas

Alejandro Egea López

Alejandro Egea López *Modelos generativos basados en procesos de difusión para la detección de datos fuera de la distribución en imágenes médicas.*

Trabajo de fin de Grado. Curso académico 2025-2026.

Directores

Miguel López Pérez
*Departamento de Ciencias de la
Computación e Inteligencia Artificial*

Rafael Molina Soriano
*Departamento de Ciencias de la
Computación e Inteligencia Artificial*

Ingeniería Informática
E.T.S. de Ingenierías
Informática y de
Telecomunicación
Universidad de Granada

*A Encarni,
mi dulce silencio*

Agradecimientos

A mis tutores, **Rafael Molina** y **Miguel López**, junto con **Javier Sáez**, por formar un equipo tan cercano y atento. Gracias a vuestro apoyo continuo desde el principio de curso os habéis convertido en auténticos mentores de los que he aprendido muchísimo. Ha sido, además, un verdadero placer que este proyecto haya unido la gran experiencia de Rafael con el comienzo de etapa docente de Miguel, y hace poco también la de Javier.

Gracias.

A la **Universidad de Murcia**, por haberme formado durante estos años y por haberme dado la oportunidad de conocer a personas que se han convertido en amigos para siempre, tanto los de la residencia como los de McDoner.

Gracias.

A la **Universidad de Granada** y a la ciudad misma, Graná, por acogerme en este último año y por hacer de esta etapa final una experiencia que no olvidaré.

Gracias.

A mis padres, **Paco** y **Carmen**, por darme la oportunidad de estudiar y por creer en mí en todo momento.

Gracias.

A mi hermana **Laura**, por acompañarme desde siempre.

Gracias.

Abstract

Diffusion-based Generative Models for Out-of-Distribution Detection in Medical Images

Alejandro Egea López

Keywords: out-of-distribution detection, diffusion models, variational autoencoders, computational histopathology, foundation models, anomaly detection

Abstract

Machine learning models utilized in clinical practice operate under an implicit closed-world assumption: the data encountered at deployment time follows the same statistical distribution as the data seen during training. In real clinical environments, this assumption is not guaranteed to hold. Images may originate from different scanners, acquisition protocols, or institutions, or may contain pathologies that were never represented in the training set. When out-of-distribution (OOD) samples are presented to a model not designed to recognize them, the model typically does not abstain from making a prediction; instead, it produces a confident output as if the input belonged to the known distribution. In high-stakes domains, such as digital pathology, this behavior can translate directly into diagnostic errors.

OOD detection addresses this problem by equipping a system with a mechanism that quantifies how unfamiliar a given sample is with respect to the training distribution, producing an anomaly score that can be compared against a threshold to flag cases for clinical review. Beyond this safety role, OOD detection in the medical domain carries a second, more proactive interpretation: if a model learns the distribution of healthy tissues or known benign categories, an elevated anomaly score can itself serve as a signal that a sample deserves closer inspection, potentially highlighting morphological patterns that were absent during training, such as biopsies with unusual grades of malignancy.

Classical approaches to OOD detection —based on density estimation, distance metrics, or supervised classifiers— impose different requirements: while some methods can calibrate their detection threshold using in-distribution data alone, others depend on labeled OOD samples or supervised training. In any case, these requirements are difficult to satisfy fully in a real clinical setting where labels are scarce and expensive to obtain, and rare pathologies are, by definition, underrepresented in training data. Generative models offer a complementary, unsupervised alternative: only in-distribution data is required for training, and the model's fit to that distribution —whether measured through reconstruction quality, likelihood, or latent-space structure— acts as the anomaly signal. Variational Autoencoders (VAEs) were among the first generative architectures explored for this purpose, but their discriminative power is constrained by the size of the latent space, which acts as a fixed bottleneck chosen prior to training. If too narrow, the model fails even on in-distribution samples; if too wide, it reconstructs anomalous samples faithfully as well, losing its detection capability.

Diffusion-based generative models offer a methodological advantage in this respect: the information bottleneck is not a fixed architectural property but is instead determined by the level of noise applied at inference time. This introduces an external degree of freedom that allows the sensitivity of the detector to be calibrated without retraining the underlying model. Diffusion models have also established themselves as the current state of the art among generative models due to their ability to capture complex data distributions and produce high-fidelity samples, making them an attractive candidate for OOD detection in medical imaging. Training diffusion models directly on high-resolution histological images is, however, substantially more demanding than training simpler architectures. This work addresses that challenge by delegating the extraction of semantic features to UNI, a large-scale foundation model pretrained specifically for computational histology, and training latent diffusion models on the resulting compact feature space. This combination reduces computational requirements to hours on a single GPU, making these techniques accessible to groups with modest resources, and constitutes an emerging line of research with high transfer potential in the medical domain. Building on this motivation, the project addresses the following research question: is it possible to build a clinically viable OOD detection system in computational histology by combining the semantic richness of a foundation model with the generative capacity of latent diffusion models?

The work is structured into a theoretical and an experimental part. The theoretical part reviews the family of variational generative models that underpins the study, progressing from Variational Autoencoders to Hierarchical VAEs, Denoising Diffusion Probabilistic Models (DDPMs), and Latent Diffusion Models (LDMs), establishing the mathematical foundations needed to understand the methods evaluated later. It then addresses OOD detection itself: its definition and taxonomy, distinguishing covariate shift from semantic shift and characterizing several related subproblems. The role of foundation models in transforming whole-slide images into tractable feature representations is also discussed, alongside classical OOD methods and reconstruction-based approaches using VAEs and DDPMs. The theoretical part closes with a discussion of the particularities of the medical domain, including the proposal of a third type of distribution shift—contextual shift—arising when the input modality or anatomical region is inconsistent with the training distribution.

The experimental part evaluates these methods across datasets of increasing complexity and clinical relevance. Simple synthetic datasets serve as qualitative validation of expected reconstruction behavior. A standard benchmark with a clear domain gap provides a moderate-difficulty reference. A histological dataset of colorectal tissue classes introduces progressively harder configurations, where some tissue types share partial morphological characteristics. Finally, SICAP—a prostate biopsy dataset annotated with Gleason grades—represents the setting of greatest clinical relevance: images are encoded into compact feature vectors using UNI, and two configurations are evaluated based on how broadly the in-distribution class is defined, with high-grade tissue as the OOD target in both cases.

For each dataset, VAE- and DDPM-based models are evaluated following a consistent training protocol. On the SICAP dataset, generative scores are compared against distance-based baselines computed on the raw UNI features, isolating the contribution of the generative model with respect to simply operating on the pretrained representation. Results show that reconstruction-based DDPM scores and distance-based scores computed on the VAE latent space are both competitive with the Mahalanobis baseline on raw UNI features, while direct distance methods on those same raw features already provide a strong reference. The

cosine-based noise-prediction score degrades severely, suggesting that not all scoring strategies transfer equally across architectures and feature spaces. Overall, the relative advantage of generative approaches depends strongly on both the scoring strategy and the difficulty of the configuration, with margins narrowing as the in-distribution definition is broadened to include borderline-grade tissue.

Overall, this work provides a systematic, reproducible comparison of variational generative models for unsupervised OOD detection in histopathology, built on top of a pretrained foundation model to keep computational requirements accessible. All code is released as open-source software, and the findings contribute to clarifying under which conditions generative models offer genuine advantages over simpler distance-based alternatives in computational pathology, and where the choice of scoring strategy matters as much as the choice of model family.

Resumen

Modelos generativos basados en procesos de difusión para la detección de datos fuera de la distribución en imágenes médicas

Alejandro Egea López

Palabras clave: detección fuera de la distribución, modelos de difusión, autoencoders variacionales, histopatología computacional, modelos fundacionales, detección de anomalías

Resumen

Los modelos de aprendizaje automático utilizados en la práctica clínica operan bajo una hipótesis implícita de mundo cerrado: los datos encontrados en el momento del despliegue siguen la misma distribución estadística que los datos vistos durante el entrenamiento. En entornos clínicos reales, esta hipótesis no está garantizada. Las imágenes pueden provenir de distintos escáneres, protocolos de adquisición o instituciones, o contener patologías que nunca estuvieron representadas en el conjunto de entrenamiento. Cuando se presentan muestras fuera de la distribución (*out-of-distribution*, OOD) a un modelo no diseñado para reconocerlas, este típicamente no se abstiene de realizar una predicción; en cambio, produce una salida con alta confianza como si la entrada perteneciera a la distribución conocida. En dominios de alto riesgo como la patología digital, este comportamiento puede traducirse directamente en errores diagnósticos.

La detección OOD aborda este problema dotando al sistema de un mecanismo que cuantifica cuán desconocida es una muestra respecto a la distribución de entrenamiento, produciendo una puntuación de anomalía que puede compararse contra un umbral para marcar casos para revisión clínica. Más allá de este papel de seguridad, la detección OOD en el dominio médico tiene una segunda interpretación más proactiva: si un modelo aprende la distribución de tejido sano o de categorías benignas conocidas, una puntuación de anomalía elevada puede servir por sí misma como señal de que una muestra merece una inspección más detallada, destacando potencialmente patrones morfológicos ausentes durante el entrenamiento, como biopsias con grados inusuales de malignidad.

Los enfoques clásicos de detección OOD (basados en estimación de densidad, métricas de distancia o clasificadores supervisados) imponen requisitos distintos que son difíciles de satisfacer plenamente en un entorno clínico real, donde las etiquetas son escasas y costosas de obtener, y las patologías raras están, por definición, infrarrepresentadas en los datos de entrenamiento. Los modelos generativos ofrecen una alternativa no supervisada complementaria: solo se requieren datos dentro de la distribución para el entrenamiento, y el ajuste del modelo a dicha distribución (ya sea medido mediante la calidad de reconstrucción, la verosimilitud o la estructura del espacio latente) actúa como señal de anomalía. Los Autoencoders Variacionales (VAEs) fueron de las primeras arquitecturas generativas exploradas con este fin, pero su poder discriminativo está limitado por el tamaño del espacio latente, que actúa como un cuello de botella fijo elegido antes del entrenamiento. Si es demasiado estrecho, el modelo falla incluso con muestras dentro de la distribución; si es demasiado am-

plio, reconstruye también las muestras anómalas con fidelidad, perdiendo así su capacidad de detección.

Los modelos generativos basados en difusión ofrecen una ventaja metodológica en este sentido: el cuello de botella de información no es una propiedad arquitectónica fija, sino que está determinado por el nivel de ruido aplicado en el momento de la inferencia. Esto introduce un grado de libertad externo que permite calibrar la sensibilidad del detector sin reentrenar el modelo subyacente. Los modelos de difusión se han consolidado además como el estado del arte actual entre los modelos generativos, lo que los convierte en un candidato atractivo para la detección OOD en imagen médica. Este trabajo aborda el reto de entrenarlos sobre imágenes histológicas de alta resolución delegando la extracción de características semánticas en UNI, un modelo fundacional preentrenado específicamente para histología computacional, y entrenando modelos de difusión latente en el espacio de características resultante. Esta combinación reduce los requisitos computacionales a pocas horas en una única GPU, haciendo estas técnicas accesibles a grupos con recursos modestos.

El trabajo se estructura en una parte teórica y una parte experimental. La primera revisa la familia de modelos generativos variacionales que sustenta el estudio, desde los VAEs y los VAEs Jerárquicos hasta los Modelos de Difusión Probabilística por Eliminación de Ruido (DDPMs) y los Modelos de Difusión Latente (LDMs), estableciendo los fundamentos matemáticos necesarios. A continuación aborda la detección OOD: su definición y taxonomía, distinguiendo el desplazamiento de covariables del desplazamiento semántico, y propone un tercer tipo de desplazamiento de distribución (el desplazamiento contextual) que surge cuando la modalidad de entrada o la región anatómica es inconsistente con la distribución de entrenamiento. La parte experimental evalúa los métodos en conjuntos de datos de complejidad e interés clínico crecientes, culminando en SICAP, un conjunto de datos de biopsias de próstata anotado con grados de Gleason, donde las imágenes se codifican en vectores de características compactos mediante UNI. Los resultados muestran que las puntuaciones DDPM basadas en reconstrucción y las puntuaciones basadas en distancia en el espacio latente del VAE son competitivas con la línea de base de Mahalanobis sobre las características brutas de UNI, mientras que los métodos de distancia directa sobre dichas características brutas ya constituyen una referencia sólida. En conjunto, este trabajo proporciona una comparación sistemática y reproducible de modelos generativos variacionales para la detección OOD no supervisada en histopatología, con todo el código publicado como software de código abierto.

Índice general

Abstract	v
Resumen	ix
1. Introducción	1
I. Fundamentos teóricos	5
2. Modelos generativos variacionales: desde los VAEs hasta los LDMs	6
2.1. Estrategias de desarrollo de los modelos de difusión	6
2.2. Variational Autoencoders	6
2.2.1. Encoder y decoder probabilísticos	7
2.2.2. Entrenamiento por Evidence Lower Bound	8
2.2.3. VAE gaussiano	9
2.2.4. El truco de reparametrización	10
2.2.5. VAE jerárquico	11
2.3. Denoising Diffusion Probabilistic Models	12
2.3.1. Proceso forward: difusión del ruido	13
2.3.2. Proceso reverse: denoising aprendido	14
2.3.3. Parametrización y función de pérdida	15
2.3.4. ELBO de DDPM	17
2.4. Latent Diffusion Models	17
2.4.1. Compresión perceptual: autocodificador latente	17
2.4.2. Difusión en el espacio latente	18
2.4.3. Una alternativa potente: los Foundation Models	18
3. Detección de datos fuera de la distribución	20
3.1. Definición y taxonomía de la detección OOD generalizada	20
3.1.1. Particularidades del dominio médico	21
3.2. Métodos clásicos para la detección OOD	22
3.2.1. Métodos basados en clasificación	23
3.2.2. Métodos basados en densidad	25
3.2.3. Métodos basados en distancia	25
3.3. Scores OOD basados en modelos generativos	27
3.3.1. Reconstrucción con VAE	28
3.3.2. Reconstrucción con DDPM	28

II. Estudio experimental	31
4. Marco experimental	32
4.1. Descripción de los datos	33
4.2. Procesamiento de los datos	38
4.2.1. Partición de los conjuntos	38
4.2.2. Normalización	38
4.2.3. Representación con modelo fundacional para SICAP	38
4.3. Detalles de implementación	40
4.3.1. Entorno de desarrollo	40
4.3.2. Arquitecturas	40
4.3.3. Protocolo de entrenamiento	43
4.4. Definición formal de los <i>scores</i> OOD implementados	45
4.4.1. <i>Scores</i> para el VAE	46
4.4.2. <i>Scores</i> para el DDPM	47
4.4.3. Hiperparámetros de inferencia OOD	49
4.5. Métricas de evaluación	50
5. Resultados y discusión	51
5.1. Resultados de los experimentos	51
5.2. Conjuntos sintéticos	51
5.2.1. Validación del entrenamiento y capacidad generativa	52
5.2.2. MNIST/SVHN y PathMNIST: VAE	54
5.2.3. MNIST/SVHN y PathMNIST: DDPM	55
5.2.4. SICAP: resultados del mejor experimento por conjunto	57
5.3. Análisis comparativo entre métodos	60
5.4. Análisis de dificultades y limitaciones	63
6. Conclusiones y trabajo futuro	67
6.1. Conclusiones	67
6.2. Trabajo futuro	68
A. Resultados cuantitativos completos	71
A.1. Toy: Blobs y Moons	71
A.2. MNIST	72
A.3. PathMNIST	72
A.4. SICAP	74
B. Planificación y estimación de costes	76
B.1. Planificación temporal	76
B.2. Estimación de costes	77
Bibliografía	79

1. Introducción

Contexto

En 2013, un estudio publicado en *Psychological Science* pidió a radiólogos expertos que identificaran nódulos pulmonares en una serie de tomografías computarizadas. En una de ellas, los investigadores habían incrustado la silueta de un gorila, 48 veces mayor que el nódulo a localizar, el 83 % de los radiólogos no lo vieron [ZFI⁺22]. El fenómeno, conocido como *ceguera por inatención*, ilustra algo que no es exclusivo de la percepción humana: también caracteriza a los modelos de aprendizaje automático desplegados en entornos clínicos. Esto es, cuando un sistema se entrena para buscar algo concreto, deja de procesar adecuadamente aquello que no esperaba encontrar, asumiendo que cualquier otra condición de los datos habrá de pertenecer a lo aprendido.

Desde una perspectiva formal, todo modelo de aprendizaje automático opera bajo una hipótesis implícita que denominaremos *hipótesis de mundo cerrado*: los datos que recibirá durante su aplicación en el mundo real provienen de la misma distribución estadística que los que vio durante el entrenamiento, la llamada distribución de referencia o *in-distribution* (ID). En la práctica clínica, sin embargo, la hipótesis de mundo cerrado rara vez se sostiene; pues las imágenes pueden provenir de equipos distintos, de protocolos de adquisición diferentes, o contener patologías no representadas en los datos de entrenamiento. Ante estas muestras *fuera de la distribución* (del inglés *out-of-distribution*, OOD), el modelo no dice «no sé», sino que tiende a emitir una predicción con total confianza como si reconociera lo que tiene delante [YZLL24, HYC⁺24]¹. Por ejemplo, el conocido ensayo MASAI (*Mammography Screening with Artificial Intelligence*), primer ensayo controlado aleatorizado sobre lectura asistida por IA en cribado mamográfico, ilustró hace ya unos años ese potencial de forma concreta: el sistema redujo la carga de trabajo radiológico en casi un 44 % manteniendo una tasa de detección de cáncer comparable a la de la doble lectura estándar [LJL⁺23]. No obstante, si bien avances como este demostraron ya desde los orígenes que la IA podía integrarse con garantías en el flujo clínico, la barrera fundamental de estos primeros modelos de IA es que eran incapaces de reconocer muestras OOD.

La detección OOD nació, precisamente, para solventar este problema. El objetivo es dotar al sistema de un mecanismo capaz de cuantificar cuán ajena le resulta cada muestra (lo que denominaremos *score de anomalía* u *ood score*). En efecto, cuando este *score* supere un umbral determinado (habitualmente llamado *ood threshold*), se notifica para que se pueda delegar la decisión en el profesional sanitario. Esta intervención puede derivar, inclusive, en una decisión conjunta *profesional-máquina* sesgada en base a un modelo que presente un desempeño razonablemente satisfactorio. En la literatura, la calidad de esa separación ID/OOD se evaluaba mediante métricas como AUROC, AUPR y FPR@95TPR, que se detallarán en el marco experimental.

De hecho, ese mismo mecanismo (saber cuándo «no sé») admite, sin embargo, una lectura más interesante, y es la que constituye el presente trabajo. Si un modelo aprende la distribu-

¹Cabe notar que esto ocurre siempre que no existan medidas preventivas diseñadas para evitar tal comportamiento.

ción del tejido sano o de las categorías benignas conocidas, este debería producir un *score* de anomalía elevado para una muestra OOD, alertando al patólogo de que esa muestra merece una revisión cuidadosa. Esto incluye, por ejemplo, biopsias con un grado de malignidad inusual, con un patrones morfológicos que nunca aparecieron durante el entrenamiento. La detección OOD se convierte así en algo más que un mecanismo de seguridad pasivo: es una herramienta de apoyo activo al diagnóstico, capaz de señalar hallazgos inesperados no presentes durante el proceso de entrenamiento.

Para que este enfoque sea efectivo, resulta fundamental emplear modelos capaces de aprender la distribución de los datos, permitiendo así que las muestras que presenten desviaciones sobre dicha distribución sean tratadas como candidatas a OOD. Con este objetivo, la literatura ha explorado diversas arquitecturas generativas que, aprendiendo dicha distribución, persiguen discernir con precisión todo aquello que se aleje de la «normalidad» de los datos de entrenamiento.

En particular, los modelos generativos basados en procesos de difusión han emergido como una de las familias más expresivas de modelos generativos [HJA20, LSK⁺25]. Su lógica de funcionamiento (aprender a invertir un proceso iterativo de corrupción gaussiana de los datos) les confiere una propiedad especialmente relevante para la detección de patologías no vistas durante el entrenamiento, ya que entrenados exclusivamente sobre datos normales o benignos, tienden a reconstruir bien lo que conocen y mal lo que no, de modo que el error de reconstrucción y sus derivados actúan de forma natural como señal de anomalía [GPT⁺23, WLSW22].

Motivación

Los métodos clásicos de detección OOD presentan una limitación estructural en el ámbito médico. Los enfoques basados en clasificación, densidad o distancia [HG17, LLS18, SMZL22] asumen, en su formulación habitual, que el modelo dispone de un clasificador supervisado entrenado sobre las clases ID, o que se tienen muestras OOD etiquetadas para calibrar umbrales o penalizar la confianza. Ninguna de las dos suposiciones es fácil de satisfacer en una clínica real, donde las etiquetas son escasas y costosas, y las patologías raras, por definición, no abundan en los datos de entrenamiento.

Los modelos generativos ofrecen una alternativa no supervisada a este problema: basta con disponer de datos ID para entrenarlos, y es la propia calidad de la reconstrucción la que actúa como señal de anomalía. Dentro de ellos, los *autoencoders* variacionales (VAE) fueron la primera arquitectura explorada para este propósito; sin embargo, su capacidad discriminativa queda supeditada al tamaño del espacio latente, que actúa como cuello de botella y debe fijarse antes de cada entrenamiento. Si es demasiado estrecho, el modelo falla incluso en las muestras normales, y si es demasiado ancho, reconstruye también las anómalas y pierde su capacidad de detección [HYC⁺24, GPT⁺23].

Por su parte, los modelos de difusión se han consolidado como el estado del arte actual en la IA generativa, reconocidos por su extraordinaria capacidad para modelar distribuciones complejas y generar imágenes sintéticas de alta fidelidad, entre otras de sus múltiples aplicaciones. En el contexto específico de la detección OOD, estos modelos aportan una cualidad metodológica ventajosa frente a los VAE: el cuello de botella no es una propiedad fija de la arquitectura, sino que viene determinado por el nivel de ruido aplicado durante la inferencia. Esto introduce una flexibilidad importante, ya que permite ajustar y calibrar la sensibilidad del detector de forma externa sin necesidad de reentrenar el modelo [GPT⁺23].

A esta motivación metodológica se suma un desafío práctico esencial: la accesibilidad de estas tecnologías en el entorno médico real, un concepto que definimos como *democratización*. Entrenar modelos de difusión directamente sobre imágenes histológicas de alta resolución requeriría días de cómputo e infraestructuras de *hardware* masivas, recursos que están fuera del alcance de la gran mayoría de los grupos de investigación clínicos u hospitalarios. Para afrontar esta barrera, este trabajo plantea la siguiente estrategia: delegar la extracción de características semánticas en UNI [CDL⁺24] (un *foundation model* de escala masiva preentrenado específicamente para histología computacional) y entrenar los modelos de difusión latente sobre ese espacio compacto de características. Esta combinación reduce el coste computacional de días a horas en una sola GPU, permitiendo que grupos con recursos modestos puedan adoptar estas herramientas. La intersección entre *foundation models* como extractores y modelos de difusión como detectores constituye una línea de investigación incipiente y con un alto potencial de transferencia en el dominio médico.

Atendiendo a la estructura de un trabajo de investigación científica, este escenario da lugar a la *pregunta de investigación* que guía el presente TFG: *¿Es posible construir un sistema de detección OOD clínicamente viable en histología computacional combinando la riqueza semántica de un modelo de base con la capacidad generativa de los modelos de difusión latente?*

Este proyecto representa una oportunidad excelente para profundizar en el estado del arte de la IA generativa avanzada (VAE, modelos de difusión y difusión latente), así como para adoptar buenas prácticas metodológicas en la investigación mediante el uso de herramientas de la industria como *Weights & Biases*² para la gestión de experimentos y *OmegaConf*³ para la configuración modular. Además, todo el *software* se ha desarrollado bajo criterios de reproducibilidad, escalabilidad y código abierto⁴. <https://github.com/a-egealopez/ood-detection-genai>. Finalmente, cabe destacar que la condición médica del problema no ha sido accidental; pues la posibilidad de que un trabajo de fin de grado pueda contribuir, aunque sea modestamente, a que un sistema clínico pueda desarrollar mejores métodos de detección de patologías ha sido una motivación importante.

Objetivos del TFG

Este trabajo se encuadra en la modalidad de **TFG de Investigación**. En concreto, el proyecto se basa en estudiar el comportamiento de modelos teóricos avanzados de IA aplicados a un problema médico (la detección de muestras anómalas de tejido histológico). Con este fin, se realizan implementaciones de dichos modelos y se proponen experimentos científicos para estudiar su potencial y diferencias. Este enfoque no solo permite adquirir competencias metodológicas y técnicas que exceden el plan de estudios del grado, sino que sitúa el trabajo en estrecha cercanía con el estado del arte actual.

Partiendo de esta base metodológica, el objetivo principal de este TFG se define de la siguiente manera:

Objetivo general (OG): Estudiar y evaluar comparativamente el potencial de los modelos generativos basados en procesos de difusión para la detección de datos

²Weights & Biases (W&B) es una plataforma de MLOps enfocada en el seguimiento, registro y visualización de experimentos de aprendizaje profundo. Disponible en: <https://wandb.ai/>

³OmegaConf es una biblioteca de configuración jerárquica para Python, útil para gestionar de forma modular los hiperparámetros de los modelos. Disponible en: <https://omegaconf.readthedocs.io/>

⁴Todo el software desarrollado bajo dichos criterios se encuentra publicado en el siguiente repositorio: <https://github.com/a-egealopez/ood-detection-genai>

1. Introducción

fuera de la distribución en imagen médica. Analizar su comportamiento frente a métodos basados en distancia y autoencoders variacionales. El estudio será realizado sobre representaciones extraídas por un *foundation model* de histología.

El objetivo general se ha articulado en torno a los siguientes objetivos específicos, ordenados según su dependencia:

- **OE1:** Revisar el estado del arte en detección OOD, con especial atención a su taxonomía, los métodos clásicos (con enfoque en los métodos de distancia) y los métodos basados en reconstrucción generativa, así como las particularidades propias del dominio médico.
- **OE2:** Estudiar los fundamentos teóricos de los modelos generativos relevantes para este trabajo: autoencoders variacionales (VAE y HVAE), modelos de difusión probabilística (DDPM) y modelos de difusión en espacio latente (LDM).
- **OE3:** Implementar y evaluar métodos de referencia (*baselines*) basados en distancia (Mahalanobis y k -NN) sobre las representaciones extraídas por UNI en los conjuntos de datos seleccionados.
- **OE4:** Implementar y evaluar métodos generativos basados en VAE y DDPM para la detección OOD, entrenados sobre el mismo espacio de características y evaluados bajo el mismo protocolo experimental que los *baselines*.
- **OE5:** Analizar y comparar los resultados de todos los métodos evaluados, discutiendo en qué condiciones los modelos de difusión presentan ventajas frente a las alternativas y cuáles son sus limitaciones.

Estructura de la memoria

En el presente capítulo se han descrito el contexto, la motivación y los objetivos del trabajo; el resto de la memoria se ha estructurado como sigue.

- **Parte I — Fundamentos teóricos.** El Capítulo 2 recorre la familia de modelos generativos variacionales que sustentan el trabajo, desde los autoencoders variacionales hasta los DDPMs y los LDMs, estableciendo las bases matemáticas necesarias para comprender los métodos evaluados. El Capítulo 3 aborda la detección OOD: su definición y taxonomía, el papel de los *foundation models* en la generación de espacios de características, los métodos clásicos y los métodos de reconstrucción generativa, y las particularidades del dominio médico.
- **Parte II — Estudio experimental.** El Capítulo 4 describe el marco experimental: datos, preprocesado, implementación y métricas de evaluación. El Capítulo 5 presenta los resultados de todos los métodos evaluados, el análisis comparativo entre ellos y una discusión de errores y limitaciones.

Finalmente, se presentan las referencias bibliográficas consultadas a lo largo del trabajo.

Parte I.

Fundamentos teóricos

2. Modelos generativos variacionales: desde los VAEs hasta los LDMs

2.1. Estrategias de desarrollo de los modelos de difusión

Una de las cuestiones fundamentales de los modelos generativos radica en aprender modelos probabilísticos lo suficiente expresivos como para reproducir fielmente la compleja estructura de datos reales. Concretamente, en este trabajo proponemos aplicar dichos modelos para abordar un problema de detección de anomalías en el ámbito de las imágenes médicas. En particular, estudiaremos los modelos de difusión, que actualmente se encuentran entre los modelos generativos más avanzados debido a la alta calidad de las imágenes que son capaces de generar.

Como se ha señalado en la literatura [LSK⁺25], existen al menos tres estrategias desde las cuales se han desarrollado los modelos de difusión (variacional, basada en puntuación [*score*] y basada en flujo), siendo la perspectiva variacional la que hemos elegido para este estudio. Esta decisión se basa en un compromiso entre la potencia que puede exhibir el modelo y la claridad con la que se puede desarrollar su teoría. En concreto, tanto los modelos basados en puntuación (*scored-based*) como en flujo (*flow-matching*) presentan una mayor expresividad matemática: recurren a ecuaciones diferenciales estocásticas (SDE) y flujos continuos normalizados (CNF), respectivamente. Sin embargo, esta mayor expresividad añade una notable complejidad teórica y computacional que no es estrictamente necesaria para los objetivos de este trabajo, y es por ello que nos decantamos por el enfoque variacional.

Bajo esta óptica, comenzaremos revisando los *Variational Autoencoders* (VAEs), que nos descubren el concepto de las variables latentes; seguidamente, analizaremos los *Hierarchical VAEs* (HVAEs) y cómo su estructura jerárquica nos conduce de forma natural a los *Denosing Diffusion Probabilistic Models* (DDPMs), actualmente considerados el estado del arte en generación de imágenes [LSK⁺25]; y, finalmente, integraremos todos estos conceptos para construir los *Latent Diffusion Models* (LDMs) [GTW⁺23].

2.2. Variational Autoencoders

Para comprender la trascendencia de los VAEs, es conveniente recordar los *autoencoders* (AE). Estos se componen de dos redes neuronales deterministas: una, que denotaremos por *encoder*, cuyo cometido es comprimir una entrada en un código latente; y otra, llamada *decoder*, que se encarga de reconstruir la entrada a partir de dicho código. El modelo se entrena para minimizar el error de reconstrucción entre la entrada original y la propia reconstrucción, pero generalmente esto produce un espacio latente desordenado. Esto dificulta notablemente el muestreo. Los VAEs solucionan este problema imponiendo una estructura probabilística en el espacio latente [LSK⁺25]. Tal como se detalla en el flujo de la Figura 2.1, el *encoder* $q_{\theta}(\mathbf{z}|\mathbf{x})$ transforma la entrada a una distribución de probabilidad y el *decoder* $p_{\phi}(\mathbf{x}|\mathbf{z})$ reconstruye la muestra a partir de dicho espacio.




Figura 2.1.: Arquitectura estándar de un VAE que detalla el *encoder* probabilístico $q_{\theta}(\mathbf{z}|\mathbf{x})$ y el *decoder* $p_{\phi}(\mathbf{x}|\mathbf{z})$.

Fuente: Lai et al. [LSK⁺25].

2.2.1. Encoder y decoder probabilísticos

Sea $\mathcal{X} \subset \mathbb{R}^D$ el espacio de datos, donde cada $\mathbf{x} \in \mathcal{X}$ representa una observación o variable observable de la entrada (por ejemplo, píxeles de una radiografía, intensidad de señal de una resonancia magnética), y sea $\mathcal{Z} \subset \mathbb{R}^d$ el espacio latente, donde cada $\mathbf{z} \in \mathcal{Z}$ es la codificación de $\mathbf{x}$ o variable latente asociada a $\mathbf{x}$ tal que estas recogen características ocultas de la entrada (v.g., forma, color, estilo). El modelo asume que toda observación $\mathbf{x}$ es generada a partir de una variable latente $\mathbf{z}$ muestreada de una distribución a priori simple como, por ejemplo, una gaussiana estándar $\mathbf{z} \sim p_{\text{prior}} := \mathcal{N}(\mathbf{0}, \mathbf{I})$.

Para mapear la variable $\mathbf{z}$ al espacio de datos, definimos la distribución del *decoder* (también llamado *generator*) $p_{\phi}(\mathbf{x}|\mathbf{z})$. Idealmente, los parámetros de decodificación ϕ se aprenderían maximizando su *log-verosimilitud* marginal:

$$\log p_{\phi}(\mathbf{x}) = \log \int p_{\phi}(\mathbf{x}|\mathbf{z}) p(\mathbf{z}) d\mathbf{z}. \quad (2.1)$$

Una vez aprendido el decoder, generar nuevas muestras es directo, ya que primero muestreemos de la a priori $\mathbf{z} \sim p_{\text{prior}}$ y luego la decodificamos con $\mathbf{x} \sim p_{\phi}(\mathbf{x}|\mathbf{z})$. El problema está en el aprendizaje: evaluar la integral de la ecuación (2.1) exigiría recorrer todo el espacio latente, considerando cada valor posible de $\mathbf{z}$, lo que vuelve computacionalmente intratable el cálculo de la *log-verosimilitud*. No podemos, por tanto, maximizar $p_{\phi}(\mathbf{x})$ de forma directa.

Hasta ahora, el decoder solo opera en un sentido: a partir de la variable latente $\mathbf{z}$ generamos el nuevo dato $\mathbf{x}$. Pero disponemos de ejemplos (observaciones $\mathbf{x}$) y queremos que el modelo aprenda a partir de ellos y para eso necesitamos el camino contrario. Dado un $\mathbf{x}$ cualquiera, cabe preguntarse qué códigos latentes $\mathbf{z}$ pudieron haberlo generado. Esto es,

$$p_{\phi}(\mathbf{z}|\mathbf{x}) = \frac{p_{\phi}(\mathbf{x}|\mathbf{z}) p(\mathbf{z})}{p_{\phi}(\mathbf{x})}$$

cuyo denominador coincide con la verosimilitud marginal anterior y es, de nuevo, intratable. He aquí cuando aplicamos, por primera vez, la estrategia variacional que caracteriza los VAEs: sustituimos esta distribución a posteriori intratable por una aproximación tratable. Para ello, definimos la distribución del *encoder* (también llamado *inferer*) $q_{\theta}(\mathbf{z}|\mathbf{x})$, que está parametrizada por otra red neuronal, cuyo objetivo es conseguir una aproximación que sea computacionalmente tratable:

$$q_{\theta}(\mathbf{z}|\mathbf{x}) \approx p_{\phi}(\mathbf{z}|\mathbf{x}).$$

2.2.2. Entrenamiento por Evidence Lower Bound

Dado que no podemos optimizar la *log-verosimilitud* $\log p_\phi(\mathbf{x})$, podemos, en su lugar, maximizar una cota inferior de la misma que denominaremos *Cota inferior de evidencia* o *Evidence Lower Bound (ELBO)*. Para cada $\mathbf{x}$ se tiene que

$$\log p_\phi(\mathbf{x}) \geq \mathcal{L}_{ELBO}(\theta, \phi; \mathbf{x})$$

donde

$$\mathcal{L}_{ELBO} = \underbrace{\mathbb{E}_{\mathbf{z} \sim q_\theta(\mathbf{z}|\mathbf{x})} [\log p_\phi(\mathbf{x}|\mathbf{z})]}_{\text{Término de reconstrucción}} - \underbrace{\mathcal{D}_{KL}(q_\theta(\mathbf{z}|\mathbf{x}) \| p(\mathbf{z}))}_{\text{Término de regularización latente}}$$

con

$$\mathcal{D}_{KL}(q \| p) = \mathbb{E}_{\mathbf{z} \sim q} \left[\log \frac{q(\mathbf{z})}{p(\mathbf{z})} \right],$$

es la *divergencia de Kullback-Leibler (KL)* entre dos distribuciones de probabilidad, que mide cuánto difiere una distribución de aproximación q con respecto a la distribución original p . Desde una perspectiva geométrica, la divergencia KL actúa como un factor de cohesión. Mientras que el término de reconstrucción tiende a fragmentar las representaciones en el espacio latente para evitar solapamientos, la divergencia KL obliga a que dichas representaciones se agrupen de manera suave y continua en torno a la *prior*. Este equilibrio es, en última instancia, lo que dota al modelo de su capacidad generativa, favoreciendo que las regiones del espacio latente contengan información ciertamente coherente.

En particular, nótese que la ELBO se compone de dos términos lógicamente diferenciados:

- **Término de reconstrucción.** Como se desprende del nombre, este incentiva a que la reconstrucción $\hat{\mathbf{x}} \sim p_\phi(\mathbf{x}|\mathbf{z})$ de $\mathbf{x}$ partiendo de su código latente $\mathbf{z}$ sea precisa. No obstante, y de la misma forma que sucede en los AEs, optimizar únicamente este término conduce al modelo a memorizar los datos del entrenamiento, lo que provoca un espacio latente desordenado e imposibilita el muestreo de nuevas instancias.
- **Término de regularización latente.** Para evitar la problemática anterior, este penaliza la divergencia entre la distribución del *encoder* $q_\theta(\mathbf{z}|\mathbf{x})$ y la *prior* $p_{\text{prior}}(\mathbf{z}) = \mathcal{N}(\mathbf{0}, \mathbf{I})$, forzando al espacio latente a mantener la estructura suave y continua de una gaussiana estándar. De este modo, cualquier $\mathbf{z}$ puede decodificarse de forma coherente.

Por tanto, existe un compromiso entre ambos términos: el término de reconstrucción empuja al *encoder* a codificar cada instancia en una región precisa del espacio latente, mientras que el término de regularización latente lo obliga a no alejarse demasiado de una distribución estándar.

Además, puede demostrarse que la diferencia entre la *log-verosimilitud* y el ELBO, que denominaremos *error de inferencia*, es exactamente

$$\log p_\phi(\mathbf{x}) - \mathcal{L}_{ELBO}(\theta, \phi; \mathbf{x}) = \mathcal{D}_{KL}(q_\theta(\mathbf{z}|\mathbf{x}) \| p_\phi(\mathbf{z}|\mathbf{x})).$$

Asimismo, una consecuencia directa de esta estructura continua del espacio latente es la posibilidad de generar muestras interpoladas entre dos observaciones $\mathbf{x}_A$ y $\mathbf{x}_B$. Para ello, basta con codificar ambas en sus respectivos códigos latentes $\mathbf{z}_A$ y $\mathbf{z}_B$, recorrer la trayectoria rectilínea $\mathbf{z}(\alpha) = (1 - \alpha) \mathbf{z}_A + \alpha \mathbf{z}_B$ para $\alpha \in [0, 1]$, y decodificar cada punto intermedio con

$p_\phi(\mathbf{x}|\mathbf{z}(\alpha))$. La regularización gaussiana ayuda a que un $\mathbf{z}(\alpha)$ cualquiera tenga una mayor probabilidad de pertenecer a una región densa del espacio latente, de modo que las muestras generadas son coherentes con el espacio aprendido. Esta propiedad, que era inviable para los *autoencoders* (AE) deterministas por la fragmentación de su espacio latente, es una de las principales ventajas generativas de los VAEs (véase la Figura 2.2 para una visualización de esta continuidad en el espacio latente).




Figura 2.2.: Visualización del espacio latente aprendido por un VAE sobre el conjunto de datos MNIST, mostrando la transición continua entre diferentes dígitos.

Fuente: Kingma y Welling [KW14].

2.2.3. VAE gaussiano

En la práctica, la construcción estándar de un VAE utiliza distribuciones gaussianas tanto para el *encoder* como el *decoder*.

- **Encoder.** El *encoder* $q_\theta(\mathbf{z}|\mathbf{x})$ suele modelarse como una distribución gaussiana estándar tal que:

$$q_\theta(\mathbf{z}|\mathbf{x}) := \mathcal{N}\left(\mathbf{z}; \boldsymbol{\mu}_\theta(\mathbf{x}), \text{diag}\left(\sigma_\theta^2(\mathbf{x})\right)\right),$$

donde $\boldsymbol{\mu}_\theta : \mathbb{R}^D \rightarrow \mathbb{R}^d$ y $\sigma_\theta^2 : \mathbb{R}^D \rightarrow \mathbb{R}_+^d$ son salidas deterministas de la red del *encoder*. En la práctica, asumiremos un $\sigma_\theta > 0$ común tal que $q_\theta(\mathbf{z}|\mathbf{x}) = \mathcal{N}(\mathbf{z}; \boldsymbol{\mu}_\theta(\mathbf{x}), \sigma_\theta^2 I)$.

2. Modelos generativos variacionales: desde los VAEs hasta los LDMs

- **Decoder.** El *decoder* suele ser una distribución gaussiana con varianza fija:

$$p_\phi(\mathbf{x}|\mathbf{z}) := \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_\phi(\mathbf{z}), \sigma^2 \mathbf{I}),$$

donde $\boldsymbol{\mu}_\theta : \mathbb{R}^D \rightarrow \mathbb{R}^d$ es una red neuronal y $\sigma > 0$ es una pequeña constante.

Bajo esta premisa, el término de reconstrucción se simplifica como

$$\mathbb{E}_{q_\theta(\mathbf{z}|\mathbf{x})} [\log p_\phi(\mathbf{x}|\mathbf{z})] = -\frac{1}{2\sigma^2} \mathbb{E}_{q_\theta(\mathbf{z}|\mathbf{x})} [\|\mathbf{x} - \boldsymbol{\mu}_\phi(\mathbf{z})\|^2] + C$$

donde C es una constante independiente de θ y ϕ . De este modo, puesto que el objetivo consiste en maximizar el ELBO para forzar el aumento de la *log-verosimilitud*, cambiando también el signo del término de regularización, entrenar un VAE se reduce a

$$\min_{\theta, \phi} \mathbb{E}_{q_\theta(\mathbf{z}|\mathbf{x})} \left[\frac{1}{2\sigma^2} \|\mathbf{x} - \boldsymbol{\mu}_\phi(\mathbf{z})\|^2 \right] + \mathcal{D}_{KL}(q_\theta(\mathbf{z}|\mathbf{x}) \parallel p_{\text{prior}}(\mathbf{z})).$$

2.2.4. El truco de reparametrización

No obstante, al intentar optimizar el ELBO surge un inconveniente con el término de reconstrucción, pues este involucra una esperanza respecto a $q_\theta(\mathbf{z}|\mathbf{x})$ (distribución que depende de los propios parámetros θ que queremos aprender). En consecuencia, no es posible retropropagar el gradiente directamente a través de una muestra $\mathbf{z} \sim q_\theta(\mathbf{z}|\mathbf{x})$, pues el proceso de muestreo es estocástico e interrumpe el flujo del gradiente [KW14].

El *truco de reparametrización* (o *reparametrization trick*) resuelve este problema introduciendo una variable auxiliar de ruido ε con distribución independiente de los parámetros. Así, la muestra aleatoria puede expresarse como una transformación determinista de dicha variable ε de la siguiente forma. Dado que el *encoder* gaussiano satisface $\mathbf{z} \sim q_\theta(\mathbf{z}|\mathbf{x}) = \mathcal{N}(\boldsymbol{\mu}_\theta(\mathbf{x}), \sigma_\theta^2(\mathbf{x})\mathbf{I})$, podemos escribir

$$\mathbf{z} = g_\theta(\varepsilon, \mathbf{x}) := \boldsymbol{\mu}_\theta(\mathbf{x}) + \sigma_\theta(\mathbf{x}) \odot \varepsilon, \quad \varepsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I}),$$

donde $\odot$ denota el producto elemento a elemento. De este modo, la componente estocástica queda centrada en ε , que no depende de θ ni de ϕ (consiguiendo, de forma natural, que g_θ sea diferenciable respecto a ambos conjuntos de parámetros). Esto permite reformular la esperanza del término de reconstrucción (del ELBO 2.2.2) como

$$\mathbb{E}_{q_\theta(\mathbf{z}|\mathbf{x})} [\log p_\phi(\mathbf{x}|\mathbf{z})] = \mathbb{E}_{\varepsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})} [\log p_\phi(\mathbf{x} | \boldsymbol{\mu}_\theta(\mathbf{x}) + \sigma_\theta(\mathbf{x}) \odot \varepsilon)],$$

y estimar dicha esperanza mediante muestras de la forma $\varepsilon^{(l)} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ [KW14].

Bajo esta reparametrización, el estimador del ELBO para un único punto $\mathbf{x}^{(i)}$ adopta la forma computable genérica siguiente:

$$\mathcal{L}_{ELBO}(\theta, \phi; \mathbf{x}) \simeq \frac{1}{L} \sum_{l=1}^L \log p_\phi(\mathbf{x} | \mathbf{z}^{(l)}) + \frac{1}{2} \sum_{j=1}^d \left(1 + \log((\sigma_{\theta,j})^2) - (\mu_{\theta,j})^2 - (\sigma_{\theta,j})^2 \right),$$

donde $\mathbf{z}^{(l)} = \boldsymbol{\mu}_\theta(\mathbf{x}) + \sigma_\theta(\mathbf{x}) \odot \varepsilon^{(l)}$ con $\varepsilon^{(l)} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$. El primer sumando corresponde al logaritmo de la verosimilitud de reconstrucción, que toma la forma de un MLP Bernoulli o

gaussiano según el tipo de datos¹; y el segundo es la solución analítica del término de regularización KL para dos gaussianas (véase [KW14]). De esta forma, gracias a que ambos son diferenciables respecto a θ y ϕ , el entrenamiento puede llevarse a cabo mediante descenso por gradiente estocástico.

Profundizando en el caso del VAE gaussiano, si asumimos explícitamente que el *decoder* es una distribución normal con varianza fija $p_\phi(\mathbf{x}|\mathbf{z}) = \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_\phi(\mathbf{z}), \sigma^2 \mathbf{I})$, el término de reconstrucción se simplifica notablemente. Bajo esta asunción, la estimación del ELBO adopta la siguiente forma analítica [LSK⁺25]:

$$\mathcal{L}_{ELBO}(\theta, \phi; \mathbf{x}) \simeq -\frac{1}{L} \sum_{l=1}^L \frac{1}{2\sigma^2} \|\mathbf{x} - \boldsymbol{\mu}_\phi(\mathbf{z}^{(l)})\|^2 + \frac{1}{2} \sum_{j=1}^d \left(1 + \log((\sigma_{\theta,j})^2) - (\mu_{\theta,j})^2 - (\sigma_{\theta,j})^2 \right) + C,$$

donde C es una constante independiente de los parámetros θ y ϕ . En esta expresión final, el logaritmo de la verosimilitud se reduce a un error cuadrático medio escalado por la varianza σ^2 , lo que equivale a minimizar una función de pérdida regularizada.

2.2.5. VAE jerárquico

Para motivar la siguiente sección, cabe destacar los HVAEs como una etapa intermedia natural entre los VAEs y los DDPMs. Un HVAE surge a partir de introducir una jerarquía de variables latentes en la estructura original de un VAE. Esto se ilustra en el flujo de la Figura 2.3, donde se observa cómo el modelo encadena una secuencia de variables latentes $\mathbf{z}_1, \dots, \mathbf{z}_L$, permitiendo que el sistema capture características de los datos a distintos niveles de abstracción jerárquica.




Figura 2.3.: Modelo gráfico de un HVAE que muestra la secuencia de variables latentes.

Fuente: Lai et al. [LSK⁺25].

Para entender qué aporta formalmente esta jerarquía, un HVAE introduce múltiples niveles latentes donde la distribución conjunta se define como:

$$p_\phi(\mathbf{x}, \mathbf{z}_{1:L}) = p_\phi(\mathbf{x}|\mathbf{z}_1) \prod_{i=2}^L p_\phi(\mathbf{z}_{i-1}|\mathbf{z}_i) p(\mathbf{z}_L),$$

¹En la práctica, la distribución de Bernoulli se emplea para datos binarios o normalizados estrictamente en el rango $[0, 1]$, mientras que la distribución gaussiana, para modelar variables continuas y representaciones latentes.

2. Modelos generativos variacionales: desde los VAEs hasta los LDMs

cuyo ELBO es

$$\begin{aligned}\mathcal{L}_{\text{ELBO}}(\mathbf{x}) = & \mathbb{E}_q[\log p_\phi(\mathbf{x}|\mathbf{z}_1)] - \mathbb{E}_q[\mathcal{D}_{\text{KL}}(q_\theta(\mathbf{z}_1|\mathbf{x}) \parallel p_\phi(\mathbf{z}_1|\mathbf{z}_2))] \\ & - \sum_{i=2}^{L-1} \mathbb{E}_q[\mathcal{D}_{\text{KL}}(q_\theta(\mathbf{z}_i|\mathbf{z}_{i-1}) \parallel p_\phi(\mathbf{z}_i|\mathbf{z}_{i+1}))] \\ & - \mathbb{E}_q[\mathcal{D}_{\text{KL}}(q_\theta(\mathbf{z}_L|\mathbf{z}_{L-1}) \parallel p(\mathbf{z}_L))],\end{aligned}$$

donde denotamos $\mathbb{E}_q := \mathbb{E}_{p_{\text{data}}(\mathbf{x})q_\theta(\mathbf{z}_{1:L}|\mathbf{x})}$. Para interpretar este ELBO de forma más intuitiva, podemos plantearlo como un mecanismo que, en lugar de evaluar todo de una vez, el modelo empareja cada nivel de codificación con su equivalente en la decodificación (por ejemplo, $q_\theta(\mathbf{z}_1|\mathbf{x})$ con $p_\phi(\mathbf{z}_1|\mathbf{z}_2)$). Esto permite fragmentar el término KL, distribuyendo la penalización de la información en múltiples divergencias locales. Al hacerlo, la red recibe señales de aprendizaje mucho más directas y estables para cada nivel de detalle.

Precisamente, esta idea de descomponer una transformación compleja en una secuencia de pequeños pasos emparejados es el camino natural hacia los DDPMs. Como veremos en la próxima sección, los DDPMs refinan esta jerarquía congelando el proceso de inferencia para que simplemente inyecte ruido paso a paso, permitiendo así que el modelo se enfoque exclusivamente en aprender a revertir ese ruido nivel a nivel.

Al aumentar la jerarquía de un VAE no se busca necesariamente incrementar el número de capas, sino el número de distribuciones y variables latentes intermedias. Esto mejora significativamente la expresividad del modelo, ya que las capas intermedias del *encoder* y *decoder* dejan de ser deterministas. Así, este enfoque se libera de la restricción de una única familia gaussiana unimodal, combinando distintas distribuciones. De esta forma, se promueve que las primeras variables latentes recojan las características más gruesas y las siguientes, las más finas.

No obstante, esta expresividad introduce una mayor complejidad matemática que complica notablemente la optimización, haciéndola propensa al fenómeno del *posterior collapse* (colapso de la *a posteriori*). Este problema surge cuando el *decoder* se vuelve tan potente que aprende a modelar los datos de forma autónoma, ignorando por completo las variables latentes. Como consecuencia, el *encoder* deja de codificar información útil y colapsa devolviendo siempre la *prior* para cualquier entrada, lo que provoca que la divergencia KL caiga a cero y el espacio latente se vuelva irrelevante.

Por otra parte, esta construcción obliga a que cada *encoder* y el *decoder* se optimicen simultáneamente, lo que suele resultar en que las capas bajas ya sean capaces de reconstruir $\mathbf{x}$ y las altas no aporten valor. Esta problemática, en efecto, es la que nos sugiere bloquear el proceso de codificación para centrarnos exclusivamente en el proceso de decodificación, esto es, en el proceso generativo, dando lugar a un modelo más estable y flexible.

2.3. Denoising Diffusion Probabilistic Models

Siguiendo el enfoque variacional, los modelos de difusión probabilísticos (o modelos de difusión, en aras de la brevedad), toman la intuición de los HVAEs acerca de estructurar el espacio latente mediante una cadena de variables, pero construyendo el proceso de inferencia como una secuencia de pasos indexados en el tiempo. A diferencia de los HVAEs, que definían una jerarquía de variables latentes *independientes*, los modelos de difusión las

asocian a marcas temporales concretas $t \in \{1, \dots, T\}$, de forma que cada variable $\mathbf{x}_t$ es *dependiente* de su sucesora $\mathbf{x}_{t+1}$, constituyendo así una cadena de Markov inversa. En otras palabras, dado que la principal diferencia entre HVAEs y DDPMs es que ahora no entrenaremos el *encoder* (es decir, este será fijo), cada variable dependerá de la que representa inmediatamente un mayor nivel ruido. Esta dependencia secuencial, ilustrada mediante los procesos de difusión hacia adelante y hacia atrás en la Figura 2.4, es precisamente la que articula los procesos estocásticos que caracterizan al modelo [LSK⁺25, HJA20].




Figura 2.4.: Cadena de Markov que ilustra los procesos de difusión hacia adelante y hacia atrás en un DDPM.

Fuente: Lai et al. [LSK⁺25].

2.3.1. Proceso forward: difusión del ruido

El proceso *forward* consiste en corromper progresivamente los datos a base de inyectar ruido gaussiano a lo largo de múltiples etapas. Así, los datos se van convirtiendo en ruido puro mediante un kernel de transición $p(\mathbf{x}_i|\mathbf{x}_{i-1})$, siguiendo una distribución gaussiana. Como hemos comentado anteriormente, una característica fundamental de los modelos de difusión es que el *encoder* que gestiona este proceso es fijo, y por tanto, no aprendido. De hecho, esta decisión que permite centrarse en el proceso generativo es la que dota a los DDPMs de la estabilidad y el poder expresión con el que son conocidos.

Dicho kernel de transición, que se aplica en cada paso, se define como

$$p(\mathbf{x}_i|\mathbf{x}_{i-1}) := \mathcal{N}\left(\mathbf{x}_i; \sqrt{1 - \beta_i^2} \mathbf{x}_{i-1}, \beta_i^2 \mathbf{I}\right)$$

donde $\mathbf{x}_0$ representa una muestra de la distribución real de datos p_{data} . La secuencia $\{\beta_i\}_{i=1}^L$ es una planificación de ruido predeterminada y monótonamente creciente tal que $\beta_i \in (0, 1)$ controla la varianza del ruido gaussiano inyectado en el paso i -ésimo. Además, en pro de la legibilidad definimos $\alpha_i := \sqrt{1 - \beta_i^2}$, que es claramente decreciente y actúa como factor de atenuación de la señal en cada paso de la cadena.

Aprovechando la parametrización que hemos obtenido del kernel de transición, y considerando $\varepsilon_i \in \mathcal{N}(\mathbf{0}, \mathbf{I})$ independientes e idénticamente distribuidos, la expresión anterior se puede reescribir de una forma intuitiva como una fórmula recursiva:

$$\mathbf{x}_i = \alpha_i \mathbf{x}_{i-1} + \beta_i \varepsilon_i$$

Es decir, cada paso i -ésimo resulta en una atenuación del estado previo $\mathbf{x}_{i-1}$ por α_i y en una adición controlada de ruido gaussiano escalada por β_i .

2. Modelos generativos variacionales: desde los VAEs hasta los LDMs

Aplicando recursivamente los kernels de transición, obtenemos una expresión analítica para la distribución de muestras de ruido en el paso i -ésimo dada una muestra original $\mathbf{x}_0$:

$$p(\mathbf{x}_i|\mathbf{x}_0) = \mathcal{N}(\mathbf{x}_i; \bar{\alpha}_i\mathbf{x}_0, (1 - \bar{\alpha}_i^2)\mathbf{I}),$$

donde

$$\bar{\alpha}_i := \prod_{k=1}^i \sqrt{1 - \beta_k^2} = \prod_{k=1}^i \alpha_k.$$

Esto tiene la ventaja de podemos muestrear $\mathbf{x}_i$ directamente desde $\mathbf{x}_0$ como

$$\mathbf{x}_i = \bar{\alpha}_i\mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_i^2}\varepsilon, \varepsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$$

de donde se sigue inmediatamente la convergencia $p_L(\mathbf{x}_L|\mathbf{x}_0) \implies \mathcal{N}(\mathbf{0}, \mathbf{I})$ si $L \rightarrow \infty$, que a su vez, reafirma la elección de la distribución *prior* como

$$p_{\text{prior}} := \mathcal{N}(\mathbf{0}, \mathbf{I})$$

independientemente del valor original de $\mathbf{x}_0$.

2.3.2. Proceso reverse: denoising aprendido

El proceso *reverse* trata de cómo, empezando desde ruido puro, se sigue un proceso iterativo de limpieza en el que se busca reducir paso a paso el ruido del dato corrupto, en vez de inferir una reconstrucción del dato original directamente. En este caso, es una red neuronal la que aprende una distribución parametrizada $p_\phi(\mathbf{x}_{i-1}|\mathbf{x}_i)$ para realizar el *denoising* progresivo.

La Figura 2.5 ilustra este proceso de degradación y reconstrucción en el dominio de la patología digital, permitiendo observar cómo la relación señal-ruido (SNR) se ve afectada por la integridad de los datos. Es decir, a mayor avance del proceso de *noising*, mayor es la pérdida de información estructural y, en consecuencia, menor es la relación señal-ruido (SNR).




Figura 2.5.: Proceso de difusión en imágenes de patología digital a diferentes niveles de SNR.

Fuente: Linmans et al. [LRvdLL24].

De forma similar a como procedíamos en los VAEs, queremos aproximar un kernel de transición inverso $p(\mathbf{x}_{i-1}|\mathbf{x}_i)$ que desconocemos, mediante un modelo de aprendizaje paramétrico $p_\phi(\mathbf{x}_{i-1}|\mathbf{x}_i)$. Para ello, necesitamos minimizar la divergencia KL esperada en cada uno de los instantes de tiempo i :

$$\mathbb{E}_{p_i(\mathbf{x}_i)} [\mathcal{D}_{KL}(p(\mathbf{x}_{i-1}|\mathbf{x}_i) \parallel p_\phi(\mathbf{x}_{i-1}|\mathbf{x}_i))]$$

No obstante, para calcular $p_\phi(\mathbf{x}_{i-1}|\mathbf{x}_i)$ nos encontramos de nuevo con que las probabilidades marginales $p_i(\mathbf{x}_i)$ y $p_{i-1}(\mathbf{x}_{i-1})$ son intratables ya que, para cada i

$$p_i(\mathbf{x}_i) = \int p_i(\mathbf{x}_i|\mathbf{x}_0)p_{\text{data}}(\mathbf{x}_0)d\mathbf{x}_0$$

con p_{data} desconocida.

Con objeto de obtener una expresión computacionalmente tratable, condicionamos la transición inversa con una muestra $\mathbf{x}_0$ tal que

$$p(\mathbf{x}_{i-1}|\mathbf{x}_i, \mathbf{x}) = p(\mathbf{x}_i|\mathbf{x}_{i-1}) \frac{p(\mathbf{x}_{i-1}|\mathbf{x})}{p(\mathbf{x}_i|\mathbf{x})}.$$

Nótese que por su propiedad de Markov se verifica que $p(\mathbf{x}_{i-1}|\mathbf{x}_i, \mathbf{x}_0) = p(\mathbf{x}_i|\mathbf{x}_{i-1})$. Además, se trata de una distribución gaussiana que admite la expresión analítica

$$p(\mathbf{x}_{i-1}|\mathbf{x}_i, \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_{i-1}; \boldsymbol{\mu}(\mathbf{x}_i, \mathbf{x}_0, i), \sigma^2(i)\mathbf{I}),$$

donde

$$\boldsymbol{\mu}(\mathbf{x}_i, \mathbf{x}_0, i) := \frac{\bar{\alpha}_{i-1}\beta_i^2}{1-\bar{\alpha}_i^2}\mathbf{x}_0 + \frac{(1-\bar{\alpha}_{i-1}^2)\alpha_i}{1-\bar{\alpha}_i^2}\mathbf{x}_i, \quad \sigma^2(i) := \frac{1-\bar{\alpha}_{i-1}^2}{1-\bar{\alpha}_i^2}\beta_i^2.$$

Ahora, podemos plantearnos reformular la divergencia KL esperada en función de esta expresión,

$$\begin{aligned} & \mathbb{E}_{p_i(\mathbf{x}_i)} [\mathcal{D}_{KL}(p(\mathbf{x}_{i-1}|\mathbf{x}_i) \parallel p_\phi(\mathbf{x}_{i-1}|\mathbf{x}_i))] \\ &= \mathbb{E}_{p_{\text{data}}(\mathbf{x})} \mathbb{E}_{p(\mathbf{x}_i|\mathbf{x})} [\mathcal{D}_{KL}(p(\mathbf{x}_{i-1}|\mathbf{x}_i, \mathbf{x}) \parallel p_\phi(\mathbf{x}_{i-1}|\mathbf{x}_i))] + C, \end{aligned}$$

donde C es una constante independiente de ϕ y el minimizador de la ecuación se aproxima a la verdadera distribución inversa marginal, es decir,

$$p^*(\mathbf{x}_{i-1}|\mathbf{x}_i) = p(\mathbf{x}_{i-1}|\mathbf{x}_i), \text{ con } \mathbf{x}_i \sim p_i.$$

Esto implica que minimizar la divergencia KL entre distribuciones marginales es idéntico a minimizarla entre distribuciones condicionales que involucren a los datos observados. Esta es la parte fundamental, ya que nos permite utilizar directamente los datos de entrenamiento, lo que hace posible entrenar los DDPMs tal como los conocemos.

2.3.3. Parametrización y función de pérdida

Aprovechando que la distribución condicional $p(\mathbf{x}_{i-1}|\mathbf{x}_i, \mathbf{x}_0)$ es gaussiana y basándonos en que el proceso *reverse* de una difusión gaussiana es también gaussiano (cuando los pasos de ruido son suficientemente pequeños), asumimos que cada transición marginal $p_\phi(\mathbf{x}_{i-1}|\mathbf{x}_i)$

2. Modelos generativos variacionales: desde los VAEs hasta los LDMs

puede aproximarse mediante una distribución gaussiana parametrizada:

$$p_\phi(\mathbf{x}_{i-1}|\mathbf{x}_i) = \mathcal{N}(\mathbf{x}_{i-1}; \boldsymbol{\mu}_\phi(\mathbf{x}_i, i), \sigma^2(i)\mathbf{I}),$$

donde $\boldsymbol{\mu}_\phi(\cdot, i) : \mathbb{R}^D \rightarrow \mathbb{R}^D$ es una función de media aprendible implementada mediante una red neuronal, y $\sigma^2(i) > 0$ es la varianza fija definida de acuerdo con la ecuación (??) de la subsección anterior.

Ahora partimos de la divergencia KL promediada sobre los pasos temporales y condicionada en $\mathbf{x}_0$, de modo que la naturaleza gaussiana de ambas distribuciones permiten expresarla de forma cerrada como suma de errores cuadráticos entre medias. Omitiendo la constante C y promediando sobre la distribución de datos p_{data} , se obtiene el objetivo teórico de entrenamiento final del DDPM.

$$\begin{aligned} \mathcal{L}_{\text{diffusion}}(\mathbf{x}_0; \phi) &:= \sum_{i=1}^L \mathbb{E}_{p(\mathbf{x}_i|\mathbf{x}_0)} [\mathcal{D}_{KL}(p(\mathbf{x}_{i-1}|\mathbf{x}_i, \mathbf{x}_0) \| p_\phi(\mathbf{x}_{i-1}|\mathbf{x}_i))] \\ &= \sum_{i=1}^L \frac{1}{2\sigma^2(i)} \left\| \boldsymbol{\mu}_\phi(\mathbf{x}_i, i) - \boldsymbol{\mu}(\mathbf{x}_i, \mathbf{x}_0, i) \right\|_2^2 + C \\ \mathcal{L}_{\text{DDPM}}(\phi) &:= \sum_{i=1}^L \frac{1}{2\sigma^2(i)} \mathbb{E}_{\mathbf{x}_0} \mathbb{E}_{p(\mathbf{x}_i|\mathbf{x}_0)} \left[\left\| \boldsymbol{\mu}_\phi(\mathbf{x}_i, i) - \boldsymbol{\mu}(\mathbf{x}_i, \mathbf{x}_0, i) \right\|_2^2 \right] \end{aligned}$$

No obstante, en la práctica solemos aplicar una reparametrización llamada formulación *ε -prediction* o *noise prediction*. Esto supone tomar un $\mathbf{x}_0 \sim p_{\text{data}}$ y $\varepsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ tal que la muestra ruidosa $\mathbf{x}_i \sim p(\mathbf{x}_i|\mathbf{x}_0)$ es

$$\mathbf{x}_i = \bar{\alpha}_i \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_i^2} \varepsilon$$

de tal forma que la media inversa puede reescribirse como

$$\boldsymbol{\mu}(\mathbf{x}_i, \mathbf{x}_0, i) = \frac{1}{\alpha_i} \left(\mathbf{x}_i - \frac{1 - \alpha_i^2}{\sqrt{1 - \bar{\alpha}_i^2}} \varepsilon \right)$$

motivando una parametrización de un modelo $\boldsymbol{\mu}_\phi$ usando una red neuronal $\varepsilon_\phi(\mathbf{x}_i, i)$ que predice directamente el ruido tal que

$$\boldsymbol{\mu}_\phi(\mathbf{x}_i, i) = \frac{1}{\alpha_i} \left(\mathbf{x}_i - \frac{1 - \alpha_i^2}{\sqrt{1 - \bar{\alpha}_i^2}} \underbrace{\varepsilon_\phi(\mathbf{x}_i, i)}_{\varepsilon\text{-prediction}} \right)$$

Sustituyendo esta expresión en la función de pérdida, se reduce al cálculo de un error cuadrático entre el ruido real y el predicho tal que

$$\left\| \boldsymbol{\mu}_\phi(\mathbf{x}_i, i) - \boldsymbol{\mu}(\mathbf{x}_i, \mathbf{x}_0, i) \right\|_2^2 \propto \left\| \varepsilon_\phi(\mathbf{x}_i, i) - \varepsilon \right\|_2^2$$

de modo que, omitiendo el término de peso, llegamos a la función de pérdida que se usa en la práctica:

$$\mathcal{L}_{\text{simple}}(\phi) := \mathbb{E}_i \mathbb{E}_{\mathbf{x} \sim p_{\text{data}}(\mathbf{x})} \mathbb{E}_{\varepsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})} \left[\left\| \varepsilon_\phi(\mathbf{x}_i, i) - \varepsilon \right\|_2^2 \right]$$

que se puede demostrar que posee la misma solución óptima ε^* mediante un argumento de minimización de cuadrados.

2.3.4. ELBO de DDPM

Dado que la verosimilitud marginal $p_\phi(\mathbf{x}_0)$ es intratable, el entrenamiento del DDPM se fundamenta, al igual que el del VAE, en la maximización de una cota inferior de la log-verosimilitud. Concretamente, puede demostrarse que

$$\begin{aligned} -\log p_\phi(\mathbf{x}_0) &\leq \underbrace{\mathcal{D}_{KL}(p(\mathbf{x}_L|\mathbf{x}_0) \parallel p_{\text{prior}}(\mathbf{x}_L))}_{\mathcal{L}_{\text{prior}}} \\ &\quad + \underbrace{\mathbb{E}_{p(\mathbf{x}_1|\mathbf{x}_0)}[-\log p_\phi(\mathbf{x}_0|\mathbf{x}_1)]}_{\mathcal{L}_{\text{recon.}}} \\ &\quad + \underbrace{\sum_{i=1}^L \mathbb{E}_{p(\mathbf{x}_i|\mathbf{x}_0)}[\mathcal{D}_{KL}(p(\mathbf{x}_{i-1}|\mathbf{x}_i, \mathbf{x}_0) \parallel p_\phi(\mathbf{x}_{i-1}|\mathbf{x}_i))]}_{\mathcal{L}_{\text{diffusion}}} \end{aligned}$$

donde $\mathcal{L}_{\text{diffusion}}$ coincide exactamente con la función de pérdida teórica enunciada anteriormente, justificando así su uso como objetivo de entrenamiento. Los términos $\mathcal{L}_{\text{prior}}$ y $\mathcal{L}_{\text{recon.}}$ suelen ser omitidos: el primero se anula eligiendo una planificación de ruido $\{\beta_i\}$ de forma que $p(\mathbf{x}_L|\mathbf{x}_0) \approx p_{\text{prior}}(\mathbf{x}_L)$, pero el segundo puede optimizarse con una estimación Monte Carlo estándar. Sin embargo, en la práctica se suele despreciar el primero y omitir el segundo, debido a que $\mathcal{L}_{\text{diffusion}}$ tiene más peso relativo.

En definitiva, el DDPM encaja en el mismo marco variacional que el VAE: la cadena de difusión *forward* actúa como un *encoder* fijo, las variables $\mathbf{x}_{1:L}$ son las variables latentes, y el entrenamiento maximiza el mismo ELBO.

2.4. Latent Diffusion Models

A pesar de la notable capacidad generativa de los DDPMs, su procesamiento directo sobre el espacio de píxeles conlleva un coste computacional muy alto. Como señalan la literatura [RBL⁺22], los modelos probabilísticos basados en verosimilitud, categoría a la que pertenecen los DDPMs, tienden a dedicar una fracción excesiva de su capacidad a modelar detalles imperceptibles de alta frecuencia, lo que encarece tanto el entrenamiento como la inferencia. Esto los hace inaccesibles para buena parte de la comunidad investigadora, que no dispone siempre de los recursos de infraestructura necesarios.

La solución que proponen los *Latent Diffusion Models* (LDMs) consiste en desplazar el proceso de difusión desde el espacio de píxeles hacia un espacio latente de menor dimensionalidad. Esto permite entrenar el modelo siguiendo el mismo procedimiento teórico, pero con un coste computacional significativamente menor. Para ello, el entrenamiento se descompone en dos fases claramente diferenciadas [RBL⁺22] que veremos a continuación.

2.4.1. Compresión perceptual: autocodificador latente

En la primera fase se entrena un autocodificador (frecuentemente un VAE) cuyo objetivo es aprender una representación comprimida del espacio de datos que preserve su estructura

2. Modelos generativos variacionales: desde los VAEs hasta los LDMs

semántica.

En el caso de los LDMs originales [RBL⁺22], el autocodificador se entrena específicamente para la tarea generativa. Dado una imagen $\mathbf{x} \in \mathbb{R}^{H \times W \times 3}$, el *encoder* $\mathcal{E}$ la proyecta a un espacio latente de menor resolución espacial:

$$\mathbf{z} = \mathcal{E}(\mathbf{x}), \quad \mathbf{z} \in \mathbb{R}^{h \times w \times c},$$

donde el factor de compresión espacial es $f = H/h = W/w$. A continuación, el *decoder* $\mathcal{D}$ recupera una reconstrucción de la imagen original a partir del código latente:

$$\tilde{\mathbf{x}} = \mathcal{D}(\mathbf{z}) = \mathcal{D}(\mathcal{E}(\mathbf{x})).$$

El espacio latente resultante no es un espacio de ruido arbitrario, sino que concentra la información semántica de la imagen. Cabe destacar que esta fase de compresión se lleva a cabo *una sola vez* y puede reutilizarse para múltiples entrenamientos del modelo de difusión subsiguiente [RBL⁺22].

2.4.2. Difusión en el espacio latente

En la segunda fase, un DDPM estándar se entrena directamente sobre las representaciones latentes $\mathbf{z}$ obtenidas por $\mathcal{E}$, en lugar de hacerlo sobre los píxeles de la imagen. Siguiendo la notación de la sección anterior, el proceso *forward* añade ruido gaussiano progresivamente sobre $\mathbf{z}_0 = \mathcal{E}(\mathbf{x})$:

$$\mathbf{z}_t = \bar{\alpha}_t \mathbf{z}_0 + \sqrt{1 - \bar{\alpha}_t^2} \boldsymbol{\varepsilon}, \quad \boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}),$$

y una red neuronal ε_ϕ aprende a predecir el ruido añadido minimizando la función de pérdida

$$\mathcal{L}_{\text{LDM}}(\phi) := \mathbb{E}_{\mathcal{E}(\mathbf{x}), \boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}), t} \left[\|\boldsymbol{\varepsilon} - \varepsilon_\phi(\mathbf{z}_t, t)\|_2^2 \right],$$

que es análoga a $\mathcal{L}_{\text{simple}}$ del DDPM original, pero evaluada en el espacio latente en lugar del espacio de píxeles [RBL⁺22, PDBE25]. Una vez completado el proceso *reverse* de denoising, la muestra latente $\hat{\mathbf{z}}_0$ se decodifica al espacio de la imagen mediante $\hat{\mathbf{x}} = \mathcal{D}(\hat{\mathbf{z}}_0)$.

2.4.3. Una alternativa potente: los Foundation Models

Aunque el flujo clásico de los LDMs implica reconstruir la imagen original, en ciertas aplicaciones prácticas no necesitamos volver al espacio de píxeles de entrada, ya que el objetivo es utilizar el modelo generativo para una aplicación concreta sobre el propio espacio latente. En estos casos, no es estrictamente necesario entrenar un *autoencoder* desde cero para la tarea generativa.

Una alternativa particularmente potente consiste en utilizar simplemente extractores de rasgos, recurriendo a los denominados *foundation models*. Estos son modelos de gran escala preentrenados sobre conjuntos de datos masivos y heterogéneos, que han desarrollado representaciones latentes ricas y transferibles a múltiples dominios [PDBE25]. En este contexto, el *encoder* de un *foundation model* $\mathcal{F}$ actúa directamente como extractor de características, proporcionando una representación latente $\mathbf{z} = \mathcal{F}(\mathbf{x})$ sin necesidad de reentrenamiento, y el modelo generativo se entrena sobre estas características extraídas.

Esta estrategia resulta especialmente conveniente en el ámbito médico, donde los datos etiquetados son escasos, ya que permite aprovechar el conocimiento general aprendido por

modelos entrenados tanto sobre imágenes naturales como sobre imágenes médicas.

En definitiva, los LDMs heredan el marco variacional de los DDPMs y lo combinan con la compresión aprendida de los VAEs o los *foundation models*: el codificador actúa como puente entre el espacio de píxeles y el espacio latente, mientras que el modelo de difusión opera en dicho espacio con un coste sensiblemente inferior. Esta arquitectura modular es precisamente la que adoptaremos como base de nuestro sistema de detección de anomalías en imágenes médicas.

3. Detección de datos fuera de la distribución

Los modelos de aprendizaje automático se entrenan habitualmente bajo una hipótesis de *mundo cerrado*, es decir, se asume que los datos de *test* siguen la misma distribución que los de entrenamiento que, en adelante, denominaremos distribución de referencia o *in-distribution* (ID) [YZLL24]. Sin embargo, cuando estos modelos deben operar en entornos reales, se enfrentan a muchas muestras que no pertenecen necesariamente a dicha distribución, las cuales son llamadas muestras fuera de la distribución o *out-of-distribution* (OOD). En general, los modelos pueden no ser capaces de generalizar con garantías en estas muestras OOD, por lo que su identificación es esencial para evitar decisiones erróneas. En el caso que nos ocupa, estos errores pueden tener consecuencias graves, derivando en fallos importantes de diagnóstico en el ámbito médico.

En la literatura [AY01, RKV⁺21, PSCvdH20, PCCT14, BCD⁺19] se ha desarrollado la detección OOD desde múltiples ramas, atendiendo a ligeras diferencias de propósito y uso. Sin embargo, los problemas que abordan están estrechamente relacionados como, por ejemplo, la detección de anomalías (*anomaly detection*, AD), la detección de novedades (*novelty detection*, ND), el reconocimiento de conjuntos abiertos (*open set recognition*, OSR) y la detección de valores atípicos (*outlier detection*, OD), que son similares en el sentido de que de que todos definen una *in-distribution* con el objetivo de detectar muestras *out-of-distribution* [YZLL24].

El presente trabajo se enfocará en la detección de anomalías (AD), orientando el estudio hacia la identificación de patologías en el ámbito médico. En particular, comenzaremos estableciendo una taxonomía precisa de los distintos subproblemas; a continuación, revisaremos los principales métodos basados en distancia; y finalmente, nos centraremos en los métodos basados en reconstrucción generativa, que constituyen el enfoque adoptado en este trabajo.

3.1. Definición y taxonomía de la detección OOD generalizada

En este trabajo nos acogeremos al enfoque definido por [YZLL24] acerca de la *detección generalizada de OOD*. En concreto, para comprender la diferencia entre cada tipo de detección OOD, conviene valorar qué tipo de cambio en la distribución ataca cada problema. Un cambio en la distribución o *distribution shift* es un cambio en la distribución conjunta $P(X, Y)$ sobre el espacio de entrada $\mathcal{X} \times \mathcal{Y}$, donde $\mathcal{X}$ corresponde al espacio de observaciones e $\mathcal{Y}$, al espacio de etiquetas (también entendiendo como el espacio de categorías semánticas). Así pues, este cambio puede deberse bien a la distribución marginal $P(X)$ o bien a la distribución conjunta $P(X)$ y $P(Y)$ (cabiendo notar que un cambio en $P(Y)$ produce inmediatamente un cambio en $P(X)$). En función de qué componente quede afectada, distinguimos dos tipos:

- **Cambio covariable (*covariate shift*)**. Se produce cuando varía la distribución marginal $P(X)$ sin que el espacio de etiquetas Y se vea alterado. Son ejemplos típicos el cambio de dominio (v.g., un modelo entrenado con radiografías de un hospital que se despliega con imágenes de otro centro con diferente equipamiento) o el cambio de estilo (v.g., variaciones en el contraste, la resolución o el protocolo de adquisición).

- **Cambio semántico (*semantic shift*)**. Implica una alteración en $P(Y)$, es decir, la aparición de nuevas categorías o la modificación de las existentes, lo que induce a su vez un cambio en $P(X)$. Este es el tipo de cambio que nos interesa detectar: el espacio de etiquetas en test difiere del de entrenamiento y, dado que el modelo no ha sido expuesto a esas categorías, debería abstenerse de emitir cualquier predicción dentro de ID y señalar la muestra como OOD.

A partir de esta distinción, pueden caracterizarse los tres subproblemas que engloba la detección OOD generalizada [YZLL24]:

- **Detección de anomalías (AD)**. Detecta cualquier muestra que se desvíe de una normalidad predefinida. Existen dos tipos: por cambio covariable (*sensory AD*), donde las anomalías provienen de $P'(X) \neq P(X)$ con $P'(Y) = P(Y)$; y por cambio semántico (*semantic AD*), donde provienen de $P'(Y) \neq P(Y)$. En ningún caso se requiere clasificar las muestras ID entre sí.
- **Reconocimiento de conjuntos abiertos (OSR)**. Exige que el modelo clasifique correctamente las muestras con $Y \in \mathcal{Y}$ y rechace simultáneamente las muestras con $Y \notin \mathcal{Y}$. A diferencia de la AD y la ND, la clasificación ID es un requisito explícito.
- **Detección de valores atípicos (OD)**. A diferencia de los anteriores, no sigue el esquema entrenamiento-test: opera directamente sobre el conjunto completo de observaciones $\{x_1, \dots, x_n\}$ (que se supone contaminado con muestras OOD), identificando las muestras que difieren significativamente del resto.

Como se resume en la Figura 3.1, esta taxonomía permite clasificar las diversas variantes de detección OOD según la naturaleza del cambio de distribución y la tarea requerida. El esquema visualiza la diferencia entre las muestras ID utilizadas durante el entrenamiento y los diversos tipos de muestras OOD que el modelo debe discriminar en fase de evaluación.

En este trabajo nos centramos en la **detección de anomalías semántica**: el modelo se entrenará exclusivamente con muestras sanas $x \sim P(X \mid Y = \text{sano})$ y deberá detectar aquellas que presentan patología, es decir, con $Y \notin \mathcal{Y}_{\text{train}}$.

3.1.1. Particularidades del dominio médico

La sección anterior ha presentado los métodos de detección OOD desde un punto de vista general. No obstante, su aplicación al ámbito de la imagen médica introduce particularidades que merecen una discusión específica [HYC⁺24].

La taxonomía presentada por [YZLL24] expuesta en 3.1 distingue entre cambio covariante y cambio semántico. No obstante, en [HYC⁺24] argumentan que esta dicotomía resulta insuficiente para el dominio clínico e introducen un tercer tipo: el **cambio contextual**, que se produce cuando la imagen de entrada presenta una modalidad (radiografía, TC, RM, histología...) o un área de interés (cerebro, tórax, piel...) inconsistente con las del conjunto de entrenamiento. Por ejemplo, introducir un corte de TC torácico en un clasificador entrenado con radiografías, un instancia de pulmón lesionado por tuberculosis en un segmentador de tumores de TC cerebral, etc. Además, la existencia de este tipo de cambio viene motivado porque, a diferencia del cambio covariante donde la imagen mantiene el contexto pero difiere en factores de calidad, protocolo de adquisición o cohorte del paciente; el cambio

3. Detección de datos fuera de la distribución




Figura 3.1.: Esquema unificado de la Detección Generalizada Fuera de Distribución (Generalized OOD Detection): (a) Detección de anomalías sensoriales; (b) Detección de novedades de una sola clase (One-Class); (c) Detección de novedades multi-clase; (d) Reconocimiento de conjunto abierto (Open Set) y Detección OOD; y (e) Detección de valores atípicos (Outlier Detection). Se muestran ejemplos visuales de los datos de entrenamiento (Train) y de prueba (Test) para distinguir entre muestras dentro de la distribución (ID) y fuera de ella (OOD).

Fuente: Yang et al. [YZLL24].

contextual conduce a predicciones sin sentido, pues tienden a surgir por error humano o ataques maliciosos y por ello, deben identificarse para ser rechazados.

Además de esta distinción taxonómica, el dominio médico plantea dificultades prácticas adicionales: los conjuntos de datos suelen ser pequeños y desbalanceados, las etiquetas costosas de obtener, y la variabilidad *sui generis* de cada centro introduce un cambio covariante permanente que dificulta definir qué constituye realmente la distribución ID. Además, la detección de cambio semántico se considera el tipo más difícil y el coste clínico de un falso negativo exige umbrales de detección más conservadores que en otros dominios.

3.2. Métodos clásicos para la detección OOD

Antes de abordar los métodos generativos que constituyen el interés de este trabajo, conviene partir de los métodos clásicos de detección OOD. Para estructurar y desarrollar la revisión de toda esta sección, tomaremos como referencia principal el exhaustivo marco taxonómico propuesto por Yang et al. [YZLL24]. En términos generales, el problema de detección OOD consiste en definir una función de puntuación (*scoring function*) que asigne un valor escalar a cada muestra, de modo que se persigue que dicho valor sea mayor cuanto más se desvíe la observación de la distribución de entrenamiento. De hecho, antes del *deep learning*, este problema ya se afrontaba mediante técnicas estadísticas y de aprendizaje clásico como el Análisis de Componentes Principales (PCA), las Máquinas de Vectores de Soporte (SVM) o Isolation Forest. En la literatura actual, centrada en técnicas de *deep learning*, estos enfoques se suelen estructurar en: métodos basados en clasificación, que marcaron el inicio del estudio OOD en esta nueva modalidad; métodos basados en densidad, que asocian las regiones de baja probabilidad a muestras OOD; y, finalmente, métodos basados en distancia, que asumen que las anomalías serán aquellas que se encuentren alejadas de los centroides o prototipos

de las clases ID.

3.2.1. Métodos basados en clasificación

Los métodos basados en clasificación emplean la salida de un clasificador (ya sea un modelo lineal, redes neuronales, conjuntos de árbol de decisión, etc.) para distinguir las muestras ID de OOD sin necesidad de modelar la distribución de los datos [YZLL24]. El origen histórico es usar la probabilidad máxima del *softmax* (*maximum softmax probability*, MSP) como indicador de pertenencia a la distribución de referencia [HG17]: una muestra se etiqueta como OOD si $\max_c p(y = c|x)$ cae por debajo de un umbral. A continuación veremos los distintos enfoques usando métodos basados en clasificación.

Modelos basados en la salida de un modelo

Estos derivan un score OOD directamente de los *logits* o probabilidades que producen la red. Cabe destacar que los *logits* son los valores numéricos generados por la última capa lineal de una red neuronal antes de ser transformados mediante una función de activación (como *softmax*) para obtener una distribución de probabilidad. En concreto, existen dos tipos de modelos basados en la salida de un modelo dependiendo de si se permite modificar la arquitectura o el objetivo de entrenamiento del clasificador, es decir, de si se puede evitar o no el re-entrenamiento.

Por una parte, nos encontramos con los métodos de *detección post-hoc* (de entre los cuales destaca el método MSP [HG17]) que tienen la ventaja de poder aplicarse sobre cualquier clasificador ya entrenado sin modificar su procedimiento de entrenamiento. Una primera estrategia es la de ODIN [LLS18], que actúa sobre los *logits* mediante perturbaciones en la entrada y escalado de temperatura para amplificar la separación entre las *scores* de muestras ID y OOD; así como, posteriormente, se propusieron justificaciones teóricas más sólidas basadas en *energy score* [LWOL20] y otros refinamientos [ZFC⁺23].

Una segunda estrategia actúa sobre las activaciones internas de la red, es decir, de las neuronas de las capas *BatchNorm*. Se identificó [SGL21] que las estadísticas de normalización por lotes, estimadas sobre los datos ID y aplicadas ciegamente en *test*, disparan activaciones anormalmente altas en muestras OOD. Otros trabajos posteriores [YZLL24] propusieron podar los pesos menos relevantes de la red o eliminar una fracción significativa de las representaciones de capas tardías, lo que reduce la varianza de los datos OOD y produce distribuciones más concretadas y separables.

Por otra parte, los métodos *basados en entrenamiento* intervienen en el propio aprendizaje del clasificador a través de diversas estrategias. Entre ellas destaca *Outlier Exposure* (OE) [HMD19], que utiliza un conjunto de datos externos auxiliar para enseñar al modelo a asignar baja confianza a las muestras fuera de distribución. Asimismo, enfoques como *LogitNorm* [WXC⁺22] normalizan la longitud de los vectores de *logits* en la función de pérdida para mitigar la sobreconfianza nativa de la red. Finalmente, métodos como *Virtual Outlier Synthesis* (VOS) [DWJ⁺22] generan de forma adversarial anomalías virtuales en el espacio latente, delimitando con precisión la frontera conocida sin necesidad de recopilar datos externos reales.

Dentro de estos últimos, los que aplican el enfoque de *outlier exposure*, incorporan datos OOD durante el entrenamiento para aprender explícitamente la frontera ID/OOD. Cuando se dispone de muestras OOD reales, la estrategia más directa (introducida por el método OE [HMD19]) penaliza las predicciones confiadas sobre ellas forzando distribuciones de

3. Detección de datos fuera de la distribución

salida uniformes o de alta entropía, de forma que el modelo aprende a reservar la confianza para las clases conocidas.

Cuando no se dispone de ellas, algunos métodos intentan sintetizar muestras (*outlier data generation*) para mejorar esta separabilidad. De esta manera, algunos trabajos emplean GANs para generar muestras OOD en la región de baja densidad. Sin embargo, sintetizar imágenes en espacios de alta dimensión resulta complicado, por lo que trabajos más recientes, como VOS [DWJ⁺22], proponen muestrear regiones de baja verosimilitud directamente en el espacio de características mediante enfoques adversariales.

Métodos basados en gradientes

Estos métodos explotan la información del espacio de gradientes, que habitualmente es ignorada por los enfoques anteriores. En particular, ODIN [LLS18] ya hacía uso implícito de los gradientes para calcular las perturbaciones añadidas al pre-procesamiento de la entrada y así, aumentar el *score softmax* anteriormente tratado. Sin embargo, este método no derivaba explícitamente un *score* a partir de la información del espacio gradiente. Un estudio más reciente propuso *GradNorm* [HGL21], que empleaba la norma del vector de gradientes retropropagado (*backpropagated*) desde la divergencia KL entre la salida *softmax* y una distribución uniforme como *score* OOD. La intuición reside en que esta norma es, en general, mayor en muestras OOD que en muestras ID, aunque posteriormente se ha estudiado que esto no depende exclusivamente de los gradientes, sino también de la magnitud de los *embeddings* aprendidos y la distribución de salida del modelo.

Modelos bayesianos

Los modelos bayesianos aprenden distribuciones de probabilidad para cuantificar la incertidumbre del modelo [Nea12], de forma que una muestra no vista durante el entrenamiento debería producir una predicción de alta incertidumbre. La red neuronal bayesiana, que estima la distribución posterior sobre los pesos mediante MCMC, métodos de Laplace o inferencia variacional, es la formulación más rigurosa, pero su coste computacional elevado y sus predicciones a menudo inexactas limitan su uso práctico. Las aproximaciones más extendidas son MC-Dropout [GG16] y los *deep ensembles* [LPB17], que obtienen estimaciones de incertidumbre más rápidas aunque menos competitivas para la detección OOD pura. Otra alternativa es *Dirichlet Prior Network* (DPN) [MG18], que modela explícitamente tres fuentes distintas de incertidumbre: la incertidumbre del modelo, los datos y la distribucional.

Modelos fundacionales

Los modelos fundacionales [BHA⁺21], y en particular, los modelos visión-lenguaje preentrenados a gran escala, han demostrado mejorar significativamente la detección OOD gracias a la riqueza de sus representaciones. Sin embargo, adaptar estos modelos a tareas específicas mediante *linear probing*, *prompt tuning* o *fine-tuning* sigue siendo un reto abierto, ya que estos enfoques estándar no siempre mejoran la detección OOD e incluso pueden degradarla. Para solucionar el problema, algunas propuestas introducen regularización OOD sobre subconjuntos de características locales del modelo o mecanismos de personalización bidireccional del prompt para mejorar la alineación entre representaciones visuales y textuales.

Las capacidades de aprendizaje *zero-shot* de modelos como CLIP [RKH⁺21] abren además una nueva dirección: detectar muestras OOD sin entrenamiento explícito, representando las clases conocidas únicamente mediante descripciones textuales. Los métodos propuestos en este marco varían entre entrenar un decodificador sobre el codificador visual del modelo para generar etiquetas candidatas, escalar directamente las puntuaciones softmax para alinear

características visuales y textuales, o incorporar una lógica de negación explícita mediante nuevos prompts y funciones de pérdida opuestas para identificar muestras difíciles de distinguir.

Sin embargo, los métodos basados en clasificación presentan la restricción de que requieren un clasificador supervisado preentrenado sobre las clases ID, lo que los hace inadecuados en escenarios donde las etiquetas son escasas o el dominio es altamente especializado (siendo este último el que nos ocupa). Bajo estas limitaciones, resultante necesario recurrir a enfoques que modelen directamente la distribución de datos ID [YZLL24], como se propondrá en las siguientes secciones.

3.2.2. Métodos basados en densidad

Los métodos basados en densidad modelan explícitamente la distribución de los datos ID mediante un modelo probabilístico, etiquetando como OOD aquellas muestras que caen en regiones de baja verosimilitud [YZLL24]. Así pues, a diferencia de los métodos basados en clasificación, no requieren de etiquetas de clase para construir el *score* de detección OOD, lo que los hace especialmente adecuados en dominios especializados donde las etiquetas escasean.

Por una parte, nos encontramos con las técnicas de estimación de densidad clásicas, ya sean paramétricas (distribuciones gaussianas o mezclas de gaussianas) o no paramétricas (histogramas o estimación por núcleos (KDE)); y por otra parte, con técnicas más modernas que aplican modelos generativos profundos, como los VAEs, los modelos de flujo normalizado o las GANs.

Sin embargo, el uso de la verosimilitud como *score* OOD plantea una dificultad que se ha demostrado empíricamente la literatura: los modelos generativos profundos pueden asignar una verosimilitud mayor a muestras OOD que a sus propios datos de entrenamiento [NMT⁺19]. Por ejemplo, un modelo de flujo normalizado entrenado sobre CIFAR-10 asigna sistemáticamente una verosimilitud más alta a imágenes de SVHN que a las imágenes del propio conjunto de entrenamiento, a pesar de que ambos conjuntos son semánticamente muy distintos [NMT⁺19]. Este fenómeno se atribuye a la *tipicidad*, es decir, que los modelos generativos profundos pueden mostrar una alta concentración de probabilidad lejos de su moda, de modo que el conjunto típico (donde reside la mayoría de las muestras ID) no coincide necesariamente con las regiones de mayor densidad [NMT⁺19].

Para paliar este problema, algunas propuestas recurren a la razón de verosimilitudes, a puntuaciones alternativas como el *likelihood regret* o a conjuntos de múltiples modelos de densidad [YZLL24]. Aún así y pese a estos avances, entrenar y optimizar modelos generativos profundos sigue siendo costoso, y su rendimiento en detección OOD acostumbra a quedar por detrás de los métodos basados en clasificación [YZLL24]. Este hecho motiva que, en los capítulos siguientes, se analice con mayor detenimiento bajo qué condiciones los modelos generativos pueden resultar competitivos, y qué estrategias permiten superar la limitación inherente de la verosimilitud como criterio de detección.

3.2.3. Métodos basados en distancia

Los métodos basados en distancia parten de la hipótesis de que las muestras OOD se sitúan, en comparación con las muestras ID, significativamente lejos de los centroides o prototipos de las clases de entrenamiento. A diferencia de los métodos basados en clasificación, estos

3. Detección de datos fuera de la distribución

enfoques no dependen directamente de las predicciones del modelo, sino de la geometría del espacio de datos. Y además, a diferencia de los basados en densidad, no requieren modelar la distribución probabilística completa, sino que basan su decisión en la proximidad relativa de cada muestra a los prototipos de referencia.

Cabe señalar que, si bien es frecuente aplicar estas métricas sobre el espacio latente para evitar la alta dimensionalidad de los píxeles, estos métodos son igualmente válidos en el espacio de entrada original, especialmente en dominios como los datos tabulares. En estos, de hecho, es posible calcular distancias directas entre las observaciones y los centroides de clase sin necesidad de una proyección previa.

Variante paramétrica: distancia de Mahalanobis

Una de las primeras soluciones de este enfoque [LLS18] propone modelar las representaciones internas de la red como una distribución Gaussiana condicional por clase y utilizar la distancia de Mahalanobis mínima a todos los centroides de clase como *score* OOD. Formalmente, dado un punto de prueba x con representación $f(x)$ en el espacio de características, la *score* se define como el opuesto a la distancia al cuadrado al centroide de clase más próximo:

$$M(x) = \max_c -(f(x) - \hat{\mu}_c)^\top \hat{\Sigma}^{-1} (f(x) - \hat{\mu}_c)$$

donde $\hat{\mu}_c$ y $\hat{\Sigma}$ son la media empírica por clase y la covarianza compartida estimadas sobre el conjunto de entrenamiento. Además, el método se extiende a múltiples capas de la red, combinando linealmente las puntuaciones por capa mediante una combinación ponderada $\sum_\ell \alpha_\ell M_\ell(x)$, e incorpora además una perturbación de la entrada en la dirección del gradiente (análoga a la de ODIN [LLS18]) para ampliar la separación entre muestras ID y OOD. Una contribución posterior [YZLL24] extiende este enfoque dividiendo las imágenes en regiones de primer plano y fondo, calculando la razón entre las distancias de Mahalanobis en ambos subespacios para mejorar la separabilidad.

Variante no paramétrica: vecinos más cercanos

En contraste con la aproximación paramétrica anterior, trabajos más recientes [SMZL22] han demostrado las ventajas que ofrece la distancia al k -ésimo vecino más cercano (*deep* K-NN) para la detección OOD. La motivación que propone es que modelar el espacio de representación como una combinación de gaussianas impone un sesgo demasiado fuerte que no tiene por qué cumplirse en la práctica.

Para ello, el método almacena el conjunto de representaciones normalizadas del entrenamiento $\mathcal{Z}_n = (z_1, z_2, \dots, z_n)$, con $z_i = \varphi(x_i) / \|\varphi(x_i)\|_2$, y durante la inferencia calcula la distancia euclídea entre la representación normalizada de la muestra de prueba $z^* = \varphi(x^*) / \|\varphi(x^*)\|_2$ y su k -ésimo vecino más cercano en dicho conjunto. La función de decisión viene dada por:

$$G(z^*; k) = -r_k(z^*),$$

donde $r_k(z^*) = \|z^* - z_{(k)}\|_2$ es la distancia al k -ésimo vecino más cercano, $1\{\cdot\}$ es una función indicador, y λ es un umbral elegido de modo que una fracción elevada de las muestras ID quede correctamente clasificada.

Funciones de distancia alternativas

Más allá de Mahalanobis y los vecinos más cercanos, la literatura ha explorado un amplio abanico de funciones de distancia [YZLL24]: similitud coseno entre características de prueba

y de clase, distancias con *kernel* de función de base radial [vASTG20] o euclídea [HLW⁺20], así como la norma de las características en el subespacio complementario ortogonal al espacio principal ID. Por último, *CIDER* [MSDL23] explora el uso de *embeddings* en el espacio hiperesférico, donde se puede fomentar simultáneamente la dispersión entre clases y la compacidad intracase mediante pérdidas de aprendizaje de métricas, lo que resulta en representaciones más discriminativas para la detección OOD.

En resumen, los métodos basados en distancia son especialmente adecuados cuando las etiquetas son escasas o el dominio es especializado, pero su eficacia depende críticamente de la calidad discriminativa de las representaciones aprendidas [YZLL24]. Esta dependencia motiva el uso de modelos fundacionales preentrenados como extractores de características, cuyas representaciones ricas pueden aprovecharse directamente para el cómputo de distancias sin reentrenamiento supervisado, siendo precisamente el enfoque adoptado como experimento *baseline* en el presente trabajo.

3.3. Scores OOD basados en modelos generativos

Los métodos basados en reconstrucción parten de la idea de que un modelo *encoder-decoder* entrenado exclusivamente sobre datos ID producirá reconstrucciones de menor calidad¹ para muestras OOD que para muestras ID, de modo que el error de reconstrucción puede emplearse directamente como *score* de detección [YZLL24]. Este enfoque resulta interesante porque no requiere etiquetas ni datos OOD en entrenamiento, sino tan solo los datos ID segregados de los OOD.

Además, estos métodos evitan las limitaciones ya discutidas de los métodos de densidad (en los cuales resulta contraintuitivo qué tipo de datos terminan recibiendo una alta verosimilitud por parte del modelo, ya que puede asignar densidades erróneamente altas a muestras OOD [NMT⁺19]), y de los métodos de distancia (cuya eficacia depende críticamente de la calidad discriminativa de las representaciones aprendidas).

En cuanto a las arquitecturas empleadas, la reconstrucción a nivel de píxel mediante autoencoders clásicos no es una solución popular debido a su elevado coste de entrenamiento; además de que estos modelos a menudo son capaces de reconstruir imágenes no vistas anteriormente debido a que aprenden a capturar patrones globales y estructurales (como bordes y fondos) en lugar de características semánticas. En cambio, reconstruir en el espacio de características latentes ha demostrado ser una alternativa más prometedora, disminuyendo el riesgo que acabamos de comentar. Trabajos recientes han explorado además estrategias de reconstrucción parcial (enmascarando porciones aleatorias de la entrada) o la combinación del error de reconstrucción con inconsistencias del clasificador para mejorar la separabilidad ID/OOD. En las subsecciones siguientes se presentan los *scores* propuestos para las dos arquitecturas generativas que articulan el trabajo: los *Variational Autoencoders* (VAE) y los modelos de difusión (DDPM), cuyas definiciones formales se recogen en la sección 4.4 del marco experimental.

¹En este contexto, una «menor calidad» se traduce matemáticamente en un incremento del error de reconstrucción, evaluado mediante funciones como el MSE (norma L₂) o el MAE (norma L₁).

3.3.1. Reconstrucción con VAE

Una vez entrenado el VAE exclusivamente sobre datos ID, los *scores* OOD se derivan desde dos espacios complementarios [HYC⁺24]. Los **scores derivados del ELBO** (el error de reconstrucción y el score ELBO) explotan la calidad con la que el decoder reproduce la entrada; una muestra OOD cae en una región no explorada durante el entrenamiento y produce una reconstrucción de baja calidad. Los **scores del espacio latente** aplican en cambio métricas de distancia directamente sobre las representaciones del encoder: dado que la regularización KL concentra las representaciones ID en una región compacta, la distancia de Mahalanobis [DSC⁺18] y la distancia al vecino más cercano [SMZL22] detectan representaciones OOD alejadas de esa nube, análogamente a los métodos de Sección 3.2.3 aplicados al espacio latente. Las definiciones formales de los cuatro *scores* resultantes se recogen en la sección 4.4.

No obstante, todos ellos comparten una limitación: su calidad depende críticamente del tamaño del espacio latente, fijado antes del entrenamiento [HYC⁺24, GPT⁺23]. Un espacio demasiado pequeño degrada la reconstrucción incluso para muestras ID, y uno demasiado grande permite reconstruir también las OOD, anulando la capacidad discriminativa. Esta rigidez motiva el uso de modelos de difusión.

3.3.2. Reconstrucción con DDPM

Los modelos de difusión pueden interpretarse como *autoencoders* cuyo cuello de botella no es una propiedad fija del modelo, sino que se controla externamente durante la inferencia mediante la cantidad de ruido aplicado [GPT⁺23]. Como ilustra la Figura 3.2, corromper la entrada parcialmente y ejecutar la cadena inversa produce una reconstrucción condicionada sobre lo aprendido en ID; cuanto mayor sea el nivel de ruido aplicado, más depende esa reconstrucción exclusivamente de la distribución entrenada y más sensible resulta a muestras OOD. A diferencia del VAE, un único modelo permite explorar múltiples cuellos de botella sin necesidad de reentrenamiento.

A partir de este mecanismo se proponen tres familias de *scores* [GPT⁺23, WLSW22]: los basados en el **error de reconstrucción** en el espacio de la imagen (S_{recon} , $S_{\text{recon_multi}}$), los basados en la **predicción de ruido** que operan directamente en el espacio del ruido sin necesidad de ejecutar la cadena inversa (S_{noise} , $S_{\text{mse_multi}}$, $S_{\text{cos_multi}}$), y los basados en el **residuo de predicción** que aplican métricas de distancia sobre la diferencia entre ruido predicho y real, de forma análoga a los *scores* del espacio latente del VAE. Las definiciones formales se recogen en la sección 4.4.

En los capítulos anteriores hemos descrito los fundamentos teóricos de los modelos generativos profundos, para terminar con una revisión de los métodos de detección OOD usados frecuentemente en la literatura. A partir de esta base teórica, en la segunda parte de la memoria detallaremos el entorno experimental, la implementación de estos métodos y el análisis de los resultados obtenidos.




Figura 3.2.: Proceso de eliminación de ruido (denoising) en el conjunto de datos Hand MNIST a lo largo de diferentes pasos de tiempo, desde $T = 100$ hasta $T = 1000$.
Fuente: Graham et al. [GPT⁺23].

Parte II.

Estudio experimental

4. Marco experimental

Los experimentos de este trabajo se diseñan para responder a la pregunta de investigación planteada en la introducción, es decir,

«¿Es posible construir un sistema de detección OOD clínicamente viable en histología computacional combinando la riqueza semántica de un modelo de base con la capacidad generativa de los modelos de difusión latente?»,

siguiendo una escalada progresiva de dificultad: desde entornos sintéticos controlados hasta datos histológicos clínicos reales. En todos los casos, el modelo se entrena exclusivamente con muestras ID y los datos OOD se reservan para la evaluación final. Las hipótesis del trabajo son:

- H1.** Los modelos generativos entrenados exclusivamente con datos ID producen *OOD scores* sistemáticamente más altas ante muestras OOD que ante muestras ID.
- H2.** Operar sobre el espacio latente de un modelo fundacional mejora los resultados de detección OOD y reduce el coste de entrenamiento de días a horas.
- H3.** El rendimiento de la detección OOD puede depender más de la representación de la entrada que del *OOD score* elegido.
- H4.** Agregar la señal de error del DDPM a lo largo de múltiples pasos de la cadena de difusión mejora la detección OOD respecto al uso de un único paso.

La Figura 4.1 muestra la progresión de los experimentos propuestos. Esta consiste en cuatro etapas de dificultad creciente. Los modelos evaluados en cada etapa ilustran una o varias de las hipótesis de estudio.




Figura 4.1.: Progresión experimental de menor a mayor dificultad (de arriba a abajo). Las etiquetas en cursiva indican qué hipótesis permite verificar cada etapa.

4.1. Descripción de los datos

Los conjuntos de datos empleados cubren un amplio espectro de dificultad. Estos van desde conjuntos sencillos (espacios sintéticos bidimensionales con distinto nivel de separabilidad geométrica), que nos permiten obtener conclusiones sólidas en entornos controlados; hasta extrapolar dichos resultados a datos reales, representados por espacios de características de alta dimensión extraídas con un modelo fundacional.

Blobs y Moons.

Los conjuntos Moons y Blobs son conjuntos de datos sintéticos que se generan mediante las utilidades de `sklearn.datasets` [PVG⁺11]. En *Blobs*, $N=2000$ puntos se generan desde dos centroides en $(-2, 0)$ y $(2, 0)$ con desviación $\sigma=0.5$; el clúster o clase 0 es la distribución ID y el clúster 1, la OOD. En *Moons* se generan $N=2000$ puntos bidimensionales con ruido $\sigma=0.05$: la clase 0, actúa como distribución ID y la clase 1, adyacente y con forma cóncava complementaria, como distribución OOD. En concreto, la separabilidad lineal de *Blobs* contrasta con la estructura no lineal de *Moons*, lo que permite evaluar si los modelos son sensibles a no linealidades. Las figuras 4.2 y 4.3 muestran el espacio de entrada de ambos conjuntos.

MNIST frente a SVHN.

MNIST [LBBH98] comprende 60 000 imágenes de entrenamiento y 10 000 de test de dígitos manuscritos en escala de grises (28×28 píxeles) y se emplea en su totalidad como distribución ID. Como distribución OOD se utiliza SVHN [NWC⁺11], un conjunto de dígitos fotorrealistas tomados de fachadas de edificios en color, que se convierte a escala de grises y se redimensiona a 28×28 para homogeneizar la dimensión de entrada con MNIST. En

4. Marco experimental




Figura 4.2.: Espacio de entrada del conjunto *Blobs*: dos clústeres gaussianos linealmente separables (ID = clúster 0, OOD = clúster 1).




Figura 4.3.: Espacio de entrada del conjunto *Moons*: distribuciones no linealmente separables en forma de medias lunas (ID = clase 0, OOD = clase 1).

la figura 4.4 se muestra una colección de las imágenes de ambos conjuntos. Aunque ambos conjuntos pertenecen al dominio semántico de los dígitos, la brecha entre el dominio dibujado y normalizado de MNIST y el dominio fotorrealista con fondo natural de SVHN genera un contraste entre dominios de dificultad moderada, ampliamente utilizado como referencia en la literatura de detección OOD. En la proyección PCA bidimensional del espacio de píxeles (figura 4.5), ambas distribuciones presentan separación apreciable. De hecho, este problema es un caso de estudio sencillo, pues las muestras OOD son perfectamente detectables aplicando tan solo 2 componentes de PCA.




Figura 4.4.: Muestras de imágenes de los conjuntos de datos MNIST (ID) y SVHN convertido a escala de grises (OOD).

PathMNIST.

PathMNIST [YSW⁺23] es un subconjunto del *benchmark* MedMNIST v2 formado por parches histológicos de tejido colorrectal de 224×224 píxeles en formato RGB (resolución elegida frente a las alternativas de menor tamaño por requisitos semánticos de los modelos). El conjunto abarca nueve categorías de tejido (véanse ejemplos en la figura 4.7): tejido adiposo (ADI, clase 0), fondo sin tejido (BACK, clase 1), detritos (DEB, clase 2), linfocitos (LYM, clase 3), moco (MUC, clase 4), músculo liso (MUS, clase 5), mucosa normal (NORM, clase 6), estroma (STR, clase 7) y epitelio tumoral (TUM, clase 8). Las clases 1 y 2 (BACK y DEB) son artefactos del procesamiento histológico sin valor diagnóstico y se excluyen de ambas distribuciones. Las clases 7 y 8 se designan como OOD por ser los tejidos de interés clínico en el cribado del cáncer colorrectal: un sistema real debería señalar estos parches para revisión




Figura 4.5.: Proyección PCA del espacio de entrada para MNIST (ID) frente a SVHN (OOD). Al provenir de dominios distintos, la proyección bidimensional muestra la separabilidad entre distribuciones en el espacio de píxeles.

por el patólogo. La dificultad radica en que *STR* comparte apariencia visual con tejido conectivo benigno, generando el solapamiento con la distribución ID visible en la figura 4.6. Se definen dos configuraciones de partición ID/OOD de dificultad creciente:

- **PathMNIST-C1:** ID = clase 6 (*NORM*); OOD = clases 7 (*STR*) y 8 (*TUM*).
- **PathMNIST-C2:** ID = clases 0, 3, 4, 5 y 6 (tejidos no tumorales, excluyendo *BACK* y *DEB*); OOD = clases 7 y 8. Esta configuración amplía la variación interna de la distribución ID al incluir cinco clases de apariencia diversa.




Figura 4.6.: Proyección PCA del espacio de entrada para PathMNIST-C2: tejidos no tumorales (ID, clases 0, 3–6) frente a tejido tumoral (OOD, clases 7–8). El solapamiento entre distribuciones histológicas ilustra la dificultad de separación en el espacio de píxeles para la configuración con mayor cobertura ID.

4. Marco experimental




Figura 4.7.: Ejemplos de parches histológicos correspondientes a las distintas clases del conjunto de datos PathMNIST.

SICAP.

SICAP [SRC⁺20] es un conjunto de biopsias de próstata anotadas con el sistema Gleason, que cuantifica la agresividad del cáncer de próstata en cuatro grados (1–4). A diferencia del resto de conjuntos, no procesaremos las imágenes directamente como píxeles. En su lugar, emplearemos vectores de características de dimensión 1024 extraídos con UNI [CDL⁺24], un *vision transformer* ViT-L/16 pre-entrenado mediante DINOv2¹ sobre más de cien millones de parches histopatológicos procedentes de The Cancer Genome Atlas (TCGA)² y otras colecciones públicas. El uso de estas características sitúa a SICAP en un dominio de alta dimensión estructurada, capturando información morfológica de alto nivel que los píxeles crudos no podrían proporcionar de forma tratable computacionalmente. Se definen dos configuraciones:

- **SICAP-C1:** ID = Gleason 1 (tejido benigno estricto); OOD = Gleason 2, 3 y 4.
- **SICAP-C12:** ID = Gleason 1 y 2 (bajo grado); OOD = Gleason 3 y 4 (alto grado).

SICAP-C1 modela el escenario más restrictivo, en el que solo se dispone de tejido completamente benigno durante el entrenamiento, mientras que SICAP-C12 amplía la definición de normalidad al incluir cambios de bajo grado, reduciendo así la distancia estadística entre ID y OOD. El solapamiento en el espacio de características UNI entre grados adyacentes, visible en la figura 4.8, anticipa la dificultad del problema respecto al resto de conjuntos.




Figura 4.8.: Proyección PCA de las características UNI del conjunto SICAP-C12: Gleason 1–2 (ID) frente a Gleason 3–4 (OOD).

¹DINOv2 es un método de aprendizaje autosupervisado desarrollado por Meta AI que produce representaciones visuales robustas y de alto rendimiento sin requerir etiquetas ni ajuste fino (*fine-tuning*) dirigido a tareas específicas.

²The Cancer Genome Atlas (TCGA) es un programa de genómica del cáncer fundamental que ha caracterizado molecularmente miles de tumores primarios y muestras normales correspondientes. El portal de datos está disponible en: <https://portal.gdc.cancer.gov/>

4.2. Procesamiento de los datos

4.2.1. Partición de los conjuntos

En todos los experimentos se respeta el principio fundamental de la evaluación OOD: **el conjunto de entrenamiento contiene únicamente muestras ID**, y los datos OOD nunca participan en la optimización de los modelos. Para cada conjunto de datos se definen tres particiones no solapadas: *train* (muestras ID para el ajuste de parámetros), *id_eval* (muestras ID retenidas para el cálculo de métricas y la construcción de la referencia de normalidad) y *ood_eval* (muestras OOD empleadas exclusivamente en la evaluación).

En los conjuntos sintéticos, el 70 % de los puntos ID se asigna al entrenamiento y el 30 % restante a *id_eval*, mientras que todos los puntos OOD forman el conjunto *ood_eval*. Para MNIST y PathMNIST se emplean las particiones *train/test* originales de los respectivos conjuntos. Para la evaluación de características extraídas con el modelo UNI sobre SICAPv2, se respetan las divisiones de datos (*splits*) oficiales establecidas en el trabajo de referencia [SRCS⁺20].

4.2.2. Normalización

Todos los conjuntos se normalizan para estabilizar el entrenamiento, llevando los valores al rango $[-1, 1]$ requerido por los modelos generativos³. Los conjuntos sintéticos y las características UNI de SICAP, cuya distribución por coordenada no tiene un rango canónico conocido a priori, se estandarizan con estadísticas calculadas sobre el propio conjunto de entrenamiento: $\tilde{x} = (x - \mu) / \sigma$, donde $\mu \in \mathbb{R}^d$ y $\sigma \in \mathbb{R}^d$ son los vectores de medias y desviaciones típicas por coordenada⁴. Para los conjuntos de imagen se aplica una normalización fija que se sirve del rango conocido del formato. Las imágenes de MNIST se representan como flotantes en $[0, 1]$ (por torchvision), por lo que `Normalize(0.5, 0.5)` (equivalente a $\tilde{x} = (x - 0.5) / 0.5$) basta para llevarlas a $[-1, 1]$. Las imágenes RGB de PathMNIST se almacenan como enteros en $[0, 255]$ (por medmnist), de modo que aplicamos la transformación $\tilde{x} = x / 127.5 - 1$, llevándolas igualmente a $[-1, 1]$.

4.2.3. Representación con modelo fundacional para SICAP

Antes de describir los métodos de representación de SICAP, conviene recordar los *modelos fundacionales* (o *foundation models*) que fueron introducidos en la Sección 2.4.3. Un modelo fundacional es un modelo de gran escala preentrenado sobre datos heterogéneos masivos mediante aprendizaje auto-supervisado, cuya capacidad de transferencia le permite adaptarse a tareas diversas sin re-entrenamiento. En patología computacional, la escasez de datos etiquetados hace especialmente interesante este paradigma. Un ejemplo destacado es UNI [CDL⁺24], un *Vision Transformer* (ViT-Large) preentrenado con DINOv2 sobre más de cien millones de parches histológicos procedentes de más de cien mil imágenes de tejido H&E a lo largo de veinte tipos de tejido distintos, que mejora la generalización fuera de dominio respecto a modelos anteriores al excluir intencionadamente los conjuntos de evaluación públicos de su colección de preentrenamiento.

³El *scheduler* DDPM necesita calibrar sus coeficientes de ruido sobre este rango específico, mientras que el VAE puede beneficiarse de esta escala simétrica y acotada.

⁴Las componentes de σ inferiores a 10^{-6} se sustituyen por 1 para evitar divisiones degeneradas.

De imágenes completas a vectores de características

Las imágenes de cortes completos de tejido (*whole-slide images*, WSIs) tienen resoluciones del orden de gigapíxeles, lo que hace inviable procesarlas directamente con una red neuronal. La solución estándar, ilustrada en la Figura 4.9, consiste en dividir las imágenes en *parches* de menor tamaño y extraer de cada uno un vector de características mediante el *encoder* congelado del modelo fundacional [CDL⁺24]. Dado un parche x , su representación latente es

$$z = \mathcal{F}(x) \in \mathbb{R}^d,$$

donde d es la dimensión del espacio de características (por ejemplo, $d = 1024$ en UNI). En este trabajo adoptamos estos vectores como entrada para los experimentos de patología (mientras que para el resto de conjuntos se utilizan imágenes directas o vectores simulados mediante aplanamiento). Esta elección se debe a que el espacio latente de un modelo fundacional entrenado a escala ya contiene una estructura semántica que hace plausible la separabilidad entre muestras ID y OOD [PDBE25], además de la notable reducción en el coste computacional.




Figura 4.9.: Esquema de extracción de características donde una imagen de entrada x en el espacio de píxeles se mapea a un espacio latente z mediante un modelo extractor $\mathcal{F}$, seguido de una función de evaluación $\mathcal{S}(z)$.

Fuente: Pocevičiūtė et al. [PDBE25].

Representación de SICAP

En consecuencia, los datos de SICAP se integran en el flujo de trabajo cargando directamente los vectores precomputados desde los ficheros `X_train.npy` y `X_test.npy`. Este espacio condensa información morfológica de alto nivel (como la textura nuclear, la densidad celular y la arquitectura glandular) que una red entrenada desde cero difícilmente lograría asimilar con un volumen de datos limitado.

Esta estrategia responde a dos motivos fundamentales:

- **Práctico:** El procesamiento directo de imágenes histopatológicas de alta resolución en el espacio de píxeles resulta inviable con los recursos computacionales disponibles y ofrece peores resultados, como se evidenciará en los experimentos con PathMNIST.
- **Científico:** Al unificar la entrada bajo la misma representación de UNI, se garantiza

4. Marco experimental

una comparación directa y equitativa entre los modelos generativos y los métodos basados en distancias (k-NN y Mahalanobis).

A modo de aclaración, cabe reiterar que en el presente trabajo no se utilizan las imágenes originales del conjunto SICAP, sino sus respectivos vectores de características.

4.3. Detalles de implementación

4.3.1. Entorno de desarrollo

Hardware.

Los experimentos se ejecutaron en un servidor con cuatro GPUs *NVIDIA GeForce RTX 3090* (24 GB de VRAM cada una), 64 núcleos de CPU y 503 GB de RAM. La paralelización a nivel de experimento se gestiona mediante sesiones screen y la variable `CUDA_VISIBLE_DEVICES`, lo que permite asignar experimentos a GPUs concretas sin interferencia entre procesos.

Software y bibliotecas.

El entorno se construyó sobre Python 3.10 con Conda. El motor de cómputo es PyTorch con soporte CUDA, complementado por *diffusers* para el *scheduler* DDPM y MONAI para la arquitectura UNet médica. Los conjuntos de datos sintéticos (Blobs, Moons) se generan con *scikit-learn*, que también proporciona los estimadores de distancia (Mahalanobis, kNN) y las métricas de evaluación (AUROC, FPR@95); MNIST se carga mediante *torchvision*; y PathMNIST mediante *medmnist*. La visualización de resultados se apoya en *matplotlib* para crear las figuras, en *L^AT_EX* para la generación automática de tablas y en *umap-learn* para la representación de espacios latentes. La gestión de configuraciones se realiza con *OmegaConf* y el seguimiento de métricas de entrenamiento con *Weights & Biases*.

Diseño del código.

El código fuente se organiza bajo `src/` en subpaquetes con responsabilidad única: *models* (arquitecturas y jerarquía OOD), *data* (carga y preprocesado), *training* (bucle de entrenamiento), *evaluation* (cómputo de *scores* y métricas), *benchmarking* y *viz* (figuras). Las configuraciones residen en `configs/`, compuestas en tres niveles jerárquicos de ficheros YAML: `base.yaml` para los valores globales, `configs/data/` para los parámetros de cada conjunto de datos, y `configs/experiments/` para los hiperparámetros de cada experimento. Todos los modelos parten de una clase base abstracta común que define la interfaz OOD; de ella heredan las clases de familia (VAE, DDPM), que concentran la lógica compartida, y estas a su vez dan lugar a las implementaciones concretas, que solo difieren en el *backbone* (MLP o UNet). La orquestación de ejecuciones se realiza mediante los *scripts* `scripts/run.sh` y `scripts/experiments.sh`, que agrupan los experimentos en bloques y los distribuyen entre GPUs.

4.3.2. Arquitecturas

Se implementan cuatro variantes de modelos generativos agrupadas en dos familias (VAE y DDPM) y dos clases de *backbone* (MLP residual y U-Net convolucional), dando lugar a las combinaciones **MLP-VAE**, **MLP-DDPM**, **UNet-VAE** y **UNet-DDPM** (véase la Figura 4.10 para apreciar la diferencia estructural entre ambos *backbones*). Las variantes MLP se pueden aplicar a todos los conjuntos de datos (pese a que en este trabajo solo se aplican a

los de interés), y las variantes UNet se reservan para los conjuntos de imágenes (MNIST y PathMNIST), donde la estructura espacial de los datos justifica el uso de capas convolucionales (pues su aplicación a vectores de características implicaría asumir un sesgo inductivo espacial incorrecto).

MLP-VAE. El *encoder* aplica d capas totalmente conectadas de anchura h con activación LeakyReLU ($\alpha=0.2$) y proyecta la representación resultante mediante dos cabezas lineales independientes hacia la media μ y el logaritmo de la varianza $\log \sigma^2$ del espacio latente de dimensión L . El logaritmo de la varianza se recorta a $[-10, 10]$ antes del truco de la reparametrización para garantizar la estabilidad numérica del muestreo. El *decoder* es simétrico: d capas de anchura h con activación ReLU seguidas de una proyección lineal que recupera la dimensión de entrada. La función objetivo es el ELBO negativo: la pérdida de reconstrucción se mide con MSE y el término de divergencia KL se escala mediante un multiplicador β configurable que controla el equilibrio entre fidelidad de reconstrucción y regularización del espacio latente.

MLP-DDPM. El *denoiser* es un MLP residual que recibe la muestra ruidosa $\mathbf{x}_t$ junto con el instante de tiempo t codificado mediante un *embedding* sinusoidal de dimensión d_t , siguiendo la arquitectura propuesta en [Sch24]. Para conjuntos de baja dimensión ($\dim \leq 4$), se aplican adicionalmente *embeddings* sinusoidales con escala 25.0 a cada coordenada de entrada por separado, técnica que mejora la capacidad del modelo para capturar variaciones de alta frecuencia en espacios muy reducidos [TSM⁺20]. Cada bloque residual incorpora normalización de capa (LayerNorm) antes de la proyección lineal y *dropout* configurable; la inicialización de pesos sigue el esquema Xavier uniforme. El proceso de difusión sigue el *schedule* squaredcos_cap_v2 de la biblioteca diffusers⁵ [vPPL⁺22], con valores de $\beta \in [10^{-4}, 0.02]$, $T=1\,000$ pasos de entrenamiento y modo de predicción del ruido (ϵ -predicción).


UNet-VAE. El UNet-VAE adapta la configuración del módulo AutoencoderKL de la biblioteca MONAI⁶ [CLB⁺22] propuesta en el tutorial de modelos de difusión latente (LDM) del mismo proyecto [Pro23b], un autoencoder variacional convolucional con bloques residuales que opera directamente sobre imágenes 28×28 y 224×224 , respectivamente. La arquitectura dispone de tres niveles de resolución con canales [32, 64, 128] y un bloque residual por nivel. La atención no lineal está desactivada en todos los niveles puesto que las resoluciones son demasiado pequeñas para que sea beneficiosa, además de que hacía inviable el entrenamiento para el conjunto de PathMNIST por motivos de memoria. El espacio latente tiene 4 canales; con dos submuestreos de factor 2, la resolución espacial latente es 7×7 para imágenes de 28×28 (cuello de botella de 196 dimensiones) y 56×56 para imágenes de 224×224 (cuello de botella de 12,544 dimensiones). La función de pérdida de reconstrucción es la norma L_1 , que produce reconstrucciones más nítidas que el MSE para datos de imagen [ZGFK17].

UNet-DDPM. El UNet-DDPM adapta la configuración del módulo DiffusionModelUNet de MONAI propuesta en el tutorial DDPM del mismo proyecto [Pro23a], un U-Net con bloques


⁵Se ha empleado la biblioteca diffusers desarrollada por Hugging Face para la implementación de los planificadores de ruido (*schedulers*). Disponible en: <https://huggingface.co/docs/diffusers/>

⁶Medical Open Network for AI (MONAI) es un *framework* de código abierto basado en PyTorch, diseñado específicamente para la investigación en imagen médica con aprendizaje profundo. Disponible en: <https://project-monai.github.io/>

4. Marco experimental



(a) **MLP Residual** para vectores de baja dimensión.



(b) **U-Net Convolutacional** para imágenes con estructura espacial.

Figura 4.10.: Representación de la arquitectura de los *backbones* utilizados.

Fuente: Elaboración propia. El estilo gráfico adopta la convención visual propuesta por Ronneberger et al. [RFB15], adaptándola para reflejar las arquitecturas específicas del proyecto (en particular, de MLP-DDPM y Unet-DDPM).

residuales (canales [64, 128, 256]) sin atención en los niveles de *skip* incorpora atención de 64 cabezas sobre los mapas de características de menor resolución, configuración impuesta por las restricciones de memoria a resolución 224×224 . El *scheduler*, componente encargado de controlar la cantidad de ruido que se añade o elimina en cada paso temporal, emplea un *schedule* lineal de betas (*linear_beta*) de MONAI.

4.3.3. Protocolo de entrenamiento

Todos los modelos se optimizan con **AdamW** [LH19] para los conjuntos de mayor complejidad (SICAP, PathMNIST, MNIST) y con **Adam** [KB15] sin decaimiento para los conjuntos sintéticos⁷. El programador de la tasa de aprendizaje combina un **calentamiento lineal** durante *warmup_epochs* épocas (del 10 % al valor nominal) con un decaimiento coseno hasta $\eta_{\min}=10^{-6}$. Los gradientes se recortan a norma máxima 1.0 en todos los modelos.

Para los modelos DDPM se activa la **media exponencial móvil (EMA)** con decaimiento 0.999: en cada paso, $\hat{\theta} \leftarrow 0.999 \hat{\theta} + 0.001 \theta$; al finalizar el entrenamiento los parámetros se reemplazan por la copia EMA, lo que mejora la consistencia de los *scores* OOD al reducir la varianza de las reconstrucciones.

El entrenamiento de los VAE incorpora un **calentamiento del peso KL**: el multiplicador β crece linealmente desde 0 hasta su valor objetivo durante las primeras *kl_warmup_epochs* épocas, previniendo el colapso del espacio latente [BVV⁺16]. El efecto es visible en la figura 4.11, donde la KL aumenta de forma gradual y progresiva.



Figura 4.11.: Evolución del peso β (*kl_weight*, izquierda) y la divergencia KL (*loss_kl*, derecha) durante el entrenamiento del VAE en SICAP. El calentamiento lineal permite que la KL ascienda de forma gradual y progresiva sin colapsar el espacio latente.

Todos los experimentos emplean *early stopping* sobre la pérdida de validación en *id_eval*: si no mejora durante *patience* épocas consecutivas, el entrenamiento se detiene. El seguimiento se realiza con **Weights & Biases** [Bie20], herramienta elegida por su capacidad para gestionar de trazable las múltiples configuraciones y registrar el rendimiento de cada barrido de hiperparámetros. La tabla 4.1 recoge los hiperparámetros por modelo y conjunto, y la tabla 4.2 los tiempos de entrenamiento; los hiperparámetros de difusión ($\beta_{\text{start}}=10^{-4}$, $\beta_{\text{end}}=0.02$, $T=1\,000$) son comunes a todos los modelos DDPM.

⁷A diferencia del optimizador Adam tradicional, AdamW implementa un decaimiento de pesos (*weight decay*) desacoplado del paso de actualización del gradiente. Esta modificación mejora significativamente la regularización y la generalización, siendo la elección recomendada para modelos de alta capacidad como los basados en procesos de difusión [LH19].

4. Marco experimental

Tabla 4.1.: Hiperparámetros de arquitectura y entrenamiento por modelo y conjunto de datos. h : anchura de la capa oculta (MLP); ch : canales del codificador UNet (32→128 para VAE, 64→256 para DDPM); d : número de bloques residuales; $lat. L$: dimensión del espacio latente (VAE); $emb. d_t$: dimensión del embedding temporal (DDPM); ep .: épocas máximas; bs .: tamaño de lote.

Conjunto	Modelo	h	ch	d	$lat. L$	$emb. d_t$	ep	bs
Sintéticos	MLP-VAE	32	—	1	2	—	80	16
Sintéticos	MLP-DDPM	64	—	2	—	64	100	16
MNIST	MLP-VAE	1024	—	5	256	—	200	256
MNIST	MLP-DDPM	2048	—	5	—	512	400	256
MNIST	UNet-VAE	—	32→128	1	4ch	—	150	32
MNIST	UNet-DDPM	—	64→256	1	—	—	300	16
PathMNIST-C1	MLP-VAE	1024	—	5	256	—	200	256
PathMNIST-C1	MLP-DDPM	2048	—	6	—	512	500	128
PathMNIST-C1	UNet-VAE	—	32→128	1	4ch	—	150	32
PathMNIST-C1	UNet-DDPM	—	64→256	1	—	—	300	16
PathMNIST-C2	UNet-VAE	—	32→128	1	4ch	—	150	32
PathMNIST-C2	UNet-DDPM	—	64→256	1	—	—	300	16
SICAP (C1/C12)	MLP-VAE	512	—	4	128	—	150	512
SICAP (C1/C12)	MLP-DDPM	1024	—	5	—	256	700	512

Tabla 4.2.: Los valores de tiempo representan la mediana y el número de épocas, a la media. Se han marcado con (†) aquellos casos en los que se aplicó *early stopping*.

Conjunto	KNN	Mahalanobis	MLP-VAE	MLP-DDPM	UNet-VAE	UNet-DDPM
Sintéticos						
<i>Moons</i>	—	—	1 m 46 s (80)	37 m 19 s (98 [†])	—	—
<i>Blobs</i>	—	—	1 m 45 s (80)	37 m 18 s (100)	—	—
Imágenes						
MNIST	—	—	3 m 50 s (150)	13 m 38 s (400)	1 h 31 m (150)	14 h 57 m (152 [†])
PathMNIST (C1)	50 s	49 s	2 m 36 s (200)	15 m 40 s (500)	2 h 30 m (150)	5 h 34 m (75)
PathMNIST (C2)	58 s	51 s	—	—	8 h 48 m (149 [†])	9 h 39 m (44 [†])
Vectores de características						
SICAP-C1	39 s	39 s	2 m 09 s (114 [†])	6 m 11 s (700)	—	—
SICAP-C12	40 s	38 s	2 m 13 s (116 [†])	6 m 11 s (551 [†])	—	—

Para ilustrar la dinámica de convergencia bajo este protocolo, las figuras 4.12a y 4.12b muestran la evolución del error de reconstrucción para el modelo VAE en los subconjuntos SICAP-C1 y C12, respectivamente, donde se aprecia el efecto estabilizador del EMA y la actuación del *early stopping*. De manera análoga, el comportamiento del error de predicción de ruido para los DDPMs en estos mismos conjuntos se detalla en las figuras 4.12c y 4.12d, evidenciando cómo la ampliación de la distribución ID (pasando de C1 a C12) introduce una estabilidad adicional en el proceso de aprendizaje. Adicionalmente, se observa en las gráficas una clara estratificación de las curvas en tres grupos distintos, dictados por las tasas de aprendizaje evaluadas (0.001, 0.0005 y 0.0001). El hecho de que esta agrupación se mantenga independientemente de la semilla aleatoria resulta muy positivo, ya que demuestra una

4.4. Definición formal de los scores OOD implementados

notable robustez en la convergencia frente a la inicialización.




Figura 4.12.: Dinámica de convergencia y curvas de entrenamiento en el conjunto SICAP. Se compara el comportamiento de los modelos VAE (arriba) y DDPM (abajo) ante los subconjuntos C1 (izquierda) y C12 (derecha). En todos los paneles se hace patente el efecto suavizador de la media exponencial móvil (EMA) y la interrupción por *early stopping*. Visualmente destaca la estratificación de las curvas en tres trayectorias bien diferenciadas, gobernadas estrictamente por la tasa de aprendizaje seleccionada (0.001, 0.0005 y 0.0001). La consistencia de estas agrupaciones a través de las distintas semillas demuestra la robustez del protocolo de entrenamiento frente a la inicialización aleatoria.

4.4. Definición formal de los scores OOD implementados

A continuación se recogen las definiciones formales de todos los *scores* implementados en este trabajo. Para la motivación conceptual de cada familia se remite a la sección 3.3; aquí el objetivo es precisar las expresiones concretas tal y como son calculadas, de modo que los resultados del capítulo 5 sean completamente reproducibles.

4. Marco experimental

4.4.1. Scores para el VAE

Para calcular cualquier *score* VAE, el primer paso es pasar la muestra $\mathbf{x}$ por el encoder y obtener la media latente $\mu_\theta(\mathbf{x})$ de forma determinista, sin muestrear. Esta elección es conveniente por dos razones: evita la varianza introducida por el muestreo y garantiza que, ante la misma muestra, siempre se obtenga la misma representación. Dependiendo de qué espacio se inspeccione a continuación, los *scores* se dividen en dos familias.

Scores derivados del ELBO.

Estos *scores* comparan $\mathbf{x}$ con su reconstrucción $\hat{\mathbf{x}} = \text{dec}(\mu_\theta(\mathbf{x}))$, obtenida decodificando directamente la media latente. El **error de reconstrucción** es:

$$S_{\text{recon}}(\mathbf{x}) = \|\hat{\mathbf{x}} - \mathbf{x}\|^2.$$

El **score ELBO** extiende el anterior sumando la divergencia KL entre la posterior del encoder y el prior gaussiano estándar, evaluada en forma cerrada como:

$$S_{\text{elbo}}(\mathbf{x}) = \|\hat{\mathbf{x}} - \mathbf{x}\|^2 + \beta \cdot \text{KL}(q_\theta(\mathbf{z}|\mathbf{x}) \parallel p(\mathbf{z})),$$

donde KL se calcula analíticamente, aprovechando que $q_\theta(\mathbf{z}|\mathbf{x}) = \mathcal{N}(\mu_\theta, \text{diag}(e^{\sigma_\theta}))$ y $p(\mathbf{z}) = \mathcal{N}(\mathbf{0}, \mathbf{I})$:

$$\text{KL}(q_\theta \parallel p) = -\frac{1}{2} \sum_j \left(1 + \sigma_{\theta,j} - \mu_{\theta,j}^2 - e^{\sigma_{\theta,j}} \right),$$

con $j = 1, \dots, d_z$ recorriendo las dimensiones del espacio latente (d_z es la dimensión del vector latente $\mathbf{z}$) y $\sigma_{\theta,j} = \log \sigma_{\theta,j}^2$ el logaritmo de varianza predicho por el encoder. El peso β coincide con el utilizado durante el entrenamiento, de modo que S_{elbo} replica exactamente la función de pérdida sobre la que el modelo fue optimizado.

Scores del espacio latente.

En lugar de inspeccionar la calidad de la reconstrucción, estos *scores* comparan directamente la representación $\mu_\theta(\mathbf{x})$ contra la nube de representaciones ID $\{\mu_\theta(\mathbf{x}_n)\}_{n=1}^N$ almacenada en una pasada previa por todos los datos de entrenamiento. Una muestra OOD debería proyectarse en una región alejada de esa nube, puesto que la regularización KL del entrenamiento ha concentrado las representaciones ID en torno al prior.

La **distancia de Mahalanobis latente** [DSC⁺18] modela la nube de referencia como una gaussiana multivariante, estimando la media y la covarianza empíricas con un término de regularización λ para garantizar la invertibilidad:

$$\begin{aligned} \mu_{\text{ref}} &= \frac{1}{N} \sum_{n=1}^N \mu_\theta(\mathbf{x}_n), \\ \Sigma &= \frac{1}{N} \sum_{n=1}^N (\mu_\theta(\mathbf{x}_n) - \mu_{\text{ref}})(\mu_\theta(\mathbf{x}_n) - \mu_{\text{ref}})^\top + \lambda \mathbf{I}. \end{aligned}$$

El *score* es la distancia al cuadrado al centroide:

$$S_{\text{Mah}}^{\text{lat}}(\mathbf{x}) = (\mu_\theta(\mathbf{x}) - \mu_{\text{ref}})^\top \Sigma^{-1} (\mu_\theta(\mathbf{x}) - \mu_{\text{ref}}).$$

A diferencia de la distancia euclídea, la distancia de Mahalanobis tiene en cuenta las co-

relaciones entre dimensiones del espacio latente, lo que la hace más robusta cuando esas dimensiones no son independientes. En los casos en que la dimensión del espacio latente es muy alta (por ejemplo, el espacio latente espacial de la UNet), se aplica previamente una reducción de dimensión mediante PCA para hacer manejable la estimación de la covarianza.

La **distancia al k -ésimo vecino más cercano** [SMZL22] evita el supuesto gaussiano y opera directamente sobre la nube de referencia:

$$S_{kNN}^{lat}(\mathbf{x}) = \left\| \boldsymbol{\mu}_\theta(\mathbf{x}) - \boldsymbol{\mu}_\theta(\mathbf{x}_{(k)}) \right\|,$$

donde $\mathbf{x}_{(k)}$ es el dato de entrenamiento cuya representación latente es la k -ésima más cercana a $\boldsymbol{\mu}_\theta(\mathbf{x})$. Esta variante no paramétrica captura la geometría local de la distribución de referencia sin imponer ningún supuesto distribucional, siendo especialmente útil cuando la nube de representaciones ID no sigue una forma gaussiana.

4.4.2. Scores para el DDPM

Los *scores* del DDPM explotan el hecho de que el modelo ha aprendido a eliminar el ruido de muestras ID: ante una muestra OOD, su comportamiento se degrada de forma sistemática. Para garantizar la reproducibilidad y evitar que la varianza estocástica del muestreo contamine el *score*, el ruido ε se fija a través de una semilla determinista, de modo que ante la misma muestra de entrada siempre se genera el mismo ruido. El proceso *forward* que corrompe la entrada al nivel de ruido t es:

$$\mathbf{x}_t = \sqrt{\bar{\alpha}_t} \mathbf{x} + \sqrt{1 - \bar{\alpha}_t} \varepsilon, \quad \varepsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I}),$$

donde $\bar{\alpha}_t = \prod_{s=1}^t (1 - \beta_s)$ es el producto acumulado de los coeficientes del *scheduler*.

Scores desde un único nivel de ruido.

Fijado un paso i^* , el **score de reconstrucción** (S_{recon}) ejecuta la cadena inversa completa del DDPM desde $\mathbf{x}_{i^*}$ hasta $t = 0$ para obtener $\hat{\mathbf{x}}$, y mide el error cuadrático medio de la reconstrucción:

$$S_{\text{recon}}(\mathbf{x}) = \|\hat{\mathbf{x}} - \mathbf{x}\|^2.$$

La ejecución de la cadena inversa descompone la denoising en i^* pasos sucesivos, lo que permite acumular progresivamente la señal de error. Nótese que esta reconstrucción iterativa es distinta a la estimación de Tweedie, que proyecta $\mathbf{x}_{i^*}$ sobre la variedad de datos en un único paso sin recorrer la cadena inversa.

Prescindiendo de la cadena inversa, el **score de predicción de ruido** (S_{noise}) mide directamente el error de predicción del *denoiser*:

$$S_{\text{noise}}(\mathbf{x}) = \|\varepsilon_\phi(\mathbf{x}_{i^*}, i^*) - \varepsilon\|^2.$$

Puesto que el modelo fue entrenado para minimizar exactamente este error sobre las muestras ID, ante muestras OOD cometerá errores sistemáticamente mayores. Su ventaja frente a S_{recon} es que evita el costoso proceso iterativo de denoising.

Scores multi-nivel.

Una limitación del enfoque de nivel único es que no existe un i^* universalmente óptimo: niveles bajos no destruyen suficiente información de la muestra y niveles muy altos apenas la

4. Marco experimental

condicionan. Para superar este problema, se agrega información de un conjunto de N niveles $\{i_1, \dots, i_N\}$ distribuidos uniformemente entre el 10 % y el 90 % de la cadena. Dado que el error crece monótonamente con el nivel de ruido, los valores brutos no son comparables entre niveles; por ello se normalizan como *Z-scores* usando la media μ_{i_j} y la desviación típica σ_{i_j} estimadas sobre los datos de entrenamiento ID para cada nivel i_j , y se promedian:

$$S_{\text{recon_multi}}(\mathbf{x}) = \frac{1}{N} \sum_{j=1}^N \frac{\|\hat{\mathbf{x}}_j - \mathbf{x}\|^2 - \mu_{i_j}}{\sigma_{i_j}},$$

donde $\hat{\mathbf{x}}_j$ es la reconstrucción iterativa desde el nivel i_j .

De forma análoga, los *scores* en espacio del ruido se extienden a múltiples niveles. El **score MSE multi-nivel** ($S_{\text{mse_multi}}$) aplica el mismo esquema de normalización al error de predicción de ruido en cada nivel:

$$S_{\text{mse_multi}}(\mathbf{x}) = \frac{1}{N} \sum_{j=1}^N \frac{\|\epsilon_\phi(\mathbf{x}_{i_j}, i_j) - \epsilon_j\|^2 - \mu_{i_j}}{\sigma_{i_j}}.$$

El **score coseno multi-nivel** ($S_{\text{cos_multi}}$) mide en cambio la orientación relativa entre ruido predicho y real, lo que en espacios de alta dimensión puede ser más informativo que la magnitud absoluta de la diferencia:

$$S_{\text{cos_multi}}(\mathbf{x}) = \frac{1}{N} \sum_{j=1}^N \frac{d_{\text{cos}}(\epsilon_\phi(\mathbf{x}_{i_j}, i_j), \epsilon_j) - \mu_{i_j}}{\sigma_{i_j}},$$

donde la distancia coseno entre dos vectores se define como:

$$d_{\text{cos}}(\mathbf{a}, \mathbf{b}) = 1 - \frac{\mathbf{a} \cdot \mathbf{b}}{\|\mathbf{a}\|_2 \|\mathbf{b}\|_2}.$$

En todos los casos, los estadísticos μ_{i_j} y σ_{i_j} se estiman sobre el conjunto de entrenamiento ID antes de la evaluación, de modo que el *Z-score* sitúa cada error en la escala de la distribución de referencia.

Scores del espacio de residuos.

De forma análoga a los *scores* del espacio latente del VAE, es posible construir para el DDPM una representación vectorial de cada muestra sobre la que aplicar métricas de distancia. Para un nivel de ruido fijo i^* y un ruido determinista ϵ , se define el **residuo de predicción**:

$$\mathbf{r}(\mathbf{x}) = \epsilon_\phi(\mathbf{x}_{i^*}, i^*) - \epsilon.$$

Dado que el modelo fue entrenado para predecir el ruido con precisión sobre las muestras ID, los residuos de entrenamiento se concentran cerca de $\mathbf{0}$; ante muestras OOD, la predicción se degrada y los residuos se alejan de esa región compacta. Almacenando la nube de residuos de entrenamiento $\{\mathbf{r}(\mathbf{x}_n)\}_{n=1}^N$ como referencia de normalidad, se le aplican exactamente las mismas métricas de distancia que al espacio latente del VAE. La **distancia de Mahalanobis en el espacio de residuos** ($S_{\text{Mah}}^{\text{res}}$) modela esa nube como una gaussiana:

$$S_{\text{Mah}}^{\text{res}}(\mathbf{x}) = (\mathbf{r}(\mathbf{x}) - \boldsymbol{\mu}_r)^\top \boldsymbol{\Sigma}_r^{-1} (\mathbf{r}(\mathbf{x}) - \boldsymbol{\mu}_r),$$

y la **distancia al k -ésimo vecino más cercano en el espacio de residuos** ($S_{\text{kNN}}^{\text{res}}$) prescinde de ese supuesto:

$$S_{\text{kNN}}^{\text{res}}(\mathbf{x}) = \left\| \mathbf{r}(\mathbf{x}) - \mathbf{r}(\mathbf{x}_{(k)}) \right\|.$$

4.4.3. Hiperparámetros de inferencia OOD

Las fórmulas anteriores quedan completamente determinadas una vez fijados los hiperparámetros de inferencia que se recogen en la Tabla 4.3, independientes del entrenamiento.

Tabla 4.3.: Hiperparámetros de inferencia OOD. k : vecinos en kNN; i^* : nivel de ruido para scores de nivel único y de residuos; N : pasos en scores multi-nivel; rango: fracción de la cadena cubierta; λ : regularización de la covarianza de Mahalanobis; PCA: reducción de dimensión previa a Mahalanobis cuando $D > 2048$; n_{ref} : tamaño máximo de la nube de referencia.

Parámetro	VAE	MLP-DDPM	UNet-DDPM
k (kNN)	5	1	1
i^*	—	100–200 ^a	100
N (pasos multi-nivel)	—	10	5
Rango multi-nivel	—	[10 %, 90 %] de $T=1\,000$	
λ (Mahalanobis)	10^{-5}	10^{-5}	10^{-5}
PCA (Mahalanobis)	256 ^b	—	—
n_{ref}	todos	todos	5 000

^a $i^*=150$ (sintéticos), $i^*=100$ (MNIST), $i^*=200$ (PathMNIST, SICAP).

^b Solo cuando la dimensión latente supera 2 048 (UNet-VAE sobre PathMNIST, con $D=12\,544$).

La configuración de los hiperparámetros se justifica de la siguiente manera:

- **Nivel de ruido (i^*):** Se establece dentro del rango [10 %–25 %] de la cadena recomendado por [GPT⁺23]. Se asignan valores superiores a los conjuntos histológicos (PathMNIST y SICAP) porque su alta complejidad semántica requiere mayor presión sobre el *denoiser* para evidenciar la degradación en muestras OOD.
- **Número de vecinos (k):** Depende del espacio operativo del modelo. En el espacio latente del VAE (de baja dimensión y regularizado por el término KL), se emplea $k=5$ para reducir la varianza de la estimación. En contraste, el espacio de residuos del DDPM presenta una alta dimensionalidad donde el vecino más cercano ya es discriminativo por sí solo [SMZL22], por lo que se usa $k=1$ para evitar la introducción de ruido.
- **Pasos multi-nivel (N):** Se fija $N=10$ para el MLP-DDPM tras observar la saturación del AUROC en el estudio de ablación (Tabla 5.16). Para la arquitectura UNet, este valor se reduce a $N=5$ por coste computacional.
- **Estimación de la covarianza y Mahalanobis:** Se añade un factor de regularización $\lambda=10^{-5}$ a la diagonal de la covarianza empírica antes de invertirla. Esto garantiza una matriz definida positiva cuando el número de muestras de referencia es comparable a la dimensión del espacio o ante direcciones de varianza casi nula. En la UNet-VAE sobre PathMNIST, dada la gran dimensión de su espacio latente (12 544), se aplica una reducción previa mediante PCA a 256 componentes para hacer tratable el cálculo.

4. Marco experimental

- **Muestras de referencia (n_{ref}):** En el modelo UNet-DDPM, el tamaño de la nube de referencia se limita a 5 000 muestras debido al alto coste de ejecutar la cadena inversa completa para cada elemento.

4.5. Métricas de evaluación

La evaluación de la capacidad de detección OOD se plantea como un problema de *ranking* binario: dado un *score* $S(\mathbf{x})$, se espera que las muestras ID reciban sistemáticamente valores más bajos que las muestras OOD. Se emplean tres métricas agnósticas al umbral, ampliamente consolidadas en la literatura de detección de distribuciones fuera de soporte [HG17, YZLL24]:

AUROC (Area Under the Receiver Operating Characteristic).

El AUROC mide la probabilidad de que una muestra OOD aleatoria reciba un *score* superior al de una muestra ID aleatoria. Su rango es $[0, 1]$: un valor de 1.0 denota separación perfecta y 0.5 corresponde a un discriminador aleatorio. Su invariancia al desbalanceo entre clases y su interpretación probabilística directa la convierten en la métrica principal de este trabajo, con la que se comparan y ordenan los distintos *scores* y configuraciones.

AUPR (Area Under the Precision-Recall Curve).

El AUPR resume la curva precisión-*recall* bajo la convención de que la clase positiva son las muestras OOD. A diferencia del AUROC, es sensible al desbalanceo entre clases: decrece cuando el conjunto OOD es minoritario, lo que la hace especialmente informativa en escenarios médicos donde el número de casos patológicos puede ser mucho menor que el de casos normales. Se reporta como métrica complementaria.

FPR@95TPR (False Positive Rate at 95 % TPR).

El FPR@95TPR mide la proporción de muestras ID clasificadas erróneamente como OOD cuando el umbral de decisión τ se fija de modo que el 95 % de las muestras OOD son detectadas correctamente. Se calcula localizando en la curva ROC el punto de cruce con $\text{TPR}=0.95$ y leyendo la FPR correspondiente. Valores bajos indican que el modelo puede mantener una alta tasa de detección con pocos falsos positivos sobre datos normales, lo que es especialmente relevante en aplicaciones clínicas con alto coste de alarmas falsas.

Análisis de umbrales.

Las métricas anteriores se complementan con un análisis de umbral operativo: dado un objetivo de FPR del 5 %, el umbral τ se calcula como el percentil 95 de los *scores* sobre *id_eval*. Se reportan la TPR y FPR efectivos al aplicar τ , lo que permite estimar el comportamiento del sistema en condiciones de mundo abierto, donde un umbral fijo debe balancear la tasa de detección con la tasa de falsas alarmas.

5. Resultados y discusión

Este capítulo presenta los resultados experimentales siguiendo la progresión de dificultad descrita en el capítulo 4: comienza con los conjuntos sintéticos como validación cualitativa del comportamiento esperado de los modelos, continúa con los conjuntos de imágenes MNIST y PathMNIST como puente entre el dominio controlado y el dominio real, y se concluye con SICAP como caso de aplicación de mayor relevancia clínica. Para cada conjunto se analizan primero las representaciones aprendidas (espacio latente para el VAE, reconstrucciones para el DDPM) y después las distribuciones de *scores* y las curvas ROC que cuantifican la capacidad de detección OOD. El capítulo cierra con un análisis comparativo entre los métodos generativos propuestos y las líneas base de distancia directa en el espacio de características, seguido de una discusión de las limitaciones del trabajo.

5.1. Resultados de los experimentos

5.2. Conjuntos sintéticos

Los conjuntos sintéticos proporcionan un entorno en el que el comportamiento esperado de los modelos ante anomalías puede verificarse visualmente: si un modelo generativo ha aprendido correctamente la distribución ID, sus reconstrucciones de muestras OOD deben diferir de las originales. Las figuras 5.1 y 5.2 muestran los espacios de entrada y reconstruido del VAE para Blobs y Moons, respectivamente, y las figuras 5.3 y 5.4 muestran el comportamiento análogo del DDPM.

Ambos modelos reconstruyen fielmente las muestras ID. Los mejores resultados cuantitativos correspondientes a estos conjuntos se recogen en la tabla 5.1, donde se evidencia numéricamente la separabilidad perfecta o casi perfecta en todos los *scores* evaluados. Para analizar todos los resultados véase la Sección A.1 del apéndice A. No obstante, esta separabilidad cuantitativa no se traduce, en general, en diferencias visuales apreciables en este tipo de espacios reconstruidos relativamente simples: en Blobs, tanto el VAE como el DDPM reconstruyen las muestras OOD con demasiada fidelidad, de modo que el efecto de atracción hacia la variedad aprendida apenas se percibe. En Moons, sucede algo similar con el VAE y es únicamente en Moons con el DDPM donde el comportamiento esperado se hace perfectamente visible: la proximidad geométrica entre ambas lunas hace que las reconstrucciones OOD queden retenidas en una región intermedia, sin llegar a ser absorbidas por la distribución ID.

5. Resultados y discusión




Figura 5.1.: Espacio de entrada y espacio reconstruido del VAE en *Blobs*.




Figura 5.2.: Espacio de entrada y espacio reconstruido del VAE en *Moons*.




Figura 5.3.: Espacio de entrada y espacio reconstruido del DDPM en *Blobs*.




Figura 5.4.: Espacio de entrada y espacio reconstruido del DDPM en *Moons*.

Tabla 5.1.: Comparación entre métodos en conjuntos de datos Toy (Blobs y Moons): mejores resultados para distancias de referencia y modelos generativos.

Método	Score	AUROC	AUPR	FPR@95 %
BLOBS				
KNN	–	0.6957	0.8785	0.7833
Mahalanobis	–	1.0000	1.0000	0.0000
VAE	ELBO	1.0000	1.0000	0.0000
DDPM	multi-step reconstruction	0.9982	0.9995	0.0000
MOONS				
KNN	–	0.8026	0.9444	0.9133
Mahalanobis	–	0.9064	0.9759	0.9600
VAE	latent k-nn	1.0000	1.0000	0.0000
DDPM	multi-step reconstruction	0.9712	0.9910	0.1567

5.2.1. Validación del entrenamiento y capacidad generativa

Habiendo validado los conjuntos sintéticos como caso de control, se examina a continuación si las arquitecturas han aprendido a modelar con fidelidad el soporte de los datos reales ID. Tras haber constatado la estabilidad de la optimización y la convergencia de las curvas

de entrenamiento en el capítulo 4, en esta sección se verifica cualitativamente que dicho ajuste matemático se traduce en una representación geométrica y estructural válida para los conjuntos de imagen.

Las proyecciones PCA y UMAP del espacio latente (figuras 5.5 y 5.6) ilustran la separabilidad que el modelo consigue en la representación interna. Para MNIST, la separación entre la nube ID y los puntos OOD es clara incluso en la proyección lineal PCA, lo que implica que los *scores* basados en distancia latente (k-NN y Mahalanobis) disponen de una representación discriminativa en la que apoyarse. Para PathMNIST, las nubes ID y OOD presentan mayor solapamiento en las proyecciones latentes, lo que anuncia valores de AUROC más moderados para los *scores* basados en la geometría del espacio latente. Los resultados numéricos completos para MNIST y PathMNIST se recogen en el apéndice A.




Figura 5.5.: Espacio latente del VAE en MNIST (proyecciones PCA y UMAP) con datos ID y OOD superpuestos.




Figura 5.6.: Espacio latente del VAE en PathMNIST (proyecciones PCA y UMAP).

Por otra parte, las figuras 5.7 y 5.8 ilustran la trayectoria del proceso de *denoising* inverso incondicional en los modelos de difusión, partiendo de ruido gaussiano puro ($t = T$) hasta la generación de la muestra final ($t = 0$). Como se puede observar, el modelo DDPM es capaz de moldear progresivamente el ruido determinista para sintetizar dígitos manuscritos nítidos y realistas en MNIST (figura 5.7), así como texturas celulares morfológicamente coherentes en PathMNIST (figura 5.8).

5. Resultados y discusión




Figura 5.7.: Trayectoria de *denoising* inverso incondicional del DDPM en MNIST desde ruido puro. El modelo modela progresivamente la estructura hasta sintetizar un dígito realista de la distribución ID.




Figura 5.8.: Trayectoria de *denoising* inverso incondicional del DDPM en PathMNIST desde ruido puro. El modelo es capaz para generar patrones de textura histopatológica relativamente coherentes.

5.2.2. MNIST/SVHN y PathMNIST: VAE

Una vez validada la consistencia de las arquitecturas, se evalúa su comportamiento como detectores de anomalías. Las figuras 5.9 y 5.10 muestran muestras originales y reconstruidas por el VAE para MNIST/SVHN y PathMNIST respectivamente. Para MNIST, las reconstrucciones de dígitos ID son limpias y nítidas, mientras que las imágenes OOD (SVHN) se reconstruyen con mayor emborronamiento y pérdida de detalle, inclusive presentando algunas características generales de MNIST. En efecto, este comportamiento es esperable dado que el modelo ha aprendido a parametrizar y muestrear la distribución de los datos de entrenamiento y, por tanto, al procesar entradas desconocidas tiende de forma natural a intentar reproducir los rasgos visuales propios de dicha distribución.

Para PathMNIST (figura 5.10), las diferencias entre las reconstrucciones ID y OOD son más sutiles: ambas presentan una calidad visual similar, lo que anticipa que el *score* de reconstrucción MSE por sí solo puede ser insuficiente para discriminar ambas distribuciones. De hecho, se manifiesta claramente una limitación característica de los VAE: su capacidad para reconstruir con éxito imágenes que nunca han visto. Esto ocurre porque el modelo tiende a aprender regularidades estadísticas y patrones globales de la imagen (como colores, formas o texturas de bajo nivel) en lugar de abstraer información verdaderamente semántica. La mayor dificultad de este dominio respecto a MNIST se origina en que los tejidos ID y OOD (mucosa normal, estroma y epitelio tumoral) comparten patrones de textura a escalas intermedias que son difícilmente capturables con un espacio latente de dimensión acotada.

El rendimiento cuantitativo de todos los *scores* del VAE, así como del DDPMm se detalla en las tablas 5.3 y 5.5 para los conjuntos MNIST/SVHN y PathMNIST, respectivamente.




Figura 5.9.: Muestras originales y reconstruidas por el VAE en MNIST/SVHN.




Figura 5.10.: Muestras originales y reconstruidas por el VAE en PathMNIST (tejido normal ID frente a tumoral OOD).

5.2.3. MNIST/SVHN y PathMNIST: DDPM

A diferencia de los VAE, que comprimen la información en un cuello de botella estático, los modelos de difusión evalúan la anomalía a través de un proceso iterativo de degradación y restauración temporal controlada. Las figuras 5.11 y 5.12 muestran la reconstrucción a distintos niveles de corrupción t para una muestra ID y una OOD de cada conjunto: se añade ruido hasta el instante t y se ejecuta la cadena inversa paso a paso hasta $t = 0$.

Para MNIST, incluso a valores de t moderados la muestra ID se reconstruye fielmente, mientras que la muestra SVHN (OOD) acumula un error creciente a medida que aumenta la corrupción. El proceso de *denoising* es incapaz de recuperar los rasgos fotorrealistas del dígito SVHN original porque el modelo nunca los ha integrado en su soporte distribucional; en su lugar, el decodificador fuerza la proyección del resultado hacia patrones manuscritos ID conocidos. Este comportamiento ilustra visualmente el mecanismo básico del *scoring* en difusión: al no poder guiar la trayectoria hacia la anomalía exacta, la divergencia o residuo entre la reconstrucción final aproximada y la entrada original actúa eficazmente como señal métrica de anomalía.

5. Resultados y discusión

Para PathMNIST (figura 5.12), la diferencia visual en las reconstrucciones supervisadas entre ID y OOD es sensiblemente más sutil. Esto es perfectamente consistente con la proximidad estadística y las regularidades de textura de bajo nivel compartidas por los tejidos biológicos implicados, lo que de antemano sugiere una frontera de decisión mucho más compleja para los descriptores basados en el espacio de píxeles. Los resultados cuantitativos de todas las variantes de *score* del VAE y del DDPM se recogen, como hemos comentado anteriormente, en las tablas 5.3 y 5.5. Para analizar todos los resultados véanse la Sección A.2 y Sección A.3 del apéndice A, respectivamente.




Figura 5.11.: Reconstrucción iterativa controlada del DDPM a distintos niveles de corrupción t para una muestra MNIST (ID) y una SVHN (OOD).




Figura 5.12.: Reconstrucción iterativa controlada del DDPM a distintos niveles de corrupción t para una muestra PathMNIST normal (ID) y tumoral (OOD).

Tabla 5.3.: Comparación entre métodos en MNIST: mejores resultados para distancias de referencia y modelos generativos.

Método	Score	AUROC	AUPR	FPR@95 %
MNIST				
KNN	–	0.9105	0.9382	0.6460
Mahalanobis	–	1.0000	1.0000	0.0000
VAE	ELBO	1.0000	1.0000	0.0000
DDPM	residual k-nn	1.0000	1.0000	0.0000

Tabla 5.5.: Comparación entre métodos en PathMNIST (clases C1 y C2): mejores resultados para distancias de referencia y modelos generativos.

Método	Score	AUROC	AUPR	FPR@95 %
PATHMNIST_C1				
KNN	–	0.6510	0.7225	0.9595
Mahalanobis	–	0.2345	0.4536	1.0000
VAE	reconstruction error	0.7140	0.8305	0.9109
DDPM	single-step noise prediction	0.6518	0.7766	0.9861
PATHMNIST_C2				
KNN	–	0.7641	0.6676	0.5860
Mahalanobis	–	0.5729	0.5771	0.8860
VAE	reconstruction error	0.5872	0.4752	0.7818
DDPM	residual mahalanobis	0.6163	0.5628	0.7013

5.2.4. SICAP: resultados del mejor experimento por conjunto

SICAP es, junto con PathMNIST, el conjunto de mayor dificultad y relevancia clínica de los estudiados. Los resultados que se presentan a continuación corresponden a la configuración con mayor AUROC de validación para cada combinación de modelo y conjunto (C1 o C12), tal y como se recoge en las macros definidas al inicio del capítulo. La comparación sistemática entre todas las configuraciones se presenta en la sección 5.3.

VAE en SICAP.

La estructura y el comportamiento de los *scores* OOD del VAE se examinan visualmente en la Figura 5.13. En ella se representan las distribuciones sobre los conjuntos *id_eval* y *ood_eval* para el error de reconstrucción (MSE), el ELBO, el *k*-NN latente y la distancia de Mahalanobis latente.

Más allá de la inspección visual, el rendimiento cuantitativo de estos métodos se detalla a través de los valores AUROC recogidos en la Tabla A.4 del Apéndice. Al contrastar ambos

5. Resultados y discusión

análisis, se hace evidente que los *scores* basados en el espacio latente (k -NN y Mahalanobis) alcanzan una capacidad discriminativa muy cercana a la de los calculados en el espacio de píxeles (MSE y ELBO). Esto refleja que el espacio latente del VAE logra capturar la estructura distribucional de la ID de una manera significativamente más compacta que el espacio de entrada.

En cuanto a los resultados sobre SICAP_C12, se observa que el ensanchamiento de la distribución ID (causado por la inclusión de Gleason 2 en el entrenamiento) tiende a mitigar la separación respecto a las muestras OOD (Gleason 3–4), ya que la discrepancia estadística entre ambas distribuciones disminuye. No obstante, en ciertos *scores*, esta mayor cobertura del espacio de normalidad permite al modelo consolidar una representación latente más rica, lo que en última instancia potencia su habilidad para discriminar anomalías de alto grado.




Figura 5.13.: Distribución de los *scores* OOD evaluados con el modelo VAE para los conjuntos SICAP_C1 y SICAP_C12. Las gráficas muestran la separación entre las distribuciones In-Distribution (ID) y Out-of-Distribution (OOD).

DDPM en SICAP.

De manera análoga, la Figura 5.14 agrupa las distribuciones correspondientes a los siete *scores* derivados del DDPM para ambos datasets, mientras que sus métricas numéricas se encuentran indexadas en la misma Tabla A.4 del Apéndice.

Por un lado, las métricas basadas en la predicción del ruido incluyen el *score single-step* MSE, que cuantifica el error en un único instante fijo t^* . Se trata de la alternativa más liviana en términos computacionales, aunque su eficacia final queda supeditada a la elección de dicho instante. Para mitigar esta sensibilidad, sus variantes *multi-step* (MSE y coseno) promedian el error normalizado por z -score a lo largo de $T=10$ instantes de tiempo distribuidos uniformemente entre el 10 % y el 90 % del rango $[1, T_{\max}]$, aportando una estimación sustancialmente más robusta de la condición de anomalía.

Adicionalmente, se evalúa el error de reconstrucción en el espacio original de la imagen (*recon single-step* y *recon multi-step*). De forma equivalente a los *scores* de ruido, estas métricas examinan la fidelidad con la que el modelo es capaz de restaurar la muestra original a partir de su versión ruidosa (ya sea en un solo instante o integrando múltiples pasos), ofreciendo una perspectiva visual directa del grado de anomalía que resulta fácilmente equiparable al MSE del VAE.

Por último, los enfoques fundamentados en el residuo de predicción de ruido (Mahalanobis y k -NN) evalúan la desviación del residuo ($\hat{\epsilon} - \epsilon$) frente a la distribución de referencia aprendida durante el entrenamiento. Estos resultan especialmente ventajosos cuando el DDPM incurre en errores de naturaleza sistemáticamente distinta al procesar muestras OOD.

5. Resultados y discusión




Figura 5.14.: Distribución de los *scores* OOD evaluados con el modelo DDPM para los conjuntos SICAP_C1 y SICAP_C12.

5.3. Análisis comparativo entre métodos

La tabla 5.7 y la figura 5.15 comparan el AUROC del mejor experimento de cada familia de métodos en SICAP_C1 y SICAP_C12. Para analizar todos los resultados véase la Sección A.4 del apéndice A. Todos operan sobre la misma representación de entrada (características UNI de dimensión 1024), lo que permite aislar la contribución del modelo generativo respecto a los métodos de distancia directa (k-NN y Mahalanobis sobre features crudas), que actúan como línea base sin entrenamiento adicional.

En SICAP_C1, el VAE obtiene el mejor AUROC con el *score* ELBO (0.855 ± 0.003), seguido del DDPM con el mejor *score* multi-paso (0.840 ± 0.010). La distancia de Mahalanobis directa alcanza 0.835, a apenas tres puntos del DDPM. En SICAP_C12, todos los métodos mejoran de forma similar al ampliarse la clase ID, y el mejor *score* del DDPM ahora pasa a ser *multi-step reconstruction*, con 0.856 ± 0.002 . También aumenta el mejor *score* del VAE, el ELBO, hasta 0.8640 ± 0.0002 . La varianza entre semillas es baja en todos los casos, lo que indica que los resultados son robustos a la inicialización.

En conjunto, los modelos generativos no superan muy notablemente a los métodos de distancia directa (a k -NN sí, pero a Mahalanobis no) de forma consistente: la ganancia existe pero es pequeña y depende del conjunto y del modo de puntuación. Esto sugiere que las características UNI ya codifican una estructura de normalidad suficientemente compacta como para que las distancias directas sean competitivas, y que el valor añadido del modelo generativo reside principalmente en la variedad de *scores* que ofrece más que en una discriminabilidad por arquitectura significativamente mayor.

Tabla 5.7.: Comparación entre métodos en SICAP (clases C1 y C12): mejores resultados para distancias de referencia y modelos generativos.

Método	Score	AUROC	AUPR	FPR@95 %
SICAP_C1				
KNN	–	0.6848	0.8440	0.7735
Mahalanobis	–	0.8348	0.9291	0.6158
VAE	ELBO	0.8553	0.9406	0.5912
DDPM	residual mahalanobis	0.8399	0.9360	0.6489
SICAP_C12				
KNN	–	0.6146	0.1989	0.7608
Mahalanobis	–	0.8545	0.5876	0.6051
VAE	ELBO	0.8640	0.5992	0.4997
DDPM	multi-step reconstruction	0.8555	0.5712	0.5455




Figura 5.15.: AUROC medio por método en SICAP_C1 y SICAP_C12.

Ablación sobre el número de pasos de puntuación T .

Una de las variables de diseño más relevantes para el DDPM es el número de instantes T

5. Resultados y discusión

sobre los que se promedia el error normalizado en los modos *multi-step*. Incrementar T proporciona una estimación más robusta de la anomalía al integrar información de un mayor rango del proceso de difusión, pero aumenta el coste computacional de la evaluación en un factor T respecto al modo *single-step*. La tabla 5.9 y la figura 5.16 muestran el AUROC en función de T para los *scores* del DDPM (S_{single} , $S_{\text{multi-noise}}$, $S_{\text{multi-cos}}$) en SICAP_C1 y SICAP_C12.

Los resultados revelan que la ganancia de AUROC al pasar de $T=1$ a $T=10$ es notable en los modos *multi-step*, mientras que incrementos adicionales ($T>10$) producen mejoras marginales que difícilmente justifican el coste computacional añadido. Esta saturación sugiere que los primeros $T=10$ pasos ya capturan la mayor parte de la información discriminativa disponible en el proceso de difusión. El modo *single-step* es insensible a T por definición y sirve como referencia de eficiencia computacional mínima.

Tabla 5.9.: Ablación del número de pasos de puntuación T del DDPM en SICAP_C1 y SICAP_C12. Mejor AUROC por fila en **negrita** (excepto filas de valor único).

Score Mode	$T = 1$	$T = 5$	$T = 10$	$T = 25$	$T = 50$
SICAP_C1					
Noise Single-step	0.8053 ± 0.0450	–	–	–	–
Noise Multi-step MSE	–	0.8225	0.7789 ± 0.0676	0.8297	0.8303
Noise Multi-step Cosine	–	0.4719	0.4719	0.4719	0.4719
Recon Single-step	0.8071 ± 0.0013	–	–	–	–
Recon Multi-step	–	0.8168	0.8147 ± 0.0055	0.8200	0.8195
SICAP_C12					
Noise Single-step	0.8376 ± 0.0018	–	–	–	–
Noise Multi-step MSE	–	0.8380	0.8377 ± 0.0060	0.8449	0.8453
Noise Multi-step Cosine	–	0.5581	0.5487 ± 0.0149	0.5594	0.5595
Recon Single-step	0.8507 ± 0.0009	–	–	–	–
Recon Multi-step	–	0.8540	0.8551 ± 0.0024	0.8543	0.8547




Figura 5.16.: AUROC en función del número de pasos de puntuación T del DDPM.

5.4. Análisis de dificultades y limitaciones

El recorrido experimental descrito en este capítulo ha estado marcado por una escalada progresiva de dificultad que ha puesto de manifiesto tanto las capacidades como los límites del enfoque propuesto.

Transferencia del MLP a imágenes y necesidad de arquitecturas espaciales. La selección de la arquitectura adecuada para cada dominio de datos representó un desafío metodológico clave. Por un lado, las redes MLP resultaron ser la arquitectura idónea para procesar los vectores de características de SICAP. Pero, sin embargo, su extensión a imágenes complejas demostró limitaciones inherentes a su diseño: aplicar un MLP a PathMNIST requiere aplanar las muestras a representaciones de 150 528 dimensiones, lo que destruye completamente la estructura espacial de la imagen histológica e impide que el modelo aprenda una distribución ID coherente. Esta dificultad evidenció la necesidad de adoptar arquitecturas convolucionales como la UNet para el tratamiento en el dominio del píxel, ya que logran preservar la localidad espacial de las características. Por ello, la aplicación del enfoque MLP sobre imágenes (tanto en MNIST como en PathMNIST) se incluye tan solo como un ejercicio didáctico para ilustrar esta limitación.

Resolución como factor crítico en el problema de la inversión OOD. Incluso con la arquitectura UNet, la resolución de entrada resultó ser un factor determinante. A resoluciones de 28, 64 o 128 píxeles, PathMNIST no proporcionaba suficiente información semántica para discriminar correctamente entre tejido benigno y maligno, y se observó un fenómeno de *inversión del detector OOD*. Esto es, que las muestras malignas, visualmente más homogéneas a baja resolución, obtenían errores de reconstrucción menores que las benignas, revirtiendo el orden esperado de los *scores*. Este comportamiento es plenamente consistente con los hallazgos de [SÁG⁺20], quienes demostraron que los modelos generativos tienden a asignar un menor error de reconstrucción a muestras OOD si estas presentan una menor complejidad espacial o mayor homogeneidad visual. Tras un análisis de entropía por resolución se pudo diagnosticar este problema originado por la falta de detalle en la textura, lo que justificó el escalado a 224×224 píxeles. Incluso con esta resolución, los resultados en PathMNIST son mediocres, lo que apunta a una limitación del modelo para dicho experimento.

De la separación evidente al OOD semánticamente complejo. Los experimentos iniciales con datos sintéticos y MNIST operan deliberadamente en un escenario *far-OOD* con una separación distribucional clara, cumpliendo un propósito ilustrativo. En el caso de PathMNIST, sin embargo, operar directamente en el dominio visual supone un desafío mucho mayor: las diferencias entre tejidos benignos y malignos a nivel de píxel carecen de una correspondencia semántica limpia, lo que provoca que los modelos generativos consuman su capacidad captando artefactos superficiales (como variaciones de color o tinción) en lugar de la estructura patológica subyacente. Frente a esto, el experimento sobre SICAP, objeto central de este trabajo, plantea un escenario de evaluación más representativo. Gracias al uso de las características UNI, se logra abstraer la variabilidad del dominio visual puro, permitiendo evaluar la capacidad de detección OOD del modelo generativo de manera aislada y sobre un espacio puramente semántico.

Coste de evaluación y métricas excluidas. Independientemente del coste de entrenamiento, los *scores* basados en trayectorias de denoising completas (*recon_single* y *recon_multi*) resultaron computacionalmente prohibitivos en evaluación a resolución 224×224 (del orden de días por configuración) y debieron excluirse del análisis del UNet-DDPM. El inconveniente es que estas métricas habían demostrado sistemáticamente mejores resultados con respecto al resto en otros experimentos donde su cálculo sí era asumible, si bien el error de predicción de ruido siempre se ha mantenido como una alternativa competitiva. Su uso como sustituto en PathMNIST no compromete, por tanto, la validez del análisis de forma sustancial. Esta exclusión forzada motiva, una vez más, el uso de un modelo fundacional como extractor de características, pues así todos los *scores* de evaluación vuelven a ser computacionalmente viables.

Número de clases ID y tamaño del conjunto de entrenamiento en SICAP. La comparación entre SICAP_C1 y SICAP_C12 muestra una mejora en AUROC al ampliar el conjunto ID de una a dos clases de Gleason. Una interpretación plausible es que disponer de más variedad de clases permite al modelo construir una noción de normalidad más rica y generalizable. Sin embargo, esta mejora debe interpretarse con cautela, pues no es descartable que con un volumen de datos mayor (especialmente, de clase Gleason 1) se diera el mismo efecto (sin incluir la clase Gleason 2 como ID) de construir una noción de normalidad satisfactoria. Con los conjuntos actuales, la diferencia entre ambas configuraciones no es lo suficientemente grande como para ser concluyente en este sentido.

¿Por qué el VAE supera al DDPM en espacio de características? En espacio de píxeles el orden habitual es el inverso. El DDPM suele modelar distribuciones de imágenes con mayor fidelidad gracias a su proceso iterativo de *denoising*, mientras que el VAE tiende a producir reconstrucciones borrosas al promediar sobre la distribución posterior. Sin embargo, la entrada que reciben los modelos en este trabajo no son píxeles sino *embeddings* de características, resultando que dicho cambio de dominio invierte el resultado. Las características de un modelo fundacional ya abstraen y comprimen la información semántica de la imagen, de modo que la distribución resultante es mucho más compacta que la de píxeles en bruto. Bajo estas condiciones, la ventaja del DDPM desaparece. Es decir, su capacidad para modelar distribuciones complejas y multimodales resulta innecesaria y el coste de indirección de sus *scores* pasa a ser una desventaja, pues miden el error de predicción de ruido a instantes concretos y no la verosimilitud marginal directamente. El VAE, en cambio, dispone del ELBO como señal de densidad directa, que penaliza simultáneamente las muestras difíciles de reconstruir y las que se alejan de la distribución latente aprendida. El DDPM demuestra su potencial cuando la distribución a modelar es genuinamente compleja, pero cuando el espacio ya ha sido simplificado por un extractor de rasgos especializado, el VAE ofrece una señal OOD más directa y limpia.

¿Merece la pena el modelo generativo frente a la distancia de Mahalanobis? La distancia de Mahalanobis calculada directamente sobre los *embeddings* de características (tan solo ajustando la media y la covarianza del conjunto ID), resulta competitiva con el DDPM y queda a apenas dos puntos del mejor *score* del VAE. Esta observación plantea una pregunta razonable sobre el retorno de la inversión en complejidad. Si el único criterio es maximizar el AUROC con el mínimo coste computacional, la distancia de Mahalanobis sobre características de un modelo fundacional es difícil de superar. Sin embargo, los modelos generativos apor-

tan un valor añadido que va más allá del AUROC puro: ofrecen una diversa variedad de *scores* y permiten visualizar e interpretar las reconstrucciones. Por otra parte, el hecho de que Mahalanobis sea tan competitivo es, en sí mismo, un resultado relevante. Indica que las características UNI codifican la normalidad histológica con una estructura suficientemente compacta como para que una distancia estadística simple sea ya altamente discriminativa, y que el modelo generativo refina este resultado más que construirlo desde cero.

Reflexión metodológica. Si bien el propósito central del trabajo era abordar el problema de mayor complejidad (SICAP), la lección aprendida fue la importancia de validar las hipótesis en entornos controlados antes de escalar. De esta forma, se planificó la estrategia como una escalada progresiva de dificultad: desde los conjuntos sintéticos, transitando por conjuntos de *benchmarking* como MNIST y PathMNIST, y así, hasta alcanzar SICAP como objetivo definitivo. En retrospectiva, esta decisión fue acertada, ya que cada nivel del espectro de dificultad aportó intuición, herramientas y confianza que se trasladaron al siguiente. Del mismo modo, aunque la modularización del proyecto ha sido una preocupación central desde el principio, el esfuerzo de una arquitectura de código sólida siempre supera las estimaciones iniciales y es muy fácil minusdimensionarla, por lo que invertiría más tiempo si cabe en su diseño y planificación inicial.

6. Conclusiones y trabajo futuro

6.1. Conclusiones

Este trabajo ha abordado la detección de anomalías semántica en imágenes médicas mediante modelos generativos variacionales, concretamente los *Variational Autoencoders* (VAE) y los *Denoising Diffusion Probabilistic Models* (DDPM). La hipótesis de partida fue que un modelo generativo entrenado exclusivamente con datos en distribución (ID) podría actuar como detector de anomalías fuera de distribución (OOD) al explotar el error de reconstrucción o la geometría del espacio latente como señal discriminativa, sin necesidad de etiquetas ni de muestras OOD durante el entrenamiento. Los resultados obtenidos permiten aceptar dicha hipótesis de forma matizada.

En todos los escenarios analizados, desde los conjuntos sintéticos hasta el dataset clínico SICAP, los modelos generativos exhiben el comportamiento esperado. Estos actúan como atractores hacia la variedad ID aprendida, de modo que las reconstrucciones de muestras OOD difieren sistemáticamente de las originales y los *scores* derivados de esa diferencia permiten discriminar entre muestras sanas y patológicas (con niveles de AUROC que oscilan entre moderados y notables). Sin embargo, la distancia de Mahalanobis calculada directamente sobre las mismas características, sin ningún entrenamiento generativo adicional, alcanza un AUROC comparable en SICAP, lo que acota la ganancia real del enfoque propuesto. La hipótesis se confirma, pero el margen de mejora no es tan amplio como cabría esperar y depende tanto del espacio de representación elegido como del *score* concreto que se emplee.

La primera y más importante lección aprendida es que la representación de entrada condiciona el resultado de forma más determinante que la elección del modelo generativo. Cuando la distribución ID se comprime en vectores de características de un modelo fundamental especializado (UNI, en este trabajo), la estructura semántica queda tan condensada que incluso una distancia estadística básica resulta altamente discriminativa. Bajo estas condiciones, el valor añadido del modelo generativo radica principalmente en la diversidad de señales de detección que ofrece y en la posibilidad de interpretar visualmente las reconstrucciones, más que en un salto cuantitativo de rendimiento.

La segunda lección concierne al comportamiento propio de cada uno de los dos modelos generativos estudiados en función del espacio de entrada. En el espacio de características compactas, el VAE supera al DDPM en todos los escenarios estudiados, aunque por un margen reducido. Este resultado es contraintuitivo si se parte de la experiencia habitual en el dominio de las imágenes en bruto, donde el DDPM modela distribuciones complejas con mayor fidelidad. La explicación reside en que, cuando la distribución de entrada es ya compacta y estructurada, la ventaja expresiva del proceso iterativo de *denoising* desaparece, y el ELBO del VAE (que penaliza simultáneamente el error de reconstrucción y la divergencia respecto a la distribución latente) se convierte en una señal OOD más directa y limpia. En el escenario de SICAP, el *score* ELBO del VAE alcanzó 0.855 ± 0.003 en la configuración C1 y 0.864 ± 0.0002 en C12, siendo el mejor *score* en ambos casos.

En cuanto a los modelos de difusión, se concluye que la formulación *multi-step* norma-

6. Conclusiones y trabajo futuro

lizada mediante *z-score* resulta más robusta y tiende a superar a la variante *single-step*. Al agregar la señal de error sobre múltiples niveles de corrupción, se mitiga la sensibilidad a un instante de evaluación concreto, proporcionando una estimación de anomalía más estable. Concretamente, los experimentos de ablación demostraron que la mayor ganancia de rendimiento se produce al aumentar de $T=1$ a $T=10$ pasos, punto a partir del cual el modelo se satura. Esto establece una pauta clara y un compromiso óptimo entre capacidad de detección y coste computacional.

Desde un punto de vista metodológico más amplio, el trabajo ha puesto de manifiesto que la escalada progresiva de dificultad (desde los conjuntos sintéticos hasta el escenario clínico más complejo) no es solo una estrategia pedagógica sino un procedimiento de validación indispensable. Cada nivel del espectro de dificultad aportó información cualitativa difícil de obtener de otra forma: los conjuntos sintéticos confirmaron el mecanismo de atracción hacia la variedad ID; MNIST proporcionó un escenario intermedio con separación clara en el espacio latente; y PathMNIST reveló que la resolución de la imagen no es un detalle de implementación sino un parámetro con impacto semántico directo sobre el comportamiento del detector. En particular, la inversión del *score* OOD observada a bajas resoluciones en PathMNIST (donde las muestras malignas obtenían errores de reconstrucción menores que las benignas) ilustra un riesgo real que debe verificarse explícitamente antes de confiar en los resultados de AUROC.

La elección de la arquitectura debe respetar el dominio de representación de los datos, y el error puede cometerse en ambas direcciones. Aplicar un MLP a imágenes histológicas aplanadas destruye la estructura espacial que el modelo necesita para aprender una distribución ID coherente; pero aplicar una U-Net convolucional a vectores de características unidimensionales como los de UNI supondría el error simétrico, es decir, imponer un sesgo inductivo espacial sobre una representación que no tiene estructura bidimensional. La elección de arquitectura no es, por tanto, independiente del espacio sobre el que opera el modelo. Del mismo modo, la línea base de Mahalanobis sobre características crudas (0.835 en SICAP-C1) recuerda que, cuando se dispone de un buen extractor de características, conviene establecer primero este *baseline* y cuantificar qué ganancia aporta el modelo generativo antes de asumir que la complejidad adicional está justificada.

En conjunto, los modelos generativos variacionales son una opción razonable para la detección OOD en imágenes médicas cuando se combinan con una representación de entrada adecuada. Su principal aportación frente a los métodos de distancia directa no es tanto una ventaja sistemática en AUROC como la variedad de distintos *OOD scores* que ofrece cada modelo y la posibilidad de inspeccionar qué aspectos de cada muestra no reconoce como propios de la distribución de entrenamiento. La hipótesis de partida se confirma, con la aclaración de que el rendimiento final depende tanto de la calidad del extractor de características como del *score* elegido, y que estos dos factores merecen tanta atención como el propio modelo generativo.

6.2. Trabajo futuro

A continuación, varias líneas quedan abiertas a partir de los resultados obtenidos.

En primer lugar, resultaría valioso comparar sistemáticamente distintos modelos fundacionales como extractores de características sobre los mismos conjuntos y arquitecturas generativas. En histopatología existen modelos orientados al alineamiento visión-lenguaje, como CONCH [LCW⁺24] o PLIP [HBY⁺23], cuyas representaciones podrían ofrecer mayor sepa-

rabilidad ID/OOD para tejidos específicos que un modelo de propósito general como UNI. Dado que la calidad de la representación de entrada resultó ser el factor más determinante del rendimiento, esta comparación permitiría cuantificar hasta qué punto los resultados obtenidos dependen de la elección del extractor.

Otra dirección interesante a investigar es la combinación de los distintos *scores* estudiados o inclusive, de otros no estudiados como los de tipo perceptual. Explorar fusionadores calibrados sobre estos *scores* podría mejorar la robustez del detector sin requerir reentrenamiento, siempre que la fusión se diseñe de forma que no comprometa la independencia respecto a las clases OOD de evaluación.

También sería interesante analizar si las diferencias entre la reconstrucción y la muestra original se concentran en las regiones morfológicamente relevantes: núcleos tumorales, cambios en la arquitectura glandular, densidad celular. En ese caso, el mapa de error podría servir como señal auxiliar de localización de la anomalía, aunque la dificultad de validar este tipo de análisis sin anotaciones espaciales de referencia es considerable.

Desde el punto de vista de la evaluación, los conjuntos utilizados provienen de entornos controlados o de un único centro, por lo que una extensión natural sería probar el sistema con datos multicéntricos, donde el *cambio covariable* entre protocolos de tinción o escáneres introduzca variabilidad adicional que puede confundirse con señal OOD. Por último, el *cambio contextual*, es decir, la introducción de imágenes de modalidades o regiones anatómicas distintas a las del entrenamiento, es un escenario que podría resultar relativamente sencillo para el sistema, dado que estas imágenes difieren radicalmente de la distribución ID. Sin embargo, distinguirlo del cambio semántico intrínseco sigue siendo un problema abierto cuya dificultad no debe subestimarse.

A. Resultados cuantitativos completos

Las tablas siguientes recogen los resultados de los mejores experimentos por familia de modelos: para MNIST, resultados del UNet; para SICAP, resultados del MLP. Las columnas recogen AUROC, AUPR y FPR@95 % (media $\pm$ desviación típica). El mejor AUROC de cada grupo aparece en **negrita**.

A.1. Toy: Blobs y Moons

Tabla A.1.: Resultados completos en Toy: AUROC, AUPR y FPR@95 % (media $\pm$ desv. típica). Mejor AUROC por grupo en **negrita**.

Método	LR	Score	AUROC	AUPR	FPR@95 %
BLOBS					
Baselines					
KNN	–	–	0.6957	0.8785	0.7833
Mahalanobis	–	–	1.0000	1.0000	0.0000
VAE					
VAE	0.001	ELBO	1.0000	1.0000	0.0000
VAE	0.001	latent k-nn	1.0000	1.0000	0.0000
VAE	0.001	latent mahalanobis	1.0000	1.0000	0.0000
VAE	0.001	reconstruction error	0.9734	0.9920	0.1333
DDPM					
DDPM	0.001	multi-step cosine noise pred.	0.7217	0.8987	0.8167
DDPM	0.001	multi-step noise prediction	0.9765	0.9936	0.2700
DDPM	0.001	multi-step reconstruction	0.9982	0.9995	0.0000
DDPM	0.001	residual k-nn	0.7092	0.8955	0.8800
DDPM	0.001	residual mahalanobis	0.5391	0.8097	0.9367
DDPM	0.001	single-step noise prediction	0.5685	0.8371	0.9533
DDPM	0.001	single-step reconstruction	0.5668	0.8213	0.9533
MOONS					
Baselines					
KNN	–	–	0.8026	0.9444	0.9133
Mahalanobis	–	–	0.9064	0.9759	0.9600
VAE					
VAE	0.001	ELBO	0.9942	0.9986	0.0000
VAE	0.001	latent k-nn	1.0000	1.0000	0.0000
VAE	0.001	latent mahalanobis	0.9041	0.9751	0.9033
VAE	0.001	reconstruction error	0.9991	0.9997	0.0067
DDPM					
DDPM	0.001	multi-step cosine noise pred.	0.6560	0.8783	0.8600
DDPM	0.001	multi-step cosine noise pred.	0.6849	0.8910	0.8267
DDPM	0.001	multi-step noise prediction	0.9257	0.9682	0.3033
DDPM	0.001	multi-step noise prediction	0.9313	0.9801	0.3767
DDPM	0.001	multi-step reconstruction	0.9586	0.9853	0.1867
DDPM	0.001	multi-step reconstruction	0.9712	0.9910	0.1567

Continúa en la siguiente página

6. Conclusiones y trabajo futuro

Método	LR	Score	AUROC	AUPR	FPR@95 %
DDPM	0.001	residual k-nn	0.8813	0.9633	0.6367
DDPM	0.001	residual k-nn	0.8860	0.9674	0.7300
DDPM	0.001	residual mahalanobis	0.9094	0.9713	0.4200
DDPM	0.001	residual mahalanobis	0.8922	0.9687	0.6767
DDPM	0.001	single-step noise prediction	0.8989	0.9661	0.4367
DDPM	0.001	single-step noise prediction	0.8814	0.9655	0.6833
DDPM	0.001	single-step reconstruction	0.9263	0.9742	0.4200
DDPM	0.001	single-step reconstruction	0.9156	0.9750	0.4933

A.2. MNIST

Tabla A.2.: Resultados completos en MNIST (UNet): AUROC, AUPR y FPR@95 % (media $\pm$ desv. típica). Mejor AUROC por grupo en **negrita**.

Método	LR	Score	AUROC	AUPR	FPR@95 %
MNIST					
Baselines					
KNN	–	–	0.9105	0.9382	0.6460
Mahalanobis	–	–	1.0000	1.0000	0.0000
VAE					
VAE	0.0001	ELBO	1.0000 $\pm$ 0.0000	1.0000 $\pm$ 0.0000	0.0000 $\pm$ 0.0000
VAE	0.0001	latent k-nn	1.0000 $\pm$ 0.0000	1.0000 $\pm$ 0.0000	0.0000 $\pm$ 0.0000
VAE	0.0001	latent mahalanobis	1.0000 $\pm$ 0.0000	1.0000 $\pm$ 0.0000	0.0000 $\pm$ 0.0000
VAE	0.0001	reconstruction error	1.0000 $\pm$ 0.0000	1.0000 $\pm$ 0.0000	0.0000 $\pm$ 0.0000
VAE	0.0005	ELBO	1.0000 $\pm$ 0.0000	1.0000 $\pm$ 0.0000	0.0000 $\pm$ 0.0000
VAE	0.0005	latent k-nn	0.9962 $\pm$ 0.0031	0.9968 $\pm$ 0.0025	0.0078 $\pm$ 0.0071
VAE	0.0005	latent mahalanobis	1.0000 $\pm$ 0.0000	1.0000 $\pm$ 0.0000	0.0000 $\pm$ 0.0000
VAE	0.0005	reconstruction error	1.0000 $\pm$ 0.0000	1.0000 $\pm$ 0.0000	0.0000 $\pm$ 0.0000
DDPM					
DDPM	0.0001	multi-step cosine noise pred.	0.8554 $\pm$ 0.0282	0.8782 $\pm$ 0.0273	0.7407 $\pm$ 0.0146
DDPM	0.0001	multi-step noise prediction	0.9998 $\pm$ 0.0002	0.9998 $\pm$ 0.0002	0.0000 $\pm$ 0.0000
DDPM	0.0001	multi-step reconstruction	1.0000 $\pm$ 0.0001	1.0000 $\pm$ 0.0001	0.0000 $\pm$ 0.0000
DDPM	0.0001	residual k-nn	1.0000 $\pm$ 0.0000	1.0000 $\pm$ 0.0000	0.0000 $\pm$ 0.0000
DDPM	0.0001	residual mahalanobis	1.0000 $\pm$ 0.0000	1.0000 $\pm$ 0.0000	0.0000 $\pm$ 0.0000
DDPM	0.0001	single-step noise prediction	1.0000 $\pm$ 0.0000	1.0000 $\pm$ 0.0000	0.0000 $\pm$ 0.0000
DDPM	0.0001	single-step reconstruction	1.0000 $\pm$ 0.0000	1.0000 $\pm$ 0.0000	0.0000 $\pm$ 0.0000
DDPM	0.0005	multi-step cosine noise pred.	0.8747 $\pm$ 0.0283	0.8944 $\pm$ 0.0261	0.7465 $\pm$ 0.0064
DDPM	0.0005	multi-step noise prediction	0.9999 $\pm$ 0.0000	0.9999 $\pm$ 0.0000	0.0000 $\pm$ 0.0000
DDPM	0.0005	multi-step reconstruction	0.9999 $\pm$ 0.0001	0.9999 $\pm$ 0.0001	0.0000 $\pm$ 0.0000
DDPM	0.0005	residual k-nn	1.0000 $\pm$ 0.0000	1.0000 $\pm$ 0.0000	0.0000 $\pm$ 0.0000
DDPM	0.0005	residual mahalanobis	1.0000 $\pm$ 0.0000	1.0000 $\pm$ 0.0000	0.0000 $\pm$ 0.0000
DDPM	0.0005	single-step noise prediction	1.0000 $\pm$ 0.0000	1.0000 $\pm$ 0.0000	0.0000 $\pm$ 0.0000
DDPM	0.0005	single-step reconstruction	1.0000 $\pm$ 0.0000	1.0000 $\pm$ 0.0000	0.0000 $\pm$ 0.0000

A.3. PathMNIST

Tabla A.3.: Resultados completos en PATHMNIST (UNet): AUROC, AUPR y FPR@95 % (media $\pm$ desv. típica). Mejor AUROC por grupo en **negrita**.

Método	LR	Score	AUROC	AUPR	FPR@95 %
PATHMNIST_C1					
Baselines					
KNN	–	–	0.6510	0.7225	0.9595
Mahalanobis	–	–	0.2345	0.4536	1.0000
VAE					
VAE	0.0001	ELBO	0.6868 $\pm$ 0.0156	0.8148 $\pm$ 0.0298	0.9267 $\pm$ 0.0180
VAE	0.0001	latent k-nn	0.4408 $\pm$ 0.0433	0.6090 $\pm$ 0.1011	0.9775 $\pm$ 0.0086
VAE	0.0001	latent mahalanobis	0.3766 $\pm$ 0.1389	0.6119 $\pm$ 0.1370	0.9910 $\pm$ 0.0156
VAE	0.0001	reconstruction error	0.7140 $\pm$ 0.0151	0.8305 $\pm$ 0.0271	0.9109 $\pm$ 0.0179
VAE	0.0005	ELBO	0.7038 $\pm$ 0.0158	0.8250 $\pm$ 0.0282	0.9100 $\pm$ 0.0125
VAE	0.0005	latent k-nn	0.4073 $\pm$ 0.0127	0.5890 $\pm$ 0.0683	0.9753 $\pm$ 0.0056
VAE	0.0005	latent mahalanobis	0.3621 $\pm$ 0.0634	0.6044 $\pm$ 0.0768	0.9919 $\pm$ 0.0140
VAE	0.0005	reconstruction error	0.7097 $\pm$ 0.0150	0.8312 $\pm$ 0.0268	0.9217 $\pm$ 0.0257
VAE	0.001	ELBO	0.6910 $\pm$ 0.0017	0.8195 $\pm$ 0.0334	0.9393 $\pm$ 0.0040
VAE	0.001	latent k-nn	0.4709 $\pm$ 0.0071	0.6309 $\pm$ 0.0695	0.9829 $\pm$ 0.0039
VAE	0.001	latent mahalanobis	0.4032 $\pm$ 0.0670	0.6353 $\pm$ 0.0769	0.9928 $\pm$ 0.0125
VAE	0.001	reconstruction error	0.6961 $\pm$ 0.0022	0.8242 $\pm$ 0.0323	0.9487 $\pm$ 0.0027
DDPM					
DDPM	0.0001	multi-step cosine noise pred.	0.5035 $\pm$ 0.0003	0.5762 $\pm$ 0.0002	0.9933 $\pm$ 0.0000
DDPM	0.0001	multi-step noise prediction	0.3335 $\pm$ 0.0021	0.5269 $\pm$ 0.0015	0.9955 $\pm$ 0.0008
DDPM	0.0001	residual k-nn	0.6459 $\pm$ 0.0030	0.7684 $\pm$ 0.0058	0.9847 $\pm$ 0.0021
DDPM	0.0001	residual mahalanobis	0.5220 $\pm$ 0.0068	0.6034 $\pm$ 0.0042	0.9798 $\pm$ 0.0023
DDPM	0.0001	glegle-step mse	0.6482 $\pm$ 0.0012	0.7741 $\pm$ 0.0010	0.9856 $\pm$ 0.0008
DDPM	0.0005	multi-step cosine noise pred.	0.5039 $\pm$ 0.0005	0.5765 $\pm$ 0.0004	0.9933 $\pm$ 0.0000
DDPM	0.0005	multi-step noise prediction	0.3352 $\pm$ 0.0044	0.5277 $\pm$ 0.0030	0.9951 $\pm$ 0.0008
DDPM	0.0005	residual k-nn	0.6502 $\pm$ 0.0029	0.7697 $\pm$ 0.0055	0.9847 $\pm$ 0.0031
DDPM	0.0005	residual mahalanobis	0.5207 $\pm$ 0.0054	0.5998 $\pm$ 0.0028	0.9798 $\pm$ 0.0054
DDPM	0.0005	single-step noise prediction	0.6518 $\pm$ 0.0024	0.7766 $\pm$ 0.0017	0.9861 $\pm$ 0.0008
PATHMNIST_C2					
Baselines					
KNN	–	–	0.7641	0.6676	0.5860
Mahalanobis	–	–	0.5729	0.5771	0.8860
VAE					
VAE	0.0001	ELBO	0.5779 $\pm$ 0.0103	0.4674 $\pm$ 0.1363	0.7570 $\pm$ 0.0276
VAE	0.0001	latent k-nn	0.5065 $\pm$ 0.0301	0.3963 $\pm$ 0.1110	0.8229 $\pm$ 0.0743
VAE	0.0001	latent mahalanobis	0.4994 $\pm$ 0.0229	0.4421 $\pm$ 0.1614	0.9084 $\pm$ 0.0596
VAE	0.0001	reconstruction error	0.5794 $\pm$ 0.0086	0.4706 $\pm$ 0.1366	0.7925 $\pm$ 0.0077
VAE	0.0005	ELBO	0.5841 $\pm$ 0.0088	0.4716 $\pm$ 0.1350	0.7654 $\pm$ 0.0158
VAE	0.0005	latent k-nn	0.5532 $\pm$ 0.0066	0.4173 $\pm$ 0.1236	0.7032 $\pm$ 0.0066
VAE	0.0005	latent mahalanobis	0.5336 $\pm$ 0.0229	0.4850 $\pm$ 0.1962	0.9018 $\pm$ 0.0726
VAE	0.0005	reconstruction error	0.5872 $\pm$ 0.0093	0.4752 $\pm$ 0.1357	0.7818 $\pm$ 0.0178
VAE	0.001	ELBO	0.5843 $\pm$ 0.0098	0.4747 $\pm$ 0.1378	0.7676 $\pm$ 0.0124
VAE	0.001	latent k-nn	0.5673 $\pm$ 0.0175	0.4256 $\pm$ 0.1323	0.6965 $\pm$ 0.0148
VAE	0.001	latent mahalanobis	0.5392 $\pm$ 0.0298	0.4905 $\pm$ 0.2012	0.8991 $\pm$ 0.0510
VAE	0.001	reconstruction error	0.5870 $\pm$ 0.0097	0.4779 $\pm$ 0.1382	0.7835 $\pm$ 0.0124
DDPM					
DDPM	0.0001	multi-step cosine noise pred.	0.5002 $\pm$ 0.0003	0.5002 $\pm$ 0.0003	1.0000 $\pm$ 0.0000
DDPM	0.0001	multi-step noise prediction	0.5497 $\pm$ 0.0029	0.4963 $\pm$ 0.0003	0.7137 $\pm$ 0.0057
DDPM	0.0001	residual k-nn	0.6094 $\pm$ 0.0018	0.5891 $\pm$ 0.0017	0.6987 $\pm$ 0.0051
DDPM	0.0001	residual mahalanobis	0.6146 $\pm$ 0.0007	0.5615 $\pm$ 0.0069	0.6997 $\pm$ 0.0064

Continúa en la siguiente página

6. Conclusiones y trabajo futuro

Método	LR	Score	AUROC	AUPR	FPR@95 %
DDPM	0.0001	single-step noise prediction	0.6093 $\pm$ 0.0021	0.5889 $\pm$ 0.0020	0.7000 $\pm$ 0.0036
DDPM	0.0005	multi-step cosine noise pred.	0.4993 $\pm$ 0.0021	0.5003 $\pm$ 0.0006	1.0000 $\pm$ 0.0000
DDPM	0.0005	multi-step noise prediction	0.5499 $\pm$ 0.0019	0.4979 $\pm$ 0.0003	0.7167 $\pm$ 0.0067
DDPM	0.0005	residual k-nn	0.6112 $\pm$ 0.0020	0.5925 $\pm$ 0.0020	0.6977 $\pm$ 0.0023
DDPM	0.0005	residual mahalanobis	0.6163 $\pm$ 0.0017	0.5628 $\pm$ 0.0078	0.7013 $\pm$ 0.0049
DDPM	0.0005	single-step noise prediction	0.6111 $\pm$ 0.0011	0.5920 $\pm$ 0.0010	0.6970 $\pm$ 0.0017

A.4. SICAP

Tabla A.4.: Resultados completos en SICAP (MLP): AUROC, AUPR y FPR@95 % (media $\pm$ desv. típica). Mejor AUROC por grupo en **negrita**.

Método	LR	Score	AUROC	AUPR	FPR@95 %
SICAP_C1					
Baselines					
KNN	–	–	0.6848	0.8440	0.7735
Mahalanobis	–	–	0.8348	0.9291	0.6158
VAE					
VAE	0.0001	ELBO	0.8553 $\pm$ 0.0026	0.9406 $\pm$ 0.0016	0.5912 $\pm$ 0.0207
VAE	0.0001	latent k-nn	0.7294 $\pm$ 0.0325	0.8685 $\pm$ 0.0230	0.7854 $\pm$ 0.0448
VAE	0.0001	latent mahalanobis	0.7363 $\pm$ 0.0207	0.8789 $\pm$ 0.0160	0.8092 $\pm$ 0.0199
VAE	0.0001	reconstruction error	0.8553 $\pm$ 0.0026	0.9406 $\pm$ 0.0016	0.5895 $\pm$ 0.0198
VAE	0.0005	ELBO	0.8484 $\pm$ 0.0042	0.9375 $\pm$ 0.0017	0.6047 $\pm$ 0.0578
VAE	0.0005	latent k-nn	0.7411 $\pm$ 0.0199	0.8740 $\pm$ 0.0132	0.7489 $\pm$ 0.0345
VAE	0.0005	latent mahalanobis	0.7292 $\pm$ 0.0066	0.8778 $\pm$ 0.0053	0.8007 $\pm$ 0.0260
VAE	0.0005	reconstruction error	0.8484 $\pm$ 0.0042	0.9375 $\pm$ 0.0017	0.6039 $\pm$ 0.0575
VAE	0.001	ELBO	0.8432 $\pm$ 0.0033	0.9352 $\pm$ 0.0009	0.5946 $\pm$ 0.0145
VAE	0.001	latent k-nn	0.7519 $\pm$ 0.0087	0.8799 $\pm$ 0.0065	0.7472 $\pm$ 0.0459
VAE	0.001	latent mahalanobis	0.7003 $\pm$ 0.0119	0.8574 $\pm$ 0.0082	0.8159 $\pm$ 0.0216
VAE	0.001	reconstruction error	0.8431 $\pm$ 0.0033	0.9352 $\pm$ 0.0009	0.5954 $\pm$ 0.0127
DDPM					
DDPM	0.0001	multi-step cosine noise pred.	0.4719 $\pm$ 0.0000	0.7230 $\pm$ 0.0000	1.0000 $\pm$ 0.0000
DDPM	0.0001	multi-step noise prediction	0.6841 $\pm$ 0.0099	0.8538 $\pm$ 0.0072	0.8770 $\pm$ 0.0251
DDPM	0.0001	multi-step reconstruction	0.8072 $\pm$ 0.0006	0.9147 $\pm$ 0.0003	0.6472 $\pm$ 0.0039
DDPM	0.0001	residual k-nn	0.7993 $\pm$ 0.0167	0.9193 $\pm$ 0.0056	0.7379 $\pm$ 0.0658
DDPM	0.0001	residual mahalanobis	0.7679 $\pm$ 0.0025	0.9061 $\pm$ 0.0026	0.9126 $\pm$ 0.0206
DDPM	0.0001	single-step noise prediction	0.7254 $\pm$ 0.0078	0.8775 $\pm$ 0.0056	0.8405 $\pm$ 0.0193
DDPM	0.0001	single-step reconstruction	0.8048 $\pm$ 0.0009	0.9131 $\pm$ 0.0005	0.6472 $\pm$ 0.0145
DDPM	0.0005	multi-step cosine noise pred.	0.4719 $\pm$ 0.0000	0.7230 $\pm$ 0.0000	1.0000 $\pm$ 0.0000
DDPM	0.0005	multi-step noise prediction	0.8167 $\pm$ 0.0082	0.9227 $\pm$ 0.0035	0.6879 $\pm$ 0.0169
DDPM	0.0005	multi-step reconstruction	0.8169 $\pm$ 0.0009	0.9192 $\pm$ 0.0004	0.6421 $\pm$ 0.0103
DDPM	0.0005	residual k-nn	0.6865 $\pm$ 0.0038	0.8673 $\pm$ 0.0022	0.9109 $\pm$ 0.0178
DDPM	0.0005	residual mahalanobis	0.7899 $\pm$ 0.0052	0.9112 $\pm$ 0.0019	0.7260 $\pm$ 0.0274
DDPM	0.0005	single-step noise prediction	0.8244 $\pm$ 0.0060	0.9262 $\pm$ 0.0032	0.6599 $\pm$ 0.0204
DDPM	0.0005	single-step reconstruction	0.8075 $\pm$ 0.0009	0.9143 $\pm$ 0.0005	0.6438 $\pm$ 0.0051
DDPM	0.001	multi-step cosine noise pred.	0.4719 $\pm$ 0.0000	0.7230 $\pm$ 0.0000	1.0000 $\pm$ 0.0000
DDPM	0.001	multi-step noise prediction	0.8231 $\pm$ 0.0064	0.9256 $\pm$ 0.0028	0.6768 $\pm$ 0.0254
DDPM	0.001	multi-step reconstruction	0.8183 $\pm$ 0.0008	0.9199 $\pm$ 0.0003	0.6412 $\pm$ 0.0044
DDPM	0.001	residual k-nn	0.7294 $\pm$ 0.0114	0.8871 $\pm$ 0.0058	0.8643 $\pm$ 0.0106
DDPM	0.001	residual mahalanobis	0.7987 $\pm$ 0.0077	0.9144 $\pm$ 0.0047	0.7142 $\pm$ 0.0229
DDPM	0.001	single-step noise prediction	0.8270 $\pm$ 0.0063	0.9277 $\pm$ 0.0033	0.6641 $\pm$ 0.0111
DDPM	0.001	single-step reconstruction	0.8078 $\pm$ 0.0009	0.9144 $\pm$ 0.0004	0.6387 $\pm$ 0.0155

Continúa en la siguiente página

Método	LR	Score	AUROC	AUPR	FPR@95 %
SICAP_C12					
Baselines					
KNN	–	–	0.6146	0.1989	0.7608
Mahalanobis	–	–	0.8545	0.5876	0.6051
VAE					
VAE	0.0001	ELBO	0.8388 ± 0.0023	0.5559 ± 0.0033	0.5757 ± 0.0230
VAE	0.0001	latent k-nn	0.8474 ± 0.0024	0.5303 ± 0.0109	0.5222 ± 0.0191
VAE	0.0001	latent mahalanobis	0.8520 ± 0.0267	0.5474 ± 0.0782	0.5425 ± 0.0876
VAE	0.0001	reconstruction error	0.8383 ± 0.0025	0.5553 ± 0.0037	0.5778 ± 0.0233
VAE	0.0005	ELBO	0.8466 ± 0.0014	0.5820 ± 0.0028	0.5934 ± 0.0079
VAE	0.0005	latent k-nn	0.8283 ± 0.0157	0.5226 ± 0.0511	0.5714 ± 0.0174
VAE	0.0005	latent mahalanobis	0.8367 ± 0.0231	0.5448 ± 0.0720	0.5738 ± 0.0571
VAE	0.0005	reconstruction error	0.8460 ± 0.0016	0.5814 ± 0.0026	0.5950 ± 0.0100
VAE	0.001	ELBO	0.8640 ± 0.0002	0.5992 ± 0.0041	0.4997 ± 0.0353
VAE	0.001	latent k-nn	0.7983 ± 0.0194	0.4135 ± 0.0530	0.5995 ± 0.0461
VAE	0.001	latent mahalanobis	0.8140 ± 0.0320	0.4415 ± 0.1006	0.5722 ± 0.0401
VAE	0.001	reconstruction error	0.8636 ± 0.0002	0.5984 ± 0.0040	0.5016 ± 0.0352
DDPM					
DDPM	0.0001	multi-step cosine noise pred.	0.5293 ± 0.0011	0.1651 ± 0.0003	0.9414 ± 0.0021
DDPM	0.0001	multi-step noise prediction	0.8295 ± 0.0027	0.5396 ± 0.0175	0.6338 ± 0.0173
DDPM	0.0001	multi-step reconstruction	0.8543 ± 0.0036	0.5711 ± 0.0034	0.5449 ± 0.0264
DDPM	0.0001	residual k-nn	0.6556 ± 0.0089	0.3277 ± 0.0145	0.9155 ± 0.0208
DDPM	0.0001	residual mahalanobis	0.8423 ± 0.0046	0.5535 ± 0.0147	0.6287 ± 0.0444
DDPM	0.0001	single-step noise prediction	0.8362 ± 0.0041	0.5444 ± 0.0222	0.6431 ± 0.0202
DDPM	0.0001	single-step reconstruction	0.8507 ± 0.0008	0.5556 ± 0.0012	0.5698 ± 0.0137
DDPM	0.0005	multi-step cosine noise pred.	0.5610 ± 0.0028	0.1750 ± 0.0009	0.8753 ± 0.0073
DDPM	0.0005	multi-step noise prediction	0.8400 ± 0.0035	0.5582 ± 0.0137	0.6233 ± 0.0161
DDPM	0.0005	multi-step reconstruction	0.8553 ± 0.0037	0.5725 ± 0.0033	0.5465 ± 0.0234
DDPM	0.0005	residual k-nn	0.7075 ± 0.0097	0.3869 ± 0.0181	0.8906 ± 0.0359
DDPM	0.0005	residual mahalanobis	0.8413 ± 0.0038	0.5552 ± 0.0203	0.6297 ± 0.0309
DDPM	0.0005	single-step noise prediction	0.8362 ± 0.0038	0.5458 ± 0.0206	0.6407 ± 0.0226
DDPM	0.0005	single-step reconstruction	0.8510 ± 0.0010	0.5556 ± 0.0011	0.5752 ± 0.0067
DDPM	0.001	multi-step cosine noise pred.	0.5566 ± 0.0013	0.1735 ± 0.0004	0.8777 ± 0.0044
DDPM	0.001	multi-step noise prediction	0.8408 ± 0.0024	0.5565 ± 0.0128	0.6129 ± 0.0159
DDPM	0.001	multi-step reconstruction	0.8554 ± 0.0028	0.5714 ± 0.0019	0.5449 ± 0.0273
DDPM	0.001	residual k-nn	0.6928 ± 0.0207	0.3807 ± 0.0223	0.9048 ± 0.0198
DDPM	0.001	residual mahalanobis	0.8414 ± 0.0050	0.5515 ± 0.0192	0.6276 ± 0.0494
DDPM	0.001	single-step noise prediction	0.8369 ± 0.0043	0.5424 ± 0.0210	0.6378 ± 0.0337
DDPM	0.001	single-step reconstruction	0.8509 ± 0.0008	0.5552 ± 0.0011	0.5754 ± 0.0070

B. Planificación y estimación de costes

B.1. Planificación temporal

A lo largo del desarrollo de este Trabajo de Fin de Grado se ha seguido una planificación que abarca desde octubre de 2025 hasta junio de 2026, fecha prevista de entrega. El proyecto se inició formalmente tras una reunión celebrada el 26 de septiembre de 2025, en la que participaron los codirectores del trabajo, Miguel López y Rafael Molina, así como Javier Sáez, cuya colaboración ha sido también significativa a lo largo de todo el proceso. A partir de entonces, se han celebrado reuniones de seguimiento con carácter bisemanal a través de Google Meet, salvo durante las vacaciones de Navidad, la convocatoria ordinaria de enero y la Semana Santa. La comunicación entre reuniones se ha gestionado mediante Slack.

Para llevar a cabo el proyecto se identificaron los siguientes requisitos principales: acceso a bibliografía especializada en modelos generativos y detección de anomalías médicas; capacidad de cómputo con GPU para el entrenamiento de modelos de difusión; conjuntos de datos de imagen médica con sus correspondientes anotaciones; y un entorno de software basado en herramientas de código abierto (PyTorch, MONAI) junto con infraestructura de seguimiento experimental (Weights & Biases, GitHub).

La planificación inicial contemplaba una progresión lineal desde la investigación previa hasta la redacción final, distribuida en cinco grandes bloques de trabajo. Se esperaba que la revisión del estado del arte y la puesta en marcha del código se completarían durante el primer cuatrimestre, dejando el segundo cuatrimestre dedicado a la experimentación y a la redacción (Figura B.1).




Figura B.1.: Planificación inicial del proyecto.

El desarrollo real del proyecto divergió de esta planificación inicial por varias razones. En primer lugar, la amplitud del estado del arte en modelos generativos aplicados a la detección de anomalías médicas exigió una fase de investigación más extensa de lo previsto, que se extendió a lo largo de todo el primer cuatrimestre. El periodo de la convocatoria extraordinaria de febrero, que quedó libre de exámenes, se destinó íntegramente a profundizar en el estudio de la literatura y a comenzar la redacción del marco teórico, tarea que no estaba contemplada de forma explícita en la planificación inicial.

En segundo lugar, se introdujeron experimentos sobre conjuntos sintéticos (Moons y Blobs) como paso intermedio antes de abordar conjuntos de imágenes reales. Esta deci-

sión, no prevista originalmente, resultó esencial para validar el *pipeline* de entrenamiento y depurar la implementación en un entorno controlado. Posteriormente, la experimentación siguió una progresión escalonada: conjuntos sintéticos, MNIST, PathMNIST y, finalmente, SICAP como caso de uso clínico. La incorporación de este último conjunto, más la necesidad de explorar arquitecturas UNet-DDPM de mayor capacidad para MNIST y PathMNIST antes de consolidar los experimentos MLP para SICAP, añadió carga de trabajo adicional. Por último, la redacción de la memoria experimental se llevó a cabo de forma paralela a los experimentos, con seguimiento continuo en *Weights & Biases* y control de versiones en GitHub. La planificación real del proyecto se recoge en la Figura B.2.



Figura B.2.: Planificación final del proyecto.

En cuanto al cumplimiento de los objetivos iniciales, el trabajo ha cubierto el objetivo principal de estudiar e implementar modelos generativos profundos para la detección de anomalías en imagen médica, evaluando VAEs y DDPMs sobre conjuntos de datos de complejidad creciente. El alcance final resultó incluso más amplio que el planificado, incorporando conjuntos sintéticos como punto de partida y el conjunto histológico SICAP como aplicación clínica de referencia.

B.2. Estimación de costes

Aunque el trabajo se ha desarrollado íntegramente con software libre y recursos proporcionados de forma institucional o gratuita, se puede realizar una estimación aproximada del esfuerzo y los recursos implicados.

La dedicación al proyecto fue variable a lo largo del año. Durante el primer cuatrimestre se destinó aproximadamente un día a la semana a la lectura de trabajos y exploración de herramientas, utilizando para ello la GPU T4 de Google Colab en su modalidad gratuita. El mes de febrero, al coincidir con la convocatoria extraordinaria y quedar libre de exámenes, se aprovechó de forma más intensiva para la investigación y la escritura del marco teórico. En el segundo cuatrimestre, y con acceso institucional a un servidor con cuatro GPUs NVIDIA RTX 3090 desde el inicio de los experimentos con imágenes, la dedicación ascendió a dos días semanales en la primera mitad, aumentando a tres días tras la Semana Santa. Durante el mes de junio, destinado al cierre del trabajo, se trabajó cuatro días a la semana.

El Cuadro B.1 recoge la estimación de costes, asumiendo un coste por hora de 20 €¹ para

¹Valor obtenido a partir del salario medio de perfiles de *machine learning* en España (≈ 34.000 €/año según Glassdoor, https://www.glassdoor.es/Sueldos/machine-learning-sueldo-SRCH_K00,16.htm), dividido entre las 1.800 horas laborables anuales establecidas por el Estatuto de los Trabajadores.

B. Planificación y estimación de costes

las tareas de desarrollo, investigación y redacción. El servidor de entrenamiento, de uso institucional, se valora a precio de mercado en aproximadamente 3.500 € para el periodo de uso.

Tabla B.1.: Estimación aproximada de los costes de la realización del TFG.

Concepto	Horas empleadas	Coste total (€)
Investigación previa (papers, MONAI, repos)	70	1.400
Investigación en profundidad y redacción del marco teórico	80	1.600
Implementación del <i>framework</i> experimental	30	600
Experimentación con conjuntos sintéticos (Moons, Blobs)	20	400
Experimentación con MNIST y PathMNIST (MLP y UNet-DDPM)	55	1.100
Experimentación con SICAP	65	1.300
Redacción de la memoria experimental	40	800
Corrección, revisión y apéndices	40	800
Servidor 4 × NVIDIA RTX 3090 (institucional, 2.º cuatrimestre)	—	3.500
Total	400	11.500

El coste total estimado del proyecto asciende a **11.500 €**, correspondiendo 8.000 € a las 400 horas de trabajo personal y 3.500 € al uso valorado del servidor de entrenamiento. El acceso a la GPU T4 de Google Colab, empleada durante el primer cuatrimestre en su modalidad gratuita, no supone coste adicional.

Bibliografía

- [AY01] Charu C. Aggarwal y Philip S. Yu. Outlier detection for high dimensional data. En *Proceedings of the 2001 ACM SIGMOD international conference on Management of data*, páginas 37–46, 2001.
- [BCD⁺19] Terrance E. Boult, Steve Cruz, Akshay R. Dhamija, Manuel Gunther, James Henrydoss, y Walter J. Scheirer. Learning and the unknown: Surveying steps toward open world recognition. En *Proceedings of the AAAI Conference on Artificial Intelligence*, volumen 33, páginas 9801–9808, 2019.
- [BHA⁺21] Rishi Bommasani, Drew A. Hudson, Ehsan Adeli, Russ Altman, Simran Arora, Sydney von Arx, Michael S. Bernstein, Jeannette Bohg, Antoine Bosselut, Emma Brunskill, et al. On the opportunities and risks of foundation models, 2021.
- [Bie20] Lukas Biewald. Experiment tracking with weights and biases, 2020. Software available from wandb.com.
- [BVV⁺16] Samuel R. Bowman, Luke Vilnis, Oriol Vinyals, Andrew M. Dai, Rafal Józefowicz, y Samy Bengio. Generating sentences from a continuous space. En *Proceedings of the 20th SIGNLL Conference on Computational Natural Language Learning*, páginas 10–21, 2016.
- [CDL⁺24] Richard J. Chen, Tong Ding, Ming Y. Lu, Drew F. K. Williamson, Guillaume Jaume, Andrew H. Song, Bowen Chen, Andrew Zhang, Daniel Shao, Muhammad Shaban, Mane Williams, Lukas Oldenburg, Luca L. Weishaupt, Judy J. Wang, Anurag Vaidya, Long Phi Le, Georg Gerber, Sharifa Sahai, Walt Williams, y Faisal Mahmood. Towards a general-purpose foundation model for computational pathology. *Nature Medicine*, 30:850–862, March 2024.
- [CLB⁺22] M. Jorge Cardoso, Wenqi Li, Richard Brown, Nic Ma, Eric Kerfoot, Yiheng Wang, Benjamin Murrey, Andriy Myronenko, Can Zhao, Dong Yang, Daguang Xu, et al. MONAI: An open-source framework for deep learning in healthcare. <https://github.com/Project-MONAI/MONAI>, 2022. GitHub repository.
- [DSC⁺18] Taylor Denouden, Rick Salay, Krzysztof Czarnecki, Vahdat Abdelzad, Buu Phan, y Sachin Vernekar. Improving reconstruction autoencoder out-of-distribution detection with Mahalanobis distance, 2018.
- [DWJ⁺22] Xuefeng Du, Zhenfang Wang, Muhao Jiang, Yifei Qi, y Yixuan Li. VOS: Learning what you don’t know by virtual outlier synthesis. En *International Conference on Learning Representations (ICLR)*, 2022.
- [GG16] Yarin Gal y Zoubin Ghahramani. Dropout as a Bayesian approximation: Representing model uncertainty in deep learning. En *International Conference on Machine Learning (ICML)*, páginas 1050–1059, 2016.
- [GPT⁺23] Mark S. Graham, Walter H. L. Pinaya, Petru-Daniel Tudosiu, Parashkev Nachev, Sebastien Ourselin, y M. Jorge Cardoso. Denoising diffusion models for out-of-distribution detection, April 2023. arXiv:2211.07740.
- [GTW⁺23] Mark S. Graham, Petru-Daniel Tudosiu, Paul Wright, Walter Hugo Lopez Pinaya, Petteri Teikari, Ashay Patel, Jean-Marie U-King-Im, Yee H. Mah, James T. Teo, Hans Rolf Jäger, David Werring, Geraint Rees, Parashkev Nachev, Sebastien Ourselin, y M. Jorge Cardoso. Latent Transformer Models for out-of-distribution detection. *Medical Image Analysis*, 90:102967, December 2023.

- [HBY⁺23] Zhi Huang, Federico Bianchi, Mert Yuksekgonul, Thomas J. Montine, y James Zou. A visual-language foundation model for pathology image analysis using medical Twitter. *Nature Medicine*, 29:2307–2316, 2023.
- [HG17] Dan Hendrycks y Kevin Gimpel. A baseline for detecting misclassified and out-of-distribution examples in neural networks. En *ICLR*, 2017.
- [HGL21] Rui Huang, Andrew Geng, y Yixuan Li. On the importance of gradients for detecting distributional shifts in the wild. En *NeurIPS*, 2021.
- [HJA20] Jonathan Ho, Ajay Jain, y Pieter Abbeel. Denoising diffusion probabilistic models. En *Advances in Neural Information Processing Systems (NeurIPS)*, volumen 33, páginas 6840–6851, 2020.
- [HLW⁺20] Haiwen Huang, Zhihan Li, Lulu Wang, Sishuo Chen, Bin Dong, y Xinyu Zhou. Feature space singularity for out-of-distribution detection. *arXiv preprint arXiv:2011.14654*, 2020.
- [HMD19] Dan Hendrycks, Mantas Mazeika, y Thomas Dietterich. Deep anomaly detection with outlier exposure. En *International Conference on Learning Representations (ICLR)*, 2019.
- [HYC⁺24] Zesheng Hong, Yubiao Yue, Yubin Chen, Lele Cong, Huanjie Lin, Yuanmei Luo, Mini Han Wang, Weidong Wang, Jialong Xu, Xiaoqi Yang, Hechang Chen, Zhenzhang Li, y Sihong Xie. Out-of-distribution Detection in Medical Image Analysis: A survey, April 2024.
- [KB15] Diederik P. Kingma y Jimmy Ba. Adam: A method for stochastic optimization. En *International Conference on Learning Representations*, 2015.
- [KW14] Diederik P. Kingma y Max Welling. Auto-encoding variational bayes. En *International Conference on Learning Representations (ICLR)*, 2014.
- [LBBH98] Yann LeCun, Léon Bottou, Yoshua Bengio, y Patrick Haffner. Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11):2278–2324, 1998.
- [LCW⁺24] Ming Y. Lu, Bowen Chen, Drew F. K. Williamson, Richard J. Chen, Ivy Liang, Tong Ding, Guillaume Jaume, Igor Odintsov, Andrew Zhang, Daniel Shao, et al. A visual-language foundation model for computational pathology. *Nature Medicine*, 30:863–874, 2024.
- [LH19] Ilya Loshchilov y Frank Hutter. Decoupled weight decay regularization. En *International Conference on Learning Representations*, 2019.
- [LJL⁺23] Kristina Lång, Viktoria Josefsson, Anna-Maria Larsson, Stefan Larsson, Charlotte Högborg, Hanna Sartor, Solveig Hofvind, Ingvar Andersson, y Aldana Rosso. Artificial intelligence-supported screen reading versus standard double reading in the Mammography Screening with Artificial Intelligence trial (MASAI): a clinical safety analysis of a randomised, controlled, non-inferiority, single-blinded, screening accuracy study. *The Lancet Oncology*, 24(8):936–944, 2023.
- [LLLS18] Kimin Lee, Kibok Lee, Honglak Lee, y Jinwoo Shin. A simple unified framework for detecting out-of-distribution samples and adversarial attacks. En *NeurIPS*, 2018.
- [LLS18] Shiyu Liang, Yixuan Li, y R. Srikant. Enhancing the reliability of out-of-distribution image detection in neural networks. En *ICLR*, 2018.
- [LPB17] Balaji Pravisubset Lakshminarayanan, Alexander Pritzel, y Charles Blundell. Simple and scalable predictive uncertainty estimation using deep ensembles. *Advances in Neural Information Processing Systems (NeurIPS)*, 30, 2017.
- [LRvdLL24] Jasper Linmans, Gabriel Raya, Jeroen van der Laak, y Geert Litjens. Diffusion models for out-of-distribution detection in digital pathology. *Medical Image Analysis*, 93:103088, January 2024.
- [LSK⁺25] Chieh-Hsin Lai, Yang Song, Dongjun Kim, Yuki Mitsufuji, y Stefano Ermon. The Principles of Diffusion Models, October 2025. *arXiv:2510.21890*.

- [LWOL20] Weitang Liu, Xiaoyun Wang, John Owens, y Yixuan Li. Energy-based out-of-distribution detection. En *NeurIPS*, 2020.
- [MG18] Andrey Malinin y Mark Gales. Prior networks for detecting out-of-distribution examples. *Advances in Neural Information Processing Systems (NeurIPS)*, 31, 2018.
- [MSDL23] Yifei Ming, Yiyu Sun, Ousmane Dia, y Yixuan Li. CIDER: Exploiting hyperspherical embeddings for out-of-distribution detection. En *ICLR*, 2023.
- [Nea12] Radford M. Neal. *Bayesian Learning for Neural Networks*. Springer, 2012.
- [NMT⁺19] Eric Nalisnick, Akihiro Matsukawa, Yee Whye Teh, Dilan Gorur, y Balaji Lakshminarayanan. Do deep generative models know what they don't know? En *ICLR*, 2019.
- [NWC⁺11] Yuval Netzer, Tao Wang, Adam Coates, Alessandro Bissacco, Bo Wu, y Andrew Y. Ng. Reading digits in natural images with unsupervised feature learning. En *NeurIPS Workshop on Deep Learning and Unsupervised Feature Learning*, 2011.
- [PCCT14] Marco A. F. Pimentel, David A. Clifton, Lei Clifton, y Lionel Tarassenko. A review of novelty detection. *Signal Processing*, 99:215–249, 2014.
- [PDBE25] Milda Pocevičiūtė, Yifan Ding, Ruben Bromée, y Gabriel Eilertsen. Out-of-distribution detection in digital pathology: Do foundation models bring the end to reconstruction-based approaches? *Computers in Biology and Medicine*, 184:109327, January 2025.
- [Pro23a] Project MONAI. 2d denoising diffusion probabilistic model tutorial. https://github.com/Project-MONAI/GenerativeModels/blob/main/tutorials/generative/2d_ddpm/2d_ddpm_tutorial.ipynb, 2023. Accedido: 2025.
- [Pro23b] Project MONAI. 2d latent diffusion model tutorial. https://github.com/Project-MONAI/GenerativeModels/blob/main/tutorials/generative/2d_ldm/2d_ldm_tutorial.ipynb, 2023. Accedido: 2025.
- [PSCvdH20] Guansong Pang, Chunhua Shen, Longbing Cao, y Anton van den Hengel. Deep learning for anomaly detection: A review. *ACM Computing Surveys (CSUR)*, 54(2):1–38, 2020.
- [PVG⁺11] Fabian Pedregosa, Gaël Varoquaux, Alexandre Gramfort, Vincent Michel, Bertrand Thirion, Olivier Grisel, Mathieu Blondel, Peter Prettenhofer, Ron Weiss, Vincent Dubourg, Jake Vanderplas, Alexandre Passos, David Cournapeau, Matthieu Brucher, Matthieu Perrot, y Édouard Duchesnay. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.
- [RBL⁺22] Robin Rombach, Andreas Blattmann, Dominik Lorenz, Patrick Esser, y Björn Ommer. High-Resolution Image Synthesis with Latent Diffusion Models, April 2022. arXiv:2112.10752.
- [RFB15] Olaf Ronneberger, Philipp Fischer, y Thomas Brox. U-net: Convolutional networks for biomedical image segmentation. En *Medical Image Computing and Computer-Assisted Intervention–MICCAI 2015*, páginas 234–241. Springer, 2015.
- [RKH⁺21] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, et al. Learning transferable visual models from natural language supervision. En *ICML*, 2021.
- [RKV⁺21] Lukas Ruff, Jacob R. Kauffmann, Robert A. Vandermeulen, Grégoire Montavon, Wojciech Samek, Marius Kloft, Thomas G. Dietterich, y Klaus-Robert Müller. A unifying review of deep and shallow anomaly detection. *Proceedings of the IEEE*, 109(5):756–795, 2021.
- [SÁG⁺20] Joan Serrà, David Álvarez, Vicenç Gómez, Olga Slizovskaia, José F. Núñez, y Jordi Luque. Input complexity and out-of-distribution detection with likelihood-based generative models. En *International Conference on Learning Representations*, 2020.
- [Sch24] Schinger. DiffusionModel: Simple mlp-based diffusion model. <https://github.com/schinger/DiffusionModel>, 2024. Accedido: 2025.

- [SGL21] Yiyou Sun, Chuan Guo, y Yixuan Li. ReAct: Out-of-distribution detection with rectified activations. En *NeurIPS*, 2021.
- [SMZL22] Yiyou Sun, Yifei Ming, Xiaojin Zhu, y Yixuan Li. Out-of-distribution detection with deep nearest neighbors. En *ICML*, 2022.
- [SRCS⁺20] Julio Silva-Rodríguez, Adrián Colomer, María A. Sales, Rafael Molina, y Valery Naranjo. Going deeper through the Gleason scoring scale: An automatic end-to-end system for prostate cancer grading and cribriform pattern detection. *Computer Methods and Programs in Biomedicine*, 195:105637, 2020.
- [TSM⁺20] Matthew Tancik, Pratul P. Srinivasan, Ben Mildenhall, Sara Fridovich-Keil, Nithin Raghavan, Utkarsh Singhal, Ravi Ramamoorthi, Jonathan T. Barron, y Ren Ng. Fourier features let networks learn high frequency functions in low dimensional domains. En *Advances in Neural Information Processing Systems*, volumen 33, páginas 7537–7547, 2020.
- [vASTG20] Joost van Amersfoort, Lewis Smith, Yee Whye Teh, y Yarin Gal. Uncertainty estimation using a single deep deterministic neural network. En *ICML*, 2020.
- [vPPL⁺22] Patrick von Platen, Suraj Patil, Anton Lozhkov, Pedro Cuenca, Nathan Lambert, Kashif Rasul, Mishig Datta, y Thomas Wolf. Diffusers: State-of-the-art diffusion models. <https://github.com/huggingface/diffusers>, 2022.
- [WLSW22] Julian Wyatt, Adam Leach, Sebastian M. Schmon, y Chris G. Willcocks. AnoDDPM: Anomaly detection with denoising diffusion probabilistic models using simplex noise. En *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR) Workshops*, páginas 650–656, 2022.
- [WXC⁺22] Hongxin Wei, Renshuai Xie, Hao Cheng, Lei Feng, Bo An, y Yixuan Li. Mitigating neural network overconfidence with LogitNorm. En *International Conference on Machine Learning (ICML)*, páginas 23631–23644. PMLR, 2022.
- [YSW⁺23] Jiancheng Yang, Rui Shi, Donglai Wei, Zequan Liu, Lin Zhao, Bilian Ke, Hanspeter Pfister, y Bingbing Ni. MedMNIST v2—a large-scale lightweight benchmark for 2d and 3d biomedical image classification. *Scientific Data*, 10(1):41, 2023.
- [YZLL24] Jingkan Yang, Kaiyang Zhou, Yixuan Li, y Ziwei Liu. Generalized Out-of-Distribution Detection: A Survey, January 2024. arXiv:2110.11334.
- [ZFC⁺23] Jinsong Zhang, Qiang Fu, Xu Chen, Lun Du, Zelin Li, Gang Wang, Shi Han, Dongmei Zhang, et al. Out-of-distribution detection based on in-distribution data patterns memorization with modern Hopfield energy. En *ICLR*, 2023.
- [ZFI⁺22] David Zimmerer, Peter M. Full, Fabian Isensee, Paul Jäger, Tim Adler, Jens Petersen, Gregor Köhler, Tobias Ross, Annika Reinke, Antanas Kascenas, Bjørn Sand Jensen, Alison Q. O’Neil, Jeremy Tan, Benjamin Hou, James Batten, Huaqi Qiu, Bernhard Kainz, Nina Shvetsova, Irina Fedulova, Dmitry V. Dylov, et al. MOOD 2020: A public benchmark for out-of-distribution detection and localization on medical images. *IEEE Transactions on Medical Imaging*, 41(10):2728–2738, 2022.
- [ZGFK17] Hang Zhao, Orazio Gallo, Iuri Frosio, y Jan Kautz. Loss functions for image restoration with neural networks. *IEEE Transactions on Computational Imaging*, 3(1):47–57, 2017.